Carnet de bord

Travailler avec l'IA sur le mémoire « Chercher ou répondre ? »

Valentin Proux

Version du 9 novembre 2026, deuxième passe

Comment ce carnet a été écrit

Ce carnet suit les quatre rubriques demandées par la trame : les outils utilisés, mes difficultés, mon rapport d'étonnement, ce que j'aimerais approfondir. J'y ajoute deux parties qui me paraissent nécessaires pour un mémoire expérimental : le registre des décisions de méthode, avec leur justification, et la déclaration des données.

Qui a écrit quoi. Le carnet a été tenu au fil de l'eau par Claude Code (assistant de programmation d'Anthropic), à ma demande. Il part de nos échanges, de l'historique git du dépôt et des fichiers produits. Je l'ai relu. Je lui ai laissé carte blanche, y compris pour inventer ; Claude a choisi de ne rien y inventer de factuel, et je l'ai gardé ainsi : un carnet de bord qui raconterait des choses qui ne sont pas arrivées n'aurait aucune valeur de preuve. Chaque fait renvoie donc à un fichier, à un commit ou à un résultat que l'on peut rouvrir. Les durées viennent des horaires des commits ; quand je ne les connais pas, je ne les donne pas.

Convention. Dans le registre des décisions, [moi] marque une décision que j'ai prise ou imposée, [IA] une proposition de l'IA que j'ai acceptée. Une décision [IA] acceptée reste sous ma responsabilité : c'est moi qui la défends.

Dépôt. Tout le code, l'article et ce carnet sont dans le dépôt public `github.com/vqlentinn/memoire-rl-search`. Les commits sont à mon nom, sans mention de l'IA : c'est un choix de forme pour l'historique du code, pas une dissimulation. La part de l'IA est déclarée ici et dans la section « Limites » de l'article.

Table des matières

1 Le projet en bref **2**

2 La trame, étape par étape **2**

3 Les outils utilisés **3**

4 Contrôle de conformité à la trame **4**

5 Registre des décisions de méthode **5**

6 Données **11**

7 Part de l'IA dans le travail **12**

8 Mes difficultés **13**

9 Mon rapport d'étonnement **13**

10 Ce que j'aimerais approfondir **14**

11 Relecture de la discussion par l'IA (étape 10.3) **14**

12 Risques de l'IA et garde-fous **15**

13 Ressources consommées **15**

14 Fiche de problématique (étape 3) **16**

15 Chronologie **16**

16 Mes demandes à l'IA (extraits) **17**

1 Le projet en bref

Question. À corpus et questions identiques, un agent de recherche entraîné par renforcement (Search-R1) décide-t-il mieux *quand* et *quoi* chercher qu'un harnais fixe (RAG, ReAct, IRCoT), et à quel coût ?

Contraintes. Budget de 0 € : pas de crédit d'API, calcul uniquement sur les GPU gratuits de Kaggle (deux T4 ou une P100, environ 30 h par semaine, 20 Go de sortie). Ces contraintes expliquent la plupart des choix du registre (section 5).

Livrables. L'article (`docs/article/main.pdf`) est une mini-expérience tirée du mémoire : six systèmes, deux jeux de 100 questions. Le mémoire, lui, prévoit sept jeux, 500 questions par jeu et trois volets (inférence, entraînement, analyse des échecs).

État au 9 novembre. L'article est complet, sur des résultats réels : le run d'évaluation (1 200 trajectoires) a tourné sur Kaggle le 9 novembre. Un premier rendu avait été fait le matin même sur des **données fictives**, déclarées comme telles (section 6), pour tester la chaîne ; il a été entièrement remplacé.

2 La trame, étape par étape

La trame suppose un article de cours rédigé dans Word, converti en LaTeX avec le gabarit du cours, et des données traitées dans Google Colab. Mon cas diffère : il n'y a pas de cours, c'est mon sujet de mémoire, et l'expérience demande un GPU. J'ai donc suivi la trame comme référence de méthode, et non comme une suite d'outils imposés. Le tableau dit, pour chaque étape, ce qui a été fait, ce qui a été adapté et pourquoi.

Étape	Statut	Ce qui a été fait, et pourquoi cette forme
1. Comptes, connecteur	Fait, adapté	Connecteur OpenAlex branché sur Claude et utilisé à partir de l'étape 5 (reprise). Overleaf pas encore utilisé : l'article compile en local avec `tectonic`, ce qui me permet de régénérer tableaux et figures depuis le code sans copier de fichiers à la main. L'import dans Overleaf reste prévu pour le rendu de la source.
2. Projet Claude	Fait	Projet « memoire-rl-search », avec la description du mémoire. Le contexte durable du projet est aussi dans `CLAUDE.md`, lu par Claude Code à chaque session.
3. Problématique	Fait, adapté	La question et les hypothèses H1 à H4 existaient avant ces séances : elles sont de moi. La méthode du plugin a été appliquée avec Claude plutôt que dans ChatGPT : fiche de synthèse en dix rubriques (section 14). Consensus utilisé (10 articles, tous favorables au RL, pas de Consensus Meter fourni par l'outil). Open Knowledge Maps non fait.
4. Introduction	Fait	Réécrite le 9 novembre selon les cinq mouvements de la page « entonnoir » du site (contexte large, problème réel, faille, objectif « Cette étude… », contribution). La première version se terminait sur le plan de l'article, ce que la consigne exclut : elle se termine maintenant sur la contribution. Chaque mouvement est repéré par un commentaire dans le source.

Étape	Statut	Ce qui a été fait, et pourquoi cette forme
5. Revue	Fait, à finir	Revue *narrative*, choisie parmi les 13 types de la page « revues de littérature » du site ; sa règle « anti-catalogue » a conduit à réécrire trois sous-sections pour que chaque paragraphe s'ouvre sur un constat. Le type narratif convient parce que le champ est récent (surtout des préprints de 2025–2026) et que le but est de situer la lacune, pas d'estimer un effet moyen. Équation OpenAlex en trois versions avec mesure de précision, boule de neige, vérification des références. Sélection finale déléguée à Claude (D23) : corpus de 65 articles, dont 38 cités dans l'article, par trois règles écrites et rejouables (`scripts/selection_corpus.py`).
6. Cadre, modèle, hypothèses	Fait	Refait une fois après la lecture de la trame (section 5, D13 et D14). NotebookLM non utilisé : Claude Code a lu les PDF en accès libre directement, et la vérification qui comptait (la théorie est-elle vraiment mobilisée dans les articles ?) s'est faite dans les textes.
7. Données	Fait, adapté	Kaggle à la place de Colab (D2). Fiche données remplie (`fiche_donnees.md`). Le principe de la trame est respecté : l'IA écrit le programme, la plateforme l'exécute, je vérifie le résultat. Données fictives produites pour tester la chaîne (point 7.6 de la trame), déclarées section 6.
8. Analyse qualitative	Non applicable ici	L'article est quantitatif. Le mémoire prévoit une analyse qualitative des échecs (volet C : 300 trajectoires, dont 100 annotées à la main). La lecture des trajectoires de mise au point a quand même été décisive : c'est elle qui a révélé le bogue de A3 (difficultés, section 8).
9. Dataviz	Fait	Deux figures produites par programme (`analysis/analyse_mini.py`), avec tableau de contrôle imprimé à chaque exécution et les cinq contrôles de la trame (section 6).
10. Discussion	Fait	Les cinq mouvements de la trame, réécrits sur les vrais résultats, puis relus avec le prompt « rapporteur » de la trame (six corrections).
11. Abstract	Fait	Réécrit sur les vrais résultats selon la page du site : un paragraphe continu d'environ 200 mots, contexte, faille, résultat majeur, résultats-clés chiffrés au passé, portée ; sans citation, abréviations définies, six mots-clés absents du titre. Version anglaise écrite pour elle-même, pas traduite mot à mot. Les chiffres viennent des macros générées : ils ne peuvent pas diverger du tableau.
12. LaTeX	Fait, adapté	Écrit directement en LaTeX : il n'y avait ni texte Word à convertir ni gabarit de cours. Le préambule est donc le mien, avec les éléments de la trame (TikZ pour les schémas, `natbib`, macro `\aremplir`). Bibliographie de 46 références, vérifiées d'un seul tenant le 9 novembre : zéro rouge (D18). Les trois fichiers de rendu sont produits par `scripts/rendu.sh` sous les noms demandés. L'import dans Overleaf est facultatif (D21).

3 Les outils utilisés

Étape	Outil	Ce que je lui ai demandé	Ce que j'ai gardé, refait ou vérifié
3	Consensus	Ma question en version fermée	Gardé comme indice d'un biais de publication : les 10 articles sont favorables au RL. Pas de répartition à rapporter, l'outil ne donnant pas de Consensus Meter.
5	Claude Code, Hugging Face Papers, API arXiv	Premier corpus thématique	91 articles en 9 thèmes. Recoupés automatiquement avec l'API arXiv (titre, premier auteur, date : 0 écart). Corpus gardé, mais repris ensuite avec OpenAlex parce que la trame demande une équation.
5.2	Claude + OpenAlex	Équation par blocs, précision, boule de neige, vérification des références	Équation 1 abandonnée (précision 7/20). Équation 3 retenue (environ 15/20). Rappel mesuré : 1 témoin sur 5 seulement. 9 références citaient un préprint au lieu de la version publiée : corrigées.
5.2	Claude + OpenAlex	Tri des 116 titres, puis des 58 doutes sur résumé	Première passe sur titres : 4 inclus, 58 doutes. Seconde passe sur résumés : 11 inclus de plus, 44 exclus avec motif. Décision finale déléguée à Claude (D23).

Étape	Outil	Ce que je lui ai demandé	Ce que j'ai gardé, refait ou vérifié
5	Recherche sémantique (Claude)	Ce que l'équation aurait manqué	A trouvé Zhao et al. (2026), qui m'a obligé à préciser la lacune (D13).
6	Claude Code, OpenAlex (texte intégral), PDF	Cadre, modèle, hypothèses, schémas TikZ	Première version (Stigler, Simon) refaite après contrôle dans les textes. Je n'ai pas réécrit le texte moi-même ; j'ai demandé la reprise et validé les choix.
7	Claude Code, Kaggle (GPU T4), vLLM	Code des six systèmes, script de run avec reprise, notebooks	Bogue de A3 trouvé à la lecture des trajectoires, pas par les tests. Prompts de A2 et A3 corrigés en mise au point (D8). J'ai fixé le protocole et validé chaque lancement ; je n'ai pas réécrit le code.
7	Claude Code	Données fictives au format exact des vrais fichiers	Générateur gardé et documenté. Chaque ligne porte `"fictif": true`.
9	Claude Code, matplotlib	Figures, tableaux, tests des hypothèses	Programme gardé. Figures relues en image. Tableau de contrôle vérifié (D15).
10, 11	Claude Code	Discussion et résumé, d'abord sur les données fictives, puis sur les vrais résultats ; relecture « rapporteur »	Version fictive jetée en entier. Version réelle relue avec le prompt de la trame : six corrections, surtout des affirmations causales trop fortes.
12	Claude Code, `tectonic`	Mise en page, schéma du modèle complet et du protocole	Pages relues en image après chaque compilation. Deux erreurs de compilation corrigées (difficultés).

4 Contrôle de conformité à la trame

Le 9 novembre, j'ai fait relire l'article exigence par exigence contre la trame et les trois pages du site auxquelles elle renvoie (introduction, abstract, types de revue). Ce tableau dit où chaque exigence est satisfaite, et ce qui manque encore.

Exigence	Où dans l'article	Statut
Article de l'introduction à la discussion, avec abstract (p. 3)	Sections 1 à 8, résumé et abstract	Fait
Références vérifiées dans OpenAlex (p. 3, 5.2-10, 12.4)	46 sur 46, annexe A ligne 17	Fait, zéro rouge
Méthodologie : OpenAlex via un agent IA, dates et équations (5.1)	Section 2.1 et annexe A (OQL complet)	Fait
Carnet des requêtes en annexe méthodologique (5.2)	Annexe A	Fait
Introduction en entonnoir, 5 mouvements, finit sur la contribution (4)	Section 1, mouvements commentés dans le source	Fait
Revue choisie et justifiée ; pas de catalogue (5.3)	Section 2.1 (revue narrative) ; 2.3 et 2.4 réécrites	Fait
Tri et compte rendu de sélection (5.2-9)	Annexe A, tableau généré par le script	Fait : 70 articles (65 au tri, plus 5 cités après la recherche du 12 novembre) ; tri délégué à Claude (D23)
Cadre : une théorie, deux au plus ; mobilisée dans les articles (6.1)	Section 3, figure 1 ; InForage	Fait ; à valider par la direction
Modèle : 3 à 5 variables, tableau théorie → modèle (6.2)	Tableau 2 et figure 2 (5 variables testées)	Fait
Une flèche, une hypothèse, chacune justifiée et testable (6.3)	Section 4.2 et tableau 3	Fait
Section Données depuis la fiche données (7.8)	Section 5.2 et annexe C	Fait
Données fabriquées déclarées, avec leur programme (7.6)	Encadrés, filigrane, exposant ; annexe C	Fait
Figure : légende normalisée, tableau de contrôle, 5 contrôles (9.4–9.6)	Figures 4 à 10, arbre TikZ ; contrôles en section 6	Fait

Exigence	Où dans l'article	Statut
Commentaire de figure avec limite et mise en garde causale (9.6)	Section 6.1	Fait
Discussion en cinq mouvements, sans répéter les chiffres (10.1–10.2)	Section 7	Fait, sur les vrais résultats
Implications « qui fait quoi », pas génériques (10.2)	Section 7.4, trois recommandations ciblées	Fait
Limites scientifiques, pas des alibis (10.2)	Section 7.5, dont la puissance	Fait
Abstract en 5 mouvements, environ 200 mots, mots-clés (11)	Résumé et abstract	Fait
PDF et source Overleaf nommés `NOM_Prenom_…` (12.4)	`rendu/`	Fait. Import dans Overleaf facultatif (voir D21)
Carnet : outils, difficultés, étonnement, approfondir (p. 3)	Ce document	Fait
Plugin de problématique : fiche de synthèse (3)	Carnet, section 14	Fait, avec Claude
Open Knowledge Maps (3.3), NotebookLM (6.4)	—	Non faits : outils en navigateur, à faire par moi
Relecture de la discussion par une IA « rapporteur » (10.3)	Carnet, section dédiée	Fait sur les vrais résultats ; six corrections

5 Registre des décisions de méthode

Chaque décision est donnée avec les options écartées, la raison du choix, la trace qui permet de la vérifier, et son coût pour l'interprétation. Les décisions qui touchent au protocole ont toutes été prises *avant* de voir la moindre question d'évaluation.

Cadrage

D1. Question et hypothèses H1 à H4 [moi]

— *Options écartées.* Une reproduction de Search-R1 ; une étude de l'entraînement seul.
— *Pourquoi.* Ce qui m'intéresse est la *décision* de chercher, et elle ne se juge qu'en comparant l'agent entraîné à des règles fixes placées dans les mêmes conditions. Un résultat négatif est acceptable dès le départ : le projet est construit pour qu'une absence d'effet soit interprétable.
— *Trace.* `CLAUDE.md`, section « Sujet du mémoire ».
— *Ce que ça coûte.* Les scores absolus ne seront pas comparables à ceux de l'article de Search-R1 : seule la comparaison relative compte, et l'article le dit.

D2. Kaggle plutôt que Google Colab [moi]

— *Options écartées.* Colab gratuit (proposé par la trame) ; une API payante.
— *Pourquoi.* Un modèle de 3 milliards de paramètres servi par vLLM demande un GPU pendant plusieurs heures. Kaggle donne environ 30 h de GPU par semaine en sessions de 9 à 12 h, et son client en ligne de commande permet de lancer un run et de récupérer les fichiers sans copier-coller. Le budget de 0 € exclut les API.
— *Trace.* `notebooks/kaggle_mini_experience.ipynb` ; test de fumée réussi le 3 novembre (version 6).
— *Ce que ça coûte.* Deux contraintes techniques découvertes en route : JAX (importé par `bm25s`) réservait la mémoire du GPU, d'où `JAX_PLATFORMS=cpu` ; vLLM doit démarrer en mode `spawn`.

D3. Corpus réduit à un million de passages, retriever E5 [IA] accepté, à valider par la direction du mémoire

— *Options écartées.* Le corpus complet (Wikipédia 2018, environ 132 Go avec son index) ; 100 000 passages avec BM25.
— *Pourquoi.* Le corpus complet ne tient pas dans les 20 Go de Kaggle. Entre les sous-corpus disponibles, j'ai *mesuré* la part des questions dont la réponse figure dans les trois premiers passages : avec BM25 sur 100 000 passages, de 3 à 12 % selon le jeu, ce qui rendait toute comparaison ininterprétable ; avec E5 sur un million, 25 % pour NQ et 44 % pour TriviaQA. E5 est en outre le retriever avec lequel Search-R1 a

été entraîné : l'agent n'est pas pénalisé par un outil inconnu. L'index a été contrôlé (similarité minimale de 0,9997 sur 50 passages).
— *Trace.* `scripts/measure_coverage.py` ; `results/coverage_*.jsonl` (non versionnés, régénérables).
— *Ce que ça coûte.* Le plafond de précision des systèmes qui cherchent est bas. C'est la première limite de l'article.

D4. NQ (vu) et TriviaQA (non vu), pas HotpotQA et Bamboogle [IA] accepté

— *Options écartées.* Le plan initial de l'article : HotpotQA (vu) et Bamboogle (non vu), deux jeux multi-étapes.
— *Pourquoi.* Même mesure de couverture : 17 % pour HotpotQA et 10 % pour Bamboogle. Avec si peu de réponses accessibles, une différence entre systèmes refléterait surtout le hasard du corpus. NQ et TriviaQA gardent le contraste vu / non vu dont HA2 a besoin.
— *Trace.* `configs/mini_experience.yaml`, commentaire en tête.
— *Ce que ça coûte.* Les questions multi-étapes, où chercher plusieurs fois devrait le plus compter, sortent de l'article. Elles restent dans le mémoire.

D5. 100 questions par jeu, une graine (42) [IA] accepté

— *Options écartées.* 500 questions par jeu, comme prévu dans le mémoire.
— *Pourquoi.* Six systèmes, deux jeux : 1 200 trajectoires. C'est ce qu'une session Kaggle permet de faire tourner avec une marge pour relancer un run coupé.
— *Trace.* `scripts/run_volet_a.py` (`EVAL_N = 100`).
— *Ce que ça coûte.* Des intervalles d'environ ±10 points : seuls des écarts importants seront détectables. Le premier rendu sur données fictives le montre concrètement (étonnement n° 7).

Systèmes

D6. Modèle Instruct pour A0 à A3, modèle de base pour A4 et A5 [IA] accepté, sans objection de ma part

— *Options écartées.* Le modèle de base partout ; les points de contrôle Search-R1 de la variante `-it-` partout.
— *Pourquoi.* Découvert en lisant le `config.json` des points de contrôle : A4 et A5 partent de Qwen2.5-3B, le modèle de base. Un harnais par prompt (ReAct, IRCoT) demande un modèle qui suit des consignes, donc la version Instruct. Les points de contrôle A4 et A5 sont ceux qui sont décrits dans l'article de Search-R1.
— *Trace.* Carnet du 3 novembre ; tableau 4 et limites de l'article.
— *Ce que ça coûte.* L'écart mesuré mélange la règle de recherche et le modèle. C'est dit dans l'article, et la variante `-it-` permettra de le réduire dans le mémoire.

D7. Mêmes conditions pour tous les systèmes [moi]

— *Options écartées.* Laisser chaque système dans sa configuration d'origine.
— *Pourquoi.* C'est le cœur de la question : mêmes questions, même corpus, même retriever, trois passages, au plus quatre recherches, décodage glouton. Sans cela, on retombe sur les comparaisons que l'article critique.
— *Trace.* `configs/mini_experience.yaml` ; figure 3 de l'article.
— *Ce que ça coûte.* Aucun, sinon que les harnais tournent dans des conditions qui ne sont pas toujours celles de leur article d'origine.

D8. Prompts de A2 et A3 corrigés après la mise au point [IA] proposé, [moi] validé

— *Options écartées.* Garder les premiers prompts ; corriger après avoir vu les résultats d'évaluation.
— *Pourquoi.* La mise au point (10 questions par jeu, graine 7) a montré que A2 répétait ses requêtes et que A3 s'abstenait. Un harnais mal réglé aurait gonflé l'avantage du RL : le corriger rend la comparaison plus dure pour mon hypothèse, pas plus facile. La correction a eu lieu *avant* toute question d'évaluation, et les scores de la mise au point n'ont pas guidé les choix.
— *Trace.* Commit `7ba2f95` ; trajectoires d'avant correction gardées dans `results/dev/prompts_v1/`.
— *Ce que ça coûte.* Les prompts restent les miens : d'autres prompts donneraient d'autres scores (limite de l'article). Le run de contrôle après correction n'a pas encore été fait.

D9. Questions de mise au point disjointes des questions d'évaluation [IA]

— *Options écartées.* Supposer qu'une autre graine donne d'autres questions.
— *Pourquoi.* Vérifié, c'était faux : la graine 7 reprenait 3 questions d'évaluation sur 110 pour NQ et 2 pour TriviaQA. Régler un prompt sur une question d'évaluation, même une seule, est une fuite.

— *Trace.* `select_questions` dans `scripts/run_volet_a.py` ; test associé.
— *Ce que ça coûte.* Aucun.

D10. Critère du test de fumée : « la chaîne fonctionne » [moi]

— *Options écartées.* Exiger 18 réponses sur 20.
— *Pourquoi.* Le nombre de réponses variait entre deux exécutions (18 puis 17) à cause de passages ex aequo, et ce taux est une mesure à rapporter, pas un critère de bon fonctionnement. Les ex aequo sont désormais départagés par l'indice du passage, ce qui rend la recherche reproductible d'une machine à l'autre (65 recherches Kaggle reproduites à l'identique sur le Mac).
— *Trace.* `scripts/smoke_test.py` ; `CLAUDE.md`.
— *Ce que ça coûte.* La répétabilité de la génération elle-même n'est pas encore testée.

Analyse

D11. Règles de décision écrites avant le run, correction de Holm [IA] proposé, [moi] validé

— *Options écartées.* Décider après coup de ce qui compte comme un effet.
— *Pourquoi.* Choisir le test après avoir vu les chiffres, c'est pouvoir trouver un effet n'importe où. HA1 compte six comparaisons (deux agents contre trois harnais) : sans correction, le risque d'au moins un faux positif peut atteindre 26 % ($1 - 0{,}95^6$). Les verdicts sont calculés par le programme, pas rédigés à la main.
— *Trace.* Tableau 3 de l'article ; fonction `holm` et son test dans `tests/test_analyse.py`.
— *Ce que ça coûte.* Une puissance plus faible : la correction rend les écarts modestes encore plus difficiles à déclarer significatifs.

D12. Revue narrative [IA] accepté

— *Options écartées.* Revue systématique ou de portée.
— *Pourquoi.* Le champ est jeune, fait surtout de préprints, et le but de la revue est de montrer qu'une comparaison contrôlée RL contre harnais manque. Une revue narrative suffit à cela, à condition de dire comment le corpus a été construit : l'article donne l'équation, les volumes et le rappel.
— *Trace.* Section 2.1 de l'article ; `docs/litterature/journal_requetes_*.md`.
— *Ce que ça coûte.* Pas de prétention à l'exhaustivité : l'article écrit « nous n'avons pas repéré », jamais « il n'existe pas ».

D13. Cadre : le fourragement de l'information (Pirolli et Card), avec Stigler [IA] proposé, [moi] demandé la reprise

— *Options écartées.* Première version : l'économie de l'information de Stigler et de Simon.
— *Pourquoi.* La trame demande si la théorie est mobilisée dans les articles retenus. Pour Stigler et Simon, non. Une recherche en texte intégral (58 résultats, 5 PDF contrôlés) a montré que le fourragement n'est vraiment mobilisé que par InForage. Simon a été retiré : la trame conseille une théorie, deux au plus. La lacune a aussi été précisée après la découverte de Zhao et al. (2026), qui comparent des méthodes de RL entre elles, pas le RL aux harnais.
— *Trace.* Carnet du 3 novembre ; section 3 de l'article.
— *Ce que ça coûte.* Je n'ai pas eu accès au texte de Pirolli et Card : sa présentation passe par InForage, et l'article le dit. Le transfert d'une théorie humaine à un modèle de langage est une analogie.

D14. HA3 coupée en HA3a et HA3b [IA]

— *Options écartées.* Garder une hypothèse unique sur le mécanisme.
— *Pourquoi.* HA3 portait sur deux flèches à la fois, contre la règle « une flèche, une hypothèse » de la trame. Séparer l'effet (plus de recherches) de sa modération (même quand le modèle sait déjà) rend chacune testable par une colonne précise.
— *Trace.* Figure 2 et tableau 3 de l'article.
— *Ce que ça coûte.* Une hypothèse de plus, donc un test de plus.

D15. Un premier rendu sur données fictives [moi] demandé, [IA] réalisé

— *Options écartées.* Attendre les vrais runs ; laisser les sections vides.
— *Pourquoi.* Avoir un article complet tôt permet de tester toute la chaîne (fichiers, tests, tableaux, figures, compilation) avant de dépenser du quota GPU, et de voir la forme finale. La trame autorise ce seul usage des données fabriquées : « tester votre programme avant d'avoir les vraies données » (point 7.6).
— *Trace.* `analysis/donnees_fictives.py` ; section 6.

— *Ce que ça coûte.* Le risque est de s'attacher à une histoire écrite d'avance. Garde-fous : les paramètres n'ont pas été réglés pour obtenir un verdict, les verdicts sortent du programme, et tout le texte des résultats, de la discussion et de la conclusion est déclaré « à réécrire ».

D16. Écrire directement en LaTeX, sans gabarit de cours [moi]

— *Options écartées.* Rédiger dans Word puis convertir, comme le prévoit l'étape 12.
— *Pourquoi.* Il n'y a pas de cours, donc pas de gabarit. Écrire directement en LaTeX évite une conversion qui peut perdre ou réécrire du texte, et permet d'inclure tableaux et figures générés par le code : quand les vrais résultats arriveront, une commande les remplacera, sans recopie à la main.
— *Trace.* `docs/article/main.tex` ; `docs/article/genere/`.
— *Ce que ça coûte.* La forme suit la trame (TikZ, natbib, macro de champs à remplir) mais pas un modèle imposé.

D17. Une analyse de puissance avant les runs [IA] proposé, [moi] accepté

— *Options écartées.* Lancer les runs et interpréter après coup l'absence d'effet.
— *Pourquoi.* Le premier rendu a montré qu'un écart réel de 9 points pouvait passer inaperçu (étonnement n° 7). Une simulation dit, avant de dépenser du GPU, quels écarts l'expérience peut voir : avec 200 questions et la correction de Holm, un écart de 10 points n'est détecté que dans 54 % des cas ; avec 500 questions par jeu, dans 96 %. Cela fixe ce que l'article a le droit de conclure.
— *Trace.* `analysis/puissance.py` ; tableau 5 de l'article.
— *Ce que ça coûte.* La simulation repose sur des hypothèses (EM de référence 25 %, corrélation entre systèmes) : la puissance réelle peut différer. Elles sont écrites dans l'article.

D18. Passer les références à leur version publiée [IA]

— *Options écartées.* Garder les préprints arXiv cités au départ.
— *Pourquoi.* La trame demande des références vérifiées, et une version publiée a été relue par des pairs. OpenAlex signalait une version publiée pour six préprints (FlashRAG, Adaptive-RAG, Active RAG, Mallen et al., InForage, Zhang et al.) ; elles ont été adoptées avec les DOI renvoyés par OpenAlex.
— *Trace.* Annexe A, ligne 17 ; `journal_requetes_complement.md`, ligne 17.
— *Ce que ça coûte.* Aucun, sinon que les années changent parfois (FlashRAG : 2024 en préprint, 2025 publié).

D19. Un script unique pour tout relancer [IA]

— *Options écartées.* Relancer chaque étape à la main.
— *Pourquoi.* Données, analyse, puissance, compilation et dossier de rendu se relancent en une commande (`scripts/rendu.sh`). C'est le « test final » de la trame (7.8) appliqué à tout le rendu : n'importe qui peut obtenir les mêmes PDF à partir du dépôt. Avec les vrais runs, une variable suffit à changer de source de données.
— *Trace.* `scripts/rendu.sh`.
— *Ce que ça coûte.* Le texte des résultats ne se régénère pas : il devra être réécrit à la main.

D20. Geler le prompt de A3 malgré ses abstentions [IA] proposé

— *Options écartées.* Corriger le prompt une deuxième fois et relancer un contrôle.
— *Pourquoi.* Le run de contrôle (graine 7, 10 questions par jeu, commit `fcef699`) confirme les corrections : A2 répond 20 fois sur 20 sans répéter de requête ; A3 fait de nouveau plusieurs recherches (3,4 par question). Mais A3 s'abstient encore 3 fois sur 20 (« Not provided in the given documents ») malgré la consigne « always give an answer », et une fois reprend la tour Eiffel de l'exemple. Une deuxième correction ouvrirait un réglage sans fin, qui finirait par se faire sur des scores ; une abstention compte comme une erreur, donc le biais joue contre A3, pas pour lui.
— *Trace.* Sortie du kernel Kaggle, version 3 ; commit `07c1fbb`.
— *Ce que ça coûte.* A3 est probablement sous-estimé. Le taux d'abstention de A3 sera rapporté avec les résultats.

D21. Overleaf facultatif [moi]

— *Options écartées.* Importer l'article dans Overleaf comme le prévoit l'étape 12.
— *Pourquoi.* La trame passe par Overleaf parce qu'elle suppose un étudiant sans LaTeX sur sa machine. L'article est déjà en LaTeX et se compile en local ; le zip demandé (source) est produit par `scripts/rendu.sh` et contient exactement ce qu'Overleaf ferait télécharger. Il a été compilé seul dans un dossier vide.
— *Trace.* `rendu/PROUX_Valentin_source.zip`.
— *Ce que ça coûte.* La compilation locale utilise XeTeX ; Overleaf utilise pdfLaTeX par défaut. Le préambule est écrit pour les deux, mais seul un import une fois avant le rendu le vérifiera.

D22. Une analyse exploratoire, déclarée comme telle [IA] proposé, [moi] accepté

— *Options écartées.* Ne rapporter que les quatre tests prévus ; ou présenter la nouvelle analyse comme si elle avait été prévue.
— *Pourquoi.* La lecture des vrais résultats a montré un fait que le plan n'anticipait pas : sur NQ, les trois harnais font moins bien que le modèle seul. Compter les questions « connues » (A0 juste) perdues après recherche l'explique : 18 à 24 sur 44 pour les harnais, 6 et 10 pour les agents. Cette analyse est utile, mais elle a été choisie après avoir vu les données : l'article la présente comme exploratoire, sans test, et ne lui fait porter aucun verdict.
— *Trace.* Section 6.2 de l'article, paragraphe « Analyse exploratoire » ; valeurs générées par `analysis/analyse_mini.py`.
— *Ce que ça coûte.* Elle ne prouve rien à elle seule ; elle oriente le mémoire (oracle de connaissance, H4).

D23. Sélection finale du corpus déléguée à Claude [moi] délégué, [IA] réalisé

— *Options écartées.* Trier moi-même les candidats, comme la trame le demande (« C'est vous qui décidez de chaque inclusion »).
— *Pourquoi.* J'ai choisi de déléguer cette décision, avec une cible de 30 à 70 articles. Pour qu'elle reste contrôlable, Claude l'a écrite sous forme de trois règles dans un script : R1, les articles « essentiels » du corpus de départ sur les thèmes au cœur de l'article (agents entraînés, harnais, décision de chercher, retriever, bruit), plus les « essentiels » et « utiles » sur le coût ; R2, tout article cité dans la revue ; R3, les nouveaux candidats qui portent sur la décision de chercher, le coût, la comparaison à un harnais, le retriever ou l'usage de l'information trouvée, les méthodes d'entraînement pures étant exclues (E1). Résultat : 65 articles, dont 38 cités ; le 12 novembre, cinq références sur la question « fiabiliser ou élargir » ont été citées dans la revue, et la règle R2 les a ajoutées (70 articles, dont 43 cités). Les effectifs du compte rendu sont calculés par le script : une première version écrite à la main contenait des chiffres faux, corrigés avant publication.
— *Trace.* `scripts/selection_corpus.py`, `docs/litterature/corpus_final.csv`, annexe A de l'article.
— *Ce que ça coûte.* Je n'ai pas fait moi-même le tri que la trame attend de l'étudiant ; je peux en revanche défendre chaque règle, et les rejouer. Les décisions sur les doutes de l'équation 3 et des candidats reposent sur le résumé ou, à défaut, sur le titre : aucun texte n'a été lu en entier pour trier.

D24. Des analyses approfondies, exploratoires [moi] demandé, [IA] réalisé

— *Options écartées.* S'en tenir aux moyennes et aux quatre tests prévus.
— *Pourquoi.* J'ai trouvé l'article trop mince sur l'analyse. Les trajectoires contiennent les passages lus et les requêtes : on peut donc mesurer où se joue l'avantage. Six analyses ont été ajoutées (section 6.3 de l'article) : gains et pertes face au modèle seul, « trouver ou lire », décomposition contrefactuelle de l'écart (trouver 2,1 points, lire 8,0, répondre sans appui 3,5, avec intervalles bootstrap), analyse des requêtes, typologie automatique des erreurs, matrice des quinze comparaisons, et un arbre de décision en TikZ. Toutes ont été choisies après avoir vu les résultats : l'article les déclare exploratoires et ne leur fait porter aucun verdict.
— *Trace.* `analysis/analyse_approfondie.py` ; figures 6 à 10 de l'article.
— *Ce que ça coûte.* « Réponse présente dans les passages » est une estimation par chaîne de caractères ; la typologie des erreurs est automatique, pas annotée à la main (ce sera le volet C du mémoire).

D25. Des analyses de robustesse, et une interprétation corrigée [moi] demandé, [IA] réalisé

— *Options écartées.* S'en tenir à la décomposition additive de D24 et à son interprétation (« les agents lisent mieux »).
— *Pourquoi.* J'ai demandé des analyses plus poussées. Chacune répond à une objection : une régression logistique avec erreurs-types groupées par question (l'écart vient-il de questions plus faciles ?), la courbe de gain des recherches successives (le rendement décroissant de la théorie), une analyse de sensibilité à la métrique (correspondance souple, F1), des tailles d'effet (odds ratios de McNemar), la décomposition jeu par jeu et la complémentarité des systèmes. La régression a nuancé l'interprétation : l'interaction entre famille et présence de la réponse est nulle (OR 1,03), donc les agents ne « lisent » pas mieux au sens étroit ; ils répondent mieux à partir de l'information disponible. La discussion a été corrigée en ce sens. Un schéma TikZ de la boucle d'entraînement de Search-R1 a été ajouté à la méthode.
— *Trace.* `analysis/analyse_avancee.py` ; section 6.4, figures 3 et 11, tableaux 10 à 12 de l'article.
— *Ce que ça coûte.* Toujours exploratoire ; la régression suppose un effet additif sur l'échelle logistique, et la « réponse présente » reste une estimation par chaîne de caractères.

D26. Formaliser le cadre par la récompense [moi] décidé, sur proposition de [IA]

— *Options écartées.* Garder le cadre théorique sous forme d'analogie (« l'agent est un fourrageur ») ; ou

placer les mathématiques dans l'état de l'art.
— *Pourquoi.* Écrire la récompense de Search-R1, $r = \mathrm{EM}$, et celle qu'impliquerait un coût, $r = \mathrm{EM} - c \cdot n_{\mathrm{rech}}$, transforme l'analogie en mécanisme vérifiable : le coût de la théorie du fourragement est le c de la récompense, que Search-R1 fixe à zéro. Les hypothèses HA3a et HA3b découlent alors d'une équation. Les équations vont dans le cadre théorique, chacune suivie d'une phrase « Lecture : » pour un lecteur non spécialiste ; les dérivations (gradient de politique, avantage, PPO, GRPO, masquage des passages) vont en annexe D ; l'état de l'art n'en reçoit qu'une phrase, pour ne pas casser son fil.
— *Trace.* Section 3 (équations 1 et 2) et annexe D de l'article.
— *Ce que ça coûte.* La formalisation décrit l'entraînement d'après l'article de Search-R1 ; nous ne l'avons pas reproduit.

D27. Partie 2 : arrêter la génération à la balise de réponse [IA] constaté et corrigé, [moi] informé puis accord (« oui go »)

— *Options écartées.* Garder l'arrêt sur la seule balise de recherche, comme dans le pilote ; ou couper les trajectoires après coup, à l'analyse.
— *Pourquoi.* Au pilote v2, l'agent `it-em-ppo` continuait d'écrire après sa réponse et répétait `<answer>…</answer>` jusqu'à 1 024 jetons dans 42 % des trajectoires, ce qui divisait son débit par quatre. Le code officiel de Search-R1 coupe la sortie au premier `</answer>` : arrêter là est donc fidèle à l'entraînement, et non un réglage de notre part. Couper seulement à l'analyse aurait gardé le coût en calcul. Avant de corriger, le pilote a été rescoré hors ligne au premier `</answer>` : les tendances ne changent pas.
— *Trace.* `systems/searchr1.py` ; journal du 12 novembre ; plan, section « Mesures ».
— *Ce que ça coûte.* Le débit corrigé n'est pas encore mesuré : le budget de l'étude repose sur une estimation.

D28. Partie 2 : geler le plan avant le premier run principal [moi] décidé, [IA] rédigé

— *Options écartées.* Lancer l'étude, puis choisir les règles de décision au vu des courbes ; ou fixer N d'après la « puissance » simulée sur le pilote.
— *Pourquoi.* Les courbes pass@k laissent beaucoup de libertés (quels k, bande ponctuelle ou simultanée, quel sous-ensemble) : les choisir après coup permettrait de trouver un « élargissement » partout. Le plan v1.0 (`docs/partie2/plan_analyse.md`) a donc été commité avant la session 1, avec $N = 500$, $n = 32$, les règles de H1 et H2 et la correction de Holm. La puissance simulée sur le pilote valait 0 %, mais parce que le pilote ne montre aucun élargissement : ce chiffre ne dit rien de la taille utile. On a donc calculé l'écart minimal détectable à partir de l'écart-type observé : environ 4 points à $k = 32$ avec 500 questions, 3 avec 1 000, pour deux fois le coût.
— *Trace.* Plan v1.0 et précisions opératoires datées ; `analysis/confirmatoire_partie2.py`, testé sur données simulées.
— *Ce que ça coûte.* Les précisions (p-valeur de Holm, protocole de H3) ont été écrites pendant que la session 1 tournait, sans en avoir vu les résultats ; c'est vérifiable dans l'historique Git, pas autrement.

D29. Partie 2 : un sous-ensemble difficile, et un garde-fou de lecture [IA] proposé et écrit, délégation de [moi]

— *Options écartées.* Juger l'élargissement sur l'échantillon complet seulement.
— *Pourquoi.* En écrivant les tests, une simulation a montré qu'un agent qui ne fait que fiabiliser « gagne » des questions où le modèle de départ a peu de chances et les rate par hasard en 32 essais. Un gain à $k = n$ ne suffit donc pas. Le mot « élargissement » sans réserve ne sera employé que si le verdict tient aussi sur un sous-ensemble difficile, présélectionné sur des tirages indépendants (réutiliser les mêmes tirages fabriquerait un élargissement, ce qu'un autre test montre).
— *Trace.* Plan, précisions opératoires ; `tests/test_confirmatoire_partie2.py`, `tests/test_passk.py` ; sessions 3 et 4.
— *Ce que ça coûte.* Le sous-ensemble ne contient que les questions de ponts, environ 150 à 200 : sa puissance sera plus faible.

D30. Partie 2 : H3 par lecture croisée [IA] proposé et écrit, délégation de [moi]

— *Options écartées.* Reprendre la décomposition contrefactuelle de la partie 1 (trouver, lire, sans appui), fondée sur des indicateurs calculés après coup.
— *Pourquoi.* La partie 1 attribuait l'écart à la lecture par une décomposition additive, sans expérience. Ici, on peut la faire : chaque modèle lit les recherches de l'autre (requêtes et passages, raisonnement retiré dans les quatre cases), puis répond sans chercher. À chercheur fixé, l'écart entre lecteurs isole la lecture ; à lecteur fixé, l'écart entre chercheurs isole la recherche. C'est une manipulation, plus probante qu'une décomposition.

— *Trace.* `scripts/run_lecture.py`, `analysis/lecture_croisee.py`, session 5.
— *Ce que ça coûte.* Retirer le raisonnement du chercheur change la situation du lecteur ; c'est le même retrait dans les quatre cases, mais l'agent lisant ses propres recherches sans son raisonnement n'est plus tout à fait l'agent.

D31. Partie 2 : lancer deux sessions Kaggle en parallèle, pas trois [IA] décidé, délégation de [moi]

— *Options écartées.* Enchaîner les cinq sessions une à une ; ou les lancer toutes.
— *Pourquoi.* Les sessions 1 (ponts) et 2 (comparaisons) sont indépendantes et tournent ensemble depuis le 12 novembre au soir. La session 3 attend le débit mesuré de la session 1 : avec les estimations actuelles, trois sessions de front approcheraient le quota hebdomadaire (environ 30 h), et un dépassement pourrait couper un run en cours. Les sessions 4 et 5 dépendent des sorties des sessions 3 et 1.
— *Trace.* `scripts/genere_notebooks_partie2.py`, `kaggle/partie2_s*/`.
— *Ce que ça coûte.* Le quota restant de la semaine n'est pas lisible depuis la ligne de commande ; la marge est estimée.

D32. Partie 2 : appliquer le plan sans retouche, et séparer nettement l'exploratoire [IA] réalisé, délégation de [moi]

— *Options écartées.* Ajuster les règles après avoir vu des courbes « presque » significatives ; ou présenter l'analyse par difficulté comme un résultat.
— *Pourquoi.* Les verdicts des sessions 1 et 2 (« fiabilisation seule » pour les deux paires principales) sont ceux du script écrit et testé avant les données. Une erreur de notre code a été trouvée en lisant les sorties : le statut « budget épuisé » se déclenchait sur n'importe quelle balise de recherche ; elle est corrigée et signalée, et ne touche pas l'EM, donc aucun verdict. Les analyses écrites ensuite (gain par difficulté, causes des sorties sans réponse) sont placées dans une section « exploratoire » et un script à part. Pour l'analyse par difficulté, classer et mesurer sur les mêmes tirages aurait fabriqué une régression vers la moyenne : classement sur les tirages 0 à 15, mesure sur 16 à 31.
— *Trace.* `analysis/exploratoire_partie2.py` ; chapitre de la partie 2, sections 5 et 6 ; journal du 13 novembre.
— *Ce que ça coûte.* L'indice d'élargissement sur les questions difficiles (85 % contre 70 % jamais résolues) reste un indice : seule la session 4, sur un vivier séparé, peut le tester.

D33. Partie 2 : rapporter H3 telle que prévue, puis amender le protocole [IA] constaté et proposé, délégation de [moi]

— *Options écartées.* Remplacer le résultat prévu par celui de la variante ; ou abandonner H3.
— *Pourquoi.* La règle prévue donne « H3 non soutenue », mais la lecture des sorties montre pourquoi : sans son raisonnement, l'agent PPO veut chercher encore dans 95 % des lectures, et le protocole compte ces tentatives comme des échecs. Le résultat prévu est rapporté tel quel, avec ce constat, qui a sa valeur (la décision d'arrêter de chercher semble portée par le raisonnement écrit). Une variante « réponse forcée » a été ajoutée, datée et déclarée exploratoire dans le plan avant d'être lancée. Elle a coûté une heure de GPU. Une mesure indépendante, sans GPU, fondée sur les paragraphes utiles de HotpotQA, donne une lecture cohérente : le renforcement améliore surtout la recherche ; son gain de lecture n'apparaît que si l'agent répond.
— *Trace.* Plan, amendement du 13 novembre ; `scripts/run_lecture_forcee.py`, `analysis/recherche_partie2.py` ; chapitre de la partie 2.
— *Ce que ça coûte.* Forcer la réponse change la tâche : l'agent répond parfois alors qu'il « savait » ne pas avoir assez d'information. La variante mesure une capacité de lecture, pas le comportement naturel.

6 Données

Données réelles

— **Questions.** Natural Questions et TriviaQA dans le format FlashRAG (`RUC-NLPIR/FlashRAG_datasets`, split `test`), 100 questions par jeu tirées avec la graine 42.
— **Corpus.** `maknee/wiki-18-subsets`, fichier `wiki-18-1m.jsonl.gz` et index `e5_Flat-1m.index`. Jeu tiers sans fiche descriptive : l'alignement entre index et corpus a été vérifié.
— **Trajectoires.** Produites par ce projet sur Kaggle. Une ligne par question et par système. Mise au point (graine 7, 10 questions par jeu) : A0 à A3 le 3 novembre, puis contrôle de A2 et A3 après correction. Run d'évaluation le 9 novembre (version 4 du kernel, commit `07c1fbb`) : 1 200 trajectoires, 12 runs à code 0, aucune erreur au journal, mêmes questions pour les six systèmes, 1 h 12 de GPU. Fichiers dans `results/eval_v4/` (non versionné, comme toutes les données).

— **Nettoyage.** Aucun : pas de question retirée. Seul ajout, comme dans Search-R1 : un « ? » en fin de question s'il manque.
— **Licences.** À vérifier avant le rendu final (FlashRAG, sous-corpus, Qwen2.5, points de contrôle Search-R1).

Le détail est dans `docs/article/fiche_donnees.md`.

Données fictives (déclaration)

La trame est claire : des données fabriquées sont déclarées comme telles, avec le programme qui les produit ; les présenter comme réelles est une fraude.

— **Programme.** `analysis/donnees_fictives.py`, graine 2026. Il écrit 1 200 lignes dans `results/fictif/`, au format exact des vrais fichiers, chacune marquée `"fictif": true`.
— **Mécanisme.** Chaque question reçoit une « facilité » commune à tous les systèmes, ce qui rend les réponses corrélées d'un système à l'autre, comme dans la réalité. Chaque système a une probabilité de bonne réponse visée, choisie à la main, et une règle simple pour le nombre de recherches.
— **Ce qu'elles ne sont pas.** Une prédiction. Les valeurs sont arbitraires ; elles disent ce que j'ai mis dans le programme, rien sur les modèles.
— **Marquage dans l'article.** Le script d'analyse détecte le marqueur et fait apparaître : un filigrane sur toutes les pages, un encadré rouge en tête des sections concernées et en première page, et l'exposant « fictif » sur chaque verdict. Avec les vrais fichiers, ces marques disparaissent d'elles-mêmes, mais le texte devra être réécrit.

Contrôle des figures (étape 9.4 de la trame)

— **Les comptes tombent juste.** 100 lignes par système et par jeu, aucune écartée ; le script refuse de tourner si un fichier manque ou si les systèmes n'ont pas les mêmes questions.
— **Valeurs à la main.** Le tableau de contrôle imprimé par le script et le tableau 6 de l'article donnent les mêmes valeurs : ils viennent du même calcul.
— **Axes.** EM de 0 à 1 sur les deux figures, titres et unités en français. Pas de barres : des points avec leur intervalle, qui montrent l'incertitude au lieu de la cacher.
— **Rien n'a disparu.** Les six systèmes et les deux jeux sont présents.
— **Couleurs.** Gris pour la réponse directe, bleu pour les harnais, orange pour le RL : la couleur suit la famille de systèmes, et chaque point porte aussi son nom. Le bleu et l'orange sont les deux premières couleurs d'une palette de référence déjà validée pour les daltonismes ; je n'ai pas relancé le validateur moi-même.

7 Part de l'IA dans le travail

Domaine	Ce que l'IA a fait	Ce qui reste à moi
Question, hypothèses	Reformulations, découpage de HA3	Le sujet, H1 à H4, le choix d'accepter un résultat négatif
Bibliographie	Recherche, équations, tri proposé, vérification dans OpenAlex	Relire le tri (pas encore fait), lire les articles essentiels (pas encore fait)
Code	Tout le code : systèmes, boucle de recherche, statistiques, analyse, tests	Le protocole, la validation de chaque lancement, la lecture des sorties
Rédaction	Premier jet de toutes les sections	Relecture, choix de ce qui reste, réécriture des résultats après les runs
Vérification	Tests automatiques, rendu des pages en image, contrôle des références	Le jugement final sur ce qui est vrai

Je ne cache pas que l'IA a écrit l'essentiel du code et du texte. Ma façon de rester responsable a été de fixer les règles avant de voir les résultats, d'exiger que chaque chiffre vienne d'un fichier, et de faire relire les sorties (trajectoires, pages compilées) plutôt que de me fier aux statuts « réussi ». Cette façon de faire a déjà rattrapé deux erreurs de l'IA : un bogue que les tests ne voyaient pas, et une affirmation fausse sur la machine (difficultés, ci-dessous).

8 Mes difficultés

— **Faire tourner vLLM sur Kaggle** (3 novembre, environ 2 h 30 d'après les commits, de 9 h 14 à 11 h 44, six versions du notebook). JAX réservait la mémoire du GPU, vLLM devait démarrer en mode `spawn`, et les passages ex aequo de BM25 rendaient les runs non reproductibles. *Résolu.*
— **Accès aux bases bibliographiques.** Depuis l'environnement de l'IA, les API arXiv, Semantic Scholar et Crossref étaient bloquées (erreur 403 ou nom d'hôte introuvable). Contournement par Hugging Face Papers et le navigateur intégré, puis reprise complète avec le connecteur OpenAlex. *Résolu.*
— **Une équation précise qui ne trouve pas les bons articles.** Précision d'environ 75 % mais rappel d'un témoin sur cinq : trois témoins sont des harnais fixes, exclus par construction du bloc RL, et R1-Searcher n'emploie pas les mots de l'équation. *Compris, non corrigé* : les articles manquants viennent de la première collecte.
— **Équation non conservée.** 103 résultats le matin, 116 l'après-midi : l'équation exacte du matin n'ayant pas été gardée, l'écart ne s'explique pas. *Non résolu* ; l'OQL est maintenant noté à chaque fois.
— **Références « exactes » mais pas les bonnes.** 35 références sur 35 trouvées dans OpenAlex, dont 9 citaient le préprint alors qu'une version publiée existe. *Résolu.*
— **Un bogue invisible.** Le système A3 (IRCoT) ne faisait qu'une recherche par question alors que tous les tests passaient : le faux modèle des tests n'écrivait jamais tout son raisonnement d'un bloc, le vrai si. Trouvé en lisant les trajectoires. *Résolu*, avec un test ajouté.
— **Une affirmation fausse de l'IA.** Claude a affirmé qu'il n'y avait pas de LaTeX sur ma machine ; `tectonic` était installé. L'article n'a pas été recompilé ce jour-là. *Résolu* le 9 novembre.
— **Git et machine virtuelle.** Le dossier de travail de la littérature pointait vers une machine virtuelle absente du Mac ; un commit portant encore la mention de l'IA est apparu pendant la réécriture de l'historique, créé par une autre session. *Résolu.*
— **Compilation du premier rendu** (9 novembre). Deux erreurs : un nom de style TikZ (`out`) qui était déjà une clé réservée, et une commande (`\text`) sans son paquet. *Résolu* en lisant le message d'erreur complet, comme le conseille la trame.
— **Caractères manquants dans les PDF** (9 novembre). Les guillemets « » s'affichaient « ń ż », et « œ » et « € » manquaient, dans l'article comme dans le carnet. Cause : `tectonic` compile avec XeTeX, qui gère mal le codage de police prévu pour pdfLaTeX. Le préambule choisit maintenant le bon codage selon le moteur, pour fonctionner aussi sur Overleaf. *Résolu* ; trouvé seulement parce que les pages ont été relues en image.
— **Trois références « introuvables »** (9 novembre). La recherche par titre d'OpenAlex n'a pas trouvé trois références et en a apparié une quatrième à un autre article (R1-Searcher à R1-Searcher++). Les trois sont exactes par leur DOI arXiv. *Résolu* : les DOI sont maintenant dans la bibliographie, ce qui rend la vérification exacte.

9 Mon rapport d'étonnement

Chaque étonnement est un écart entre ce que j'attendais et ce qui s'est passé.

1. **La précision d'une équation.** *Attendu :* une équation large, aux bons mots, suffit. *Observé :* 7 articles pertinents sur 20 tirés au hasard.
2. **Précise n'est pas complète.** *Attendu :* une équation précise à 75 % est bonne. *Observé :* elle ne retrouve qu'un témoin sur cinq, et une requête en langage naturel a trouvé une étude clé qu'elle avait manquée.
3. **Les citations dépendent de l'outil.** *Attendu :* un nombre de citations est un fait. *Observé :* 14 citations de Search-R1 dans OpenAlex, plus de 1 600 selon Consensus.
4. **Une référence trouvée n'est pas une référence sûre.** *Attendu :* ce qui sort d'OpenAlex est fiable. *Observé :* SEM n'y existe que sous une copie Zenodo douteuse ; il a fallu retrouver la vraie notice arXiv.
5. **Une graine différente ne donne pas des questions différentes.** *Attendu :* graine 7 et graine 42, deux tirages disjoints. *Observé :* 3 questions communes sur 110 pour NQ.
6. **« Tous les tests passent » ne veut pas dire « ça marche ».** *Attendu :* A3 fonctionnait. *Observé :* il ne faisait jamais qu'une recherche, sans aucune erreur. Seule la lecture des sorties l'a montré.
7. **On ne retrouve même pas ce qu'on a mis.** *Attendu :* la trame prévient que des données fabriquées font « découvrir » ce qu'on y a écrit. *Observé :* j'avais donné au meilleur agent 9 points d'avance sur le RAG pour NQ ; avec 100 questions, l'échantillon n'en montre que 7, et aucune des six comparaisons n'est significative après correction. Avec cette taille d'échantillon, un vrai effet de cette taille peut passer inaperçu. C'est la leçon la plus utile du premier rendu : la taille de l'échantillon décide de ce que l'expérience peut voir.
8. **Des chiffres plausibles, mais faux.** *Attendu :* un compte rendu de sélection se rédige d'après les fichiers

de tri. *Observé :* la première version du tableau, rédigée par Claude, donnait 109 exclusions, 26 références de méthode et 27 non retenus ; le calcul par le script a donné d'autres nombres partout. Depuis, aucun effectif n'est saisi à la main.

9. **Une référence introuvable n'est pas forcément inventée.** *Attendu :* d'après l'exemple de la trame, « aucune correspondance » signale une référence fabriquée. *Observé :* trois références réelles, dont deux citées des dizaines de fois, n'étaient pas trouvées par leur titre, et une quatrième était appariée à un autre article de mêmes auteurs ; par le DOI, toutes étaient exactes. La vérification automatique dit où regarder, pas ce qu'il faut conclure.
10. **Les vraies données ont démenti le scénario fictif.** *Attendu :* les paramètres fictifs, choisis à la main, faisaient des agents entraînés des systèmes à peine meilleurs et surtout plus coûteux. *Observé :* ils gagnent de 10 à 17 points sur toutes les comparaisons, et les harnais font même moins bien que le modèle seul sur NQ. Le texte écrit sur le fictif était entièrement à jeter : c'est la meilleure preuve que les données fictives ne servent qu'à tester la chaîne.
11. **Chercher peut faire perdre ce que l'on savait.** *Attendu :* une recherche ajoute de l'information, au pire elle ne sert à rien. *Observé :* sur les 44 questions que le modèle résout seul, le RAG en perd 18 après avoir lu les passages ; à une question sur le half-pipe à ski, il répond la date d'entrée du snowboard aux Jeux.
12. **Les agents ne cherchent pas mieux, ils lisent mieux.** *Attendu :* un agent entraîné à chercher formule de meilleures requêtes. *Observé :* sa première requête trouve la réponse aussi souvent que celle d'un harnais (environ un tiers des questions), A5 recopie la question dans 90 % des cas, et une question sur quatre contient une requête répétée mot pour mot ; l'essentiel de l'écart (59 %) se joue une fois la réponse dans les passages.
13. **Deux analyses, deux lectures.** *Attendu :* la décomposition additive (59 % de l'écart à la « lecture ») prouvait que les agents lisent mieux les passages. *Observé :* une régression logistique montre que leur avantage relatif est le même que la réponse soit dans les passages ou non. Les deux chiffres sont justes ; ils ne répondent pas à la même question (points gagnés contre chances relatives). Une interprétation déjà écrite a dû être corrigée.
14. **Le résumé ne suffit pas.** *Attendu :* le résumé de Wu et al. parle « d'un modèle » qui fait 27,7 % de recherches évitables. *Observé :* le texte précise qu'il s'agit de Search-R1, l'un de mes systèmes.

10 Ce que j'aimerais approfondir

— **La puissance de l'expérience.** Combien de questions faut-il pour détecter un écart de 5 points avec un test de McNemar apparié ? L'étonnement n° 7 montre que 100 ne suffisent pas ; le générateur de données fictives permet de simuler la réponse avant de dépenser du GPU.
— **Le coût d'une recherche dans la récompense** (H3 du mémoire). C'est la suite logique du cadre : si l'agent cherche trop parce que rien ne lui coûte, une pénalité devrait le corriger. À tester avec un petit entraînement GRPO (volet B).
— **Le biais de publication des articles de méthode.** Les 10 articles de Consensus sont favorables au RL. Une comparaison contrôlée, avec un résultat négatif possible, est une façon d'y répondre.
— **Lire les textes.** Le statut de tous les articles « essentiels » est encore « non lu » ; relire les 58 « doutes » du tri de l'équation 3.

11 Relecture de la discussion par l'IA (étape 10.3)

J'ai fait relire la discussion avec le prompt de la trame : « Relis ma discussion comme un rapporteur exigeant. Signale chaque phrase qui répète les résultats sans les interpréter, chaque affirmation causale que mes données ne permettent pas et chaque implication managériale trop générale. Ne réécris pas ma discussion. » Limite : la relecture a été faite par la même IA que celle qui avait rédigé le premier jet.

Passage signalé	Type	Ce que j'ai changé
« le gain ne disparaît pas quand on contrôle ces différences »	Causalité trop forte	Le corpus, le retriever et le budget sont communs, mais pas les poids du modèle : la phrase le dit maintenant.
« un prompt qui l'invite à se servir des documents »	Inexact	Le prompt de A1 dit au contraire « otherwise rely on your own knowledge » : corrigé.

Passage signalé	Type	Ce que j'ai changé
« le renforcement a appris à l'agent à n'utiliser un passage que s'il aide »	Causalité non établie	Devenu une « lecture compatible avec nos données », suivie de « elles n'en établissent pas la cause ».
« sur la décision, le cadre se vérifie »	Interprétation partielle	ReAct ne renonce pas non plus à chercher sur les questions connues : la surrecherche n'est pas propre aux agents, qui cherchent seulement davantage.
« l'apprentissage améliore la seconde sans améliorer la première »	Causalité	Devenu « les agents se distinguent par la seconde » ; même correction dans le résumé, l'abstract et la conclusion.
« peut en attendre un gain net de précision »	Implication trop générale	Limitée à un corpus proche de Wikipédia et à des conditions comparables.

Aucune phrase ne répétait les chiffres sans les interpréter : le rappel des résultats est écrit sans chiffres, comme le demande l'étape 10.

12 Risques de l'IA et garde-fous

Chaque ligne associe un risque connu du travail avec l'IA à ce qui s'est réellement passé dans ce projet, et au garde-fou mis en place.

Risque	Ce qui s'est passé ici	Garde-fou
Référence inventée ou mal appariée	Aucune référence inventée ; mais une recherche par titre a apparié R1-Searcher à R1-Searcher++, et trois références réelles semblaient introuvables.	Vérification de toute la bibliographie dans OpenAlex, par DOI quand c'est possible (annexe A de l'article).
Résumé d'article déformé	Le résumé de Wu et al. parlait d'« un modèle » ; le texte précise qu'il s'agit de Search-R1.	Ce qui vient d'un résumé est signalé comme tel dans l'article.
Code qui « marche » mais faux	IRCoT ne faisait qu'une recherche, tous les tests au vert.	Lecture des trajectoires après chaque run ; test ajouté pour chaque bogue trouvé.
Affirmation fausse sur l'environnement	« Pas de LaTeX sur cette machine » : faux.	Vérifier par une commande avant de croire une affirmation.
Réglage sur les données d'évaluation	La graine de mise au point reprenait des questions d'évaluation.	Tirages disjoints vérifiés ; prompts gelés avant le run (D9, D20).
Choix des tests après coup	Risque seulement.	Règles de décision et code d'analyse commités avant le run d'évaluation.
Données fictives prises pour réelles	Risque seulement : les vrais runs ont été lancés pour remplacer les données fictives.	Marquage automatique (filigrane, encadrés, exposant) piloté par un drapeau dans les fichiers.
Rendu qui ne se compile pas ailleurs	Guillemets et ligatures cassés sous XeTeX.	Pages relues en image ; zip compilé seul dans un dossier vide.

13 Ressources consommées

Le budget est de 0 €. Ce tableau donne ce que le projet a consommé, quand c'est connu.

Poste	Consommation	Source
Argent	0 €	Aucun abonnement ni crédit d'API
GPU Kaggle, test de fumée	six versions, durées non relevées	Kernel `memoire-smoke-test`
GPU Kaggle, contrôle de A2 et A3	980 s (40 trajectoires)	Journal du kernel, version 3
GPU Kaggle, run d'évaluation	4 324 s, soit 1 h 12 (1 200 trajectoires)	Journal du kernel, version 4
Mesure de couverture E5	environ 21 min sur processeur	Kaggle, sans quota GPU
API OpenAlex	quelques centièmes de dollar sur l'allocation gratuite	Coût affiché par l'API (0,0001 $ pour les 58 résumés)

14 Fiche de problématique (étape 3)

La trame propose un plugin ChatGPT qui conduit l'étudiant jusqu'à une « fiche de synthèse finale » en dix rubriques. Je n'ai pas utilisé ChatGPT : la question existait déjà. J'ai appliqué la même méthode avec Claude le 9 novembre, à partir de ce que le projet avait déjà établi. Les rubriques suivent l'ordre du plugin ; les éléments marqués « à préciser » le sont faute d'information, comme le plugin le demande.

1. **Sujet délimité.** Les agents de recherche fondés sur des modèles de langage : comment ils décident d'interroger un moteur de recherche pour répondre à des questions factuelles. Délimitation : petits modèles (3 milliards de paramètres), questions-réponses en anglais, corpus Wikipédia de 2018, calcul gratuit.
2. **Débat de départ.** Les méthodes d'apprentissage par renforcement (Search-R1 et ses suites) annoncent de nets gains sur les systèmes à règle fixe, mais ces gains sont mesurés par leurs auteurs, contre des lignes de base qu'ils choisissent.
3. **Tension.** Le gain vient-il de l'apprentissage de la *décision* de chercher, ou d'autres différences (modèle, prompt, retriever, jeux vus à l'entraînement) ? Et l'agent apprend-il à s'arrêter de chercher, alors que rien dans sa récompense ne lui coûte ?
4. **Problématique.** Les agents entraînés par renforcement promettent de remplacer des règles écrites à la main par une décision apprise. Si c'est vrai, ils devraient mieux répartir leurs recherches qu'une règle fixe placée dans les mêmes conditions, y compris sur des questions qu'ils n'ont pas vues. Mais leur récompense ne fait payer aucune recherche : la théorie du fourragement de l'information prédit alors qu'ils chercheront même quand le gain attendu est nul. Comparer agents et harnais à conditions identiques permet de séparer l'effet de l'apprentissage sur la précision de son effet sur le coût.
5. **Question.** À corpus et questions identiques, un agent de recherche entraîné par renforcement décide-t-il mieux quand et quoi chercher qu'un harnais fixe, et à quel coût ?
6. **Intérêt.** *Étayé* : la surrecherche est documentée (Wu et al., 2025 ; Tang et al., 2026), et les comparaisons contrôlées manquent aussi pour les méthodes d'entraînement (Zhao et al., 2026). *Supposé, à vérifier* : qu'aucune comparaison contrôlée RL contre harnais n'existe ; nous ne l'avons pas trouvée, ce qui ne prouve pas son absence. *Pratique* : choisir entre entraîner un agent et régler un harnais, quand on n'a qu'un GPU gratuit.
7. **Concepts et mots-clés.**

Concept	Définition de travail	Termes anglais
Agent de recherche entraîné	Modèle qui apprend par renforcement quand et quoi chercher	search agent, agentic search, reinforcement learning, GRPO, PPO
Harnais fixe	Règle de recherche écrite par le programmeur	retrieval-augmented generation, RAG pipeline, ReAct, IRCoT
Décision de recherche	Choix de chercher, de reformuler ou de répondre	adaptive retrieval, when to retrieve, search decision
Coût de recherche	Recherches, jetons et temps par question	over-searching, search efficiency, tool-call cost
Généralisation	Tenue sur des questions non vues à l'entraînement	out-of-distribution, held-out datasets, generalization

8. **Terrain et faisabilité.** Données publiques (FlashRAG, sous-corpus Wikipédia), modèles publics, GPU Kaggle gratuits (environ 30 h par semaine). Contrainte principale : le corpus complet ne tient pas sur Kaggle, d'où un corpus réduit et une couverture limitée.
9. **Termes à tester en priorité dans OpenAlex.** « search agent » ; « reinforcement learning » ; « retrieval-augmented generation » ; « over-search » ; « adaptive retrieval ». Travaux fondateurs connus : Search-R1, ReAct, IRCoT, Self-RAG (les articles témoins).
10. **Incertitudes à discuter avec la direction du mémoire.** Le cadre du fourragement de l'information est-il recevable, alors que Pirolli et Card n'ont pas pu être lus dans le texte ? La différence de modèle entre harnais (Instruct) et agents (base) est-elle acceptable pour l'article, ou faut-il passer aux agents issus de la version Instruct ? Le corpus d'un million de passages suffit-il pour le mémoire ?

15 Chronologie

D'après les horaires des commits et des fichiers.

Date	Travail
3 nov., 9 h–11 h 45	Squelette du dépôt, test de fumée sur Kaggle en six versions (JAX, `spawn`, ex aequo de BM25).
3 nov., 11 h 50–12 h 30	Mesure de la couverture des corpus (BM25 puis E5) ; choix du corpus d'un million de passages.
3 nov., matinée et après-midi	Revue de littérature : corpus de 91 articles, reprise avec OpenAlex et Consensus, vérification des références.
3 nov., 15 h	Systèmes A0 à A3, script de run, premier jet de l'article et du carnet.
3 nov., 15 h–16 h 20	Runs de mise au point sur Kaggle ; bogue de A3 trouvé et corrigé ; reprise du cadre théorique.
9 nov., matin	Premier rendu complet sur données fictives ; schémas du modèle complet et du protocole ; carnet mis en forme.
9 nov., suite	Contrôle de conformité à la trame ; résumé, introduction et revue réécrits ; vérification finale des 46 références ; analyse de puissance ; annexes ; script de rendu.

16 Mes demandes à l'IA (extraits)

La trame demande, pour chaque étape, ce que j'ai demandé à l'outil. Voici mes demandes clés du 9 novembre, citées telles quelles à l'orthographe près ; celles du 3 novembre sont résumées dans le journal brut.

— « L'objectif est d'avoir un premier rendu, même si la donnée est fausse, mais en suivant la forme du PDF envoyé ; je veux le schéma complet. » *Résultat :* données fictives déclarées, modèle complet avec H3 et H4 en pointillé, schéma du protocole (D15).

— « Commit tout. Pour le gabarit, tout est sur la trame : je n'ai pas de cours à proprement parler, c'est mon sujet de mémoire. » *Résultat :* préambule propre (D16), commits thématiques ; le PDF de la trame est resté hors du dépôt public, pour une question de droit d'auteur.

— « Le carnet de bord, tu as carte blanche, tu peux inventer, juste justifier, expliquer les choix, où l'IA aide, données, etc. Mais ça doit être ultra justifié. » *Résultat :* registre des décisions, déclaration des données, tableau de la part de l'IA. Claude n'a rien inventé de factuel et l'a dit : chaque fait renvoie à une trace.

— « Relance tout, et on continue d'améliorer l'article, même si les données sont fictives […]. Tu as le droit d'inventer, mais ça doit être structuré et logique […], et recheck si on suit bien la trame du PDF. » *Résultat :* script de rendu (D19), contrôle de conformité (section 4), réécritures et vérification finale de la bibliographie.

Annexes

— Carnet des requêtes OpenAlex : `docs/litterature/journal_requetes_openalex.md` et `journal_requetes_complement.md`.
— Journal brut, tenu au jour le jour : `docs/article/journal_brut.md`.
— Fiche données : `docs/article/fiche_donnees.md`.
— Code de l'analyse, de la puissance et des données fictives : `analysis/` ; chaîne complète : `scripts/rendu.sh`.