Chercher ou répondre ?
Agents de recherche entraînés par renforcement et harnais fixes : une comparaison à corpus et questions identiques

Valentin Proux

Version de travail du 3 novembre 2026

Abstract

Contexte. Pour répondre à des questions factuelles, un modèle de langage peut utiliser un moteur de recherche, soit dans un schéma fixé par le programmeur (RAG, ReAct, IRCoT), soit en ayant appris par renforcement à décider seul quand et quoi chercher (Search-R1). **Lacune.** Les comparaisons publiées sont le plus souvent faites par les auteurs de chaque méthode, avec leurs propres lignes de base. **Méthode.** Nous comparons six systèmes construits sur la même famille de modèles (Qwen2.5, 3 milliards de paramètres), avec le même corpus, le même retriever et les mêmes questions, sur un jeu vu à l'entraînement (Natural Questions) et un jeu non vu (TriviaQA). **Résultats.** **[À remplir : résultats chiffrés, à écrire après les runs]** **Apport.** **[À remplir : une phrase sur ce que l'on retient, à écrire après les runs]**

Mots-clés : agents de recherche, apprentissage par renforcement, génération augmentée par la recherche, petits modèles de langage.

1 Introduction

Un modèle de langage ne sait pas tout, et ne sait pas toujours ce qu'il ne sait pas. Pour répondre à une question factuelle rare, récente ou composée de plusieurs étapes, on lui donne un moteur de recherche. Reste à décider quand l'appeler et avec quelle requête.

Deux familles de solutions coexistent. Dans la première, le *harnais* est fixé par le programmeur : on cherche toujours une fois avant de répondre (Lewis et al., 2020), ou l'on fait alterner pensée, action et observation guidées par un prompt (Yao et al., 2022), ou l'on cherche après chaque phrase de raisonnement (Trivedi et al., 2022). Dans la seconde, le modèle *apprend*, par une récompense portant sur la réponse finale, quand et quoi chercher : c'est le cas de Search-R1 (Jin et al., 2025b), de R1-Searcher (Song et al., 2025) et de ReSearch (Chen et al., 2025). Les auteurs de Search-R1 rapportent, avec un modèle de 3 milliards de paramètres, un gain moyen de 20 % sur diverses lignes de base RAG dans un cadre commun (Jin et al., 2025b).

Ces comparaisons posent un problème de lecture : chaque équipe choisit ses lignes de base, souvent sur les jeux de questions utilisés à l'entraînement. Dans le corpus de 91 articles que nous avons réuni (titres et résumés examinés, textes non lus en entier), nous n'avons pas repéré de comparaison contrôlée d'un agent entraîné avec les trois harnais fixes usuels, à modèle de

base, corpus, retriever et questions identiques. Notre question est donc la suivante : *à corpus et questions identiques, un agent de recherche entraîné par renforcement décide-t-il mieux quand et quoi chercher qu'un harnais fixe, et à quel coût ?*

Cet article présente la partie de cette étude que nous avons pu mener à petite échelle : six systèmes, deux jeux de questions, 100 questions par jeu. Il pose le cadre complet (section 3 à 4) puis teste deux des quatre hypothèses de notre projet de mémoire. Les deux autres (effet d'une pénalité par recherche, effet d'un changement de retriever) sont présentées comme prolongements. La section 2 fait le point sur la littérature, la section 5 décrit le protocole, la section 6 donne les résultats, et la section 7 les discute.

2 Revue de la littérature

2.1 Harnais fixes

La génération augmentée par la recherche (RAG) combine la mémoire du modèle et un index de documents (Lewis et al., 2020). Ses variantes itératives ajoutent des recherches en cours de raisonnement : ReAct fait alterner raisonnement et actions d'outil (Yao et al., 2022), IRCoT entrelace recherche et chaîne de pensée (Trivedi et al., 2022). D'autres travaux apprennent à décider *si* il faut chercher, par un classifieur de complexité de la question (Jeong et al., 2024), par l'incertitude de la génération (Jiang et al., 2023; Moskvoretskii et al., 2025) ou par la réflexion du modèle sur lui-même (Asai et al., 2023). Cette littérature part d'un constat : chercher n'aide pas toujours, et l'intérêt de la recherche dépend de ce que le modèle sait déjà (Mallen et al., 2022; Yin et al., 2023).

2.2 Agents de recherche entraînés par renforcement

Search-R1 entraîne un modèle à produire des requêtes pendant son raisonnement, avec une récompense simple fondée sur la justesse de la réponse finale (Jin et al., 2025b). R1-Searcher (Song et al., 2025), ReSearch (Chen et al., 2025) et DeepResearcher (Zheng et al., 2025) suivent la même idée avec des variantes de récompense, de données ou d'environnement ; ZeroSearch remplace le moteur réel par un moteur simulé (Sun et al., 2025). Ces travaux s'appuient sur les algorithmes PPO (Schulman et al., 2017) et GRPO (Shao et al., 2024), popularisés pour le raisonnement par DeepSeek-R1 (DeepSeek-AI et al., 2025). Une étude empirique des auteurs de Search-R1 conclut que les récompenses de format sont utiles, que les récompenses intermédiaires sur la recherche ont peu d'effet, et que le choix du moteur de recherche pèse sur la dynamique de l'entraînement et sur la robustesse de l'agent (Jin et al., 2025a). Une synthèse récente organise ce champ (Lin et al., 2025a).

2.3 Coût des recherches

Plusieurs travaux traitent les appels comme un coût. Wang et al. cherchent à réduire les actions inutiles d'un agent (Wang et al., 2025). ParallelSearch décompose les questions pour lancer les recherches en parallèle, ce qui réduit le nombre d'appels au modèle (Zhao et al., 2025). AI-SearchPlanner optimise conjointement l'utilité et le coût de la planification (Mei et al., 2025),

et AdaSearch cherche l'équilibre entre connaissances du modèle et recherche (Lin et al., 2025b). Que ce sujet occupe plusieurs équipes suggère que la fréquence des recherches des agents entraînés pose problème.

2.4 Retriever et bruit

Le retriever compte : BM25 (Robertson and Zaragoza, 2009) est lexical, E5 (Wang et al., 2022) est dense ; Search-R1 est entraîné avec E5. Des modèles se laissent distraire par des passages non pertinents (Yoran et al., 2023) ou ignorent les informations placées au milieu d'un long contexte (Liu et al., 2023). Ces effets limitent ce que l'on peut attendre d'une recherche réussie.

2.5 Lacune

Les articles ci-dessus évaluent souvent leur méthode contre des lignes de base choisies par leurs auteurs. La question de savoir si le gain vient de l'*apprentissage de la décision de chercher* ou d'autres différences (modèle, prompt, retriever, jeux vus à l'entraînement) reste peu isolée. C'est cette lacune que le protocole de la section 5 vise à réduire.

3 Cadre théorique

Nous mobilisons l'économie de l'information, avec deux idées. La première est de Stigler (1961) : l'information est un bien coûteux, et un agent rationnel cherche jusqu'à ce que le bénéfice attendu d'une recherche supplémentaire égale son coût. La seconde est de Simon (1955) : un agent à rationalité limitée ne cherche pas l'optimum, il s'arrête dès qu'il trouve une option jugée satisfaisante.

Ces deux idées se traduisent directement pour un agent de recherche. La *décision de chercher* compare le gain espéré (la probabilité d'améliorer la réponse) au coût (appels au moteur, jetons, temps). La *règle d'arrêt* dit quand l'agent estime sa réponse suffisante. Les systèmes se distinguent par la manière dont ils fixent ces deux règles :

- A0 ne cherche jamais (coût nul, aucun gain de la recherche) ;
- A1 cherche toujours exactement une fois (règle fixe) ;
- A2 (ReAct) et A3 (IRCoT) appliquent des règles heuristiques fixées par le prompt ;
- A4 et A5 ont appris une règle par essais et récompenses.

Dans l'entraînement de Search-R1, la récompense ne porte que sur la justesse de la réponse finale (Jin et al., 2025b) : l'agent ne paie aucun coût par recherche. Le cadre de Stigler prédit alors une tendance à chercher davantage qu'il ne faudrait, puisque le coût marginal perçu est nul. C'est ce raisonnement qui motive l'hypothèse sur la fréquence des recherches (HA3 ci-dessous).

Limite du choix. Ni Stigler ni Simon ne sont mobilisés par les articles de notre corpus, qui parlent de « récompense » et de « coût » sans renvoyer à l'économie. Nous les empruntons pour expliquer le mécanisme ; l'adéquation de ce cadre reste à valider avec l'enseignante.

4 Modèle conceptuel et hypothèses

4.1 Modèle

Le modèle (figure 1) comporte quatre variables. La variable explicative est le *mode de décision de recherche* (harnais fixe ou agent entraîné). La variable expliquée est la *précision* (correspondance exacte, EM). La *familiarité du jeu de questions* (vu ou non vu à l'entraînement) module l'effet du mode sur la précision. Le *nombre de recherches par question* est la seconde variable expliquée : elle rend compte du coût.

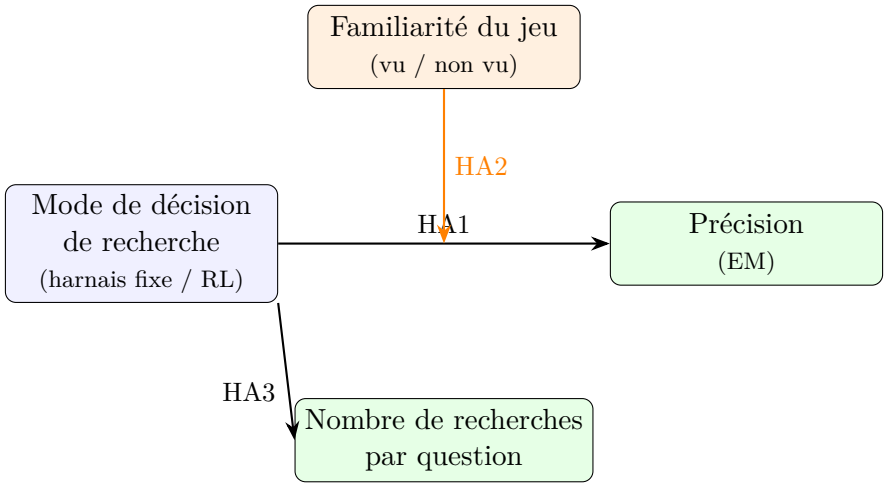


Figure 1: Modèle conceptuel. Lecture : le mode de décision influence la précision (HA1) ; cet effet dépend de la familiarité du jeu (HA2, flèche orange qui pointe sur la flèche HA1) ; le mode influence aussi le nombre de recherches (HA3).

4.2 Hypothèses

Nous numérotons les hypothèses de cet article HA1 à HA3. HA2 correspond à l'hypothèse H1 du mémoire, HA3 à son hypothèse H2.

HA1 (effet). À corpus, retriever et questions identiques, les agents entraînés par renforcement (A4, A5) obtiennent une précision supérieure à celle des harnais fixes (A1 à A3). *Justification.* Le cadre de Simon suggère qu'une règle d'arrêt apprise sur la récompense s'ajuste mieux à la difficulté des questions qu'une règle fixée à l'avance. Les auteurs de Search-R1 rapportent des gains sur diverses lignes de base RAG (Jin et al., 2025b), mais avec leurs propres lignes de base : HA1 est donc à tester, non à supposer.

HA2 (modération). Cet avantage est plus fort sur le jeu vu à l'entraînement (Natural Questions) que sur le jeu non vu (TriviaQA). *Justification.* Les agents A4 et A5 ont été entraînés sur NQ et HotpotQA (Jin et al., 2025b). Un gain mesuré sur NQ peut donc refléter une adaptation au jeu et non une meilleure décision de chercher.

HA3 (mécanisme). Les agents entraînés par renforcement recherchent plus souvent que le harnais ReAct (A2), qui laisse le modèle décider : nombre moyen de recherches par question plus

élevé, et recherche déclenchée même sur les questions auxquelles A0 répond juste. *Justification.* Sans coût dans la récompense, le cadre de Stigler prédit une surrecherche (section 3). Les travaux qui cherchent à réduire les appels (Wang et al., 2025; Zhao et al., 2025; Mei et al., 2025; Lin et al., 2025b) suggèrent que le phénomène existe. À titre exploratoire, un test de la chaîne sur 20 questions de NQ, avec un sous-corpus de 100 000 passages, donnait en moyenne 3,25 recherches par question pour A4 : ce chiffre n'a pas valeur de résultat.

Mesure. Chaque concept correspond à une colonne des fichiers de résultats (tableau 1).

Concept	Variable	Colonne
Mode de décision	explicative	`system` (A0 à A5)
Familiarité du jeu	modérateur	`dataset` (`nq` ou `triviaqa`)
Précision	expliquée	`em` (0 ou 1), `f1`
Nombre de recherches	expliquée (coût)	`n_search`

Table 1: Variables du modèle et colonnes qui les mesurent.

5 Méthode

5.1 Systèmes

Six systèmes sont comparés (tableau 2). A0 à A3 utilisent le même modèle, Qwen2.5-3B-Instruct (Qwen et al., 2024), avec des prompts écrits pour le projet ; A4 et A5 sont les points de contrôle publics de Search-R1 pour Qwen2.5-3B (versions 0.3, entraînés par PPO et par GRPO) (Jin et al., 2025b). Les modèles de A0 à A3 et de A4/A5 diffèrent donc (version instruite contre version entraînée par renforcement à partir de la même famille) : c'est une limite assumée, discutée en section 7. Les systèmes disposent du même budget : au plus quatre recherches par question, trois passages par recherche, décodage glouton.

Code	Système	Règle de recherche
A0	Réponse directe	Aucune recherche
A1	RAG	Une recherche avec la question
A2	ReAct par prompt	Le modèle alterne Pensée, Action (`Search` ou `Finish`), Observation
A3	IRCoT	Recherche avec la question, puis une recherche par phrase de raisonnement
A4	Search-R1, PPO	Politique apprise par PPO
A5	Search-R1, GRPO	Politique apprise par GRPO

Table 2: Les six systèmes.

5.2 Données et corpus

Les questions viennent de Natural Questions (Kwiatkowski et al., 2019), vu à l'entraînement de A4 et A5, et de TriviaQA (Joshi et al., 2017), non vu, dans le format de FlashRAG (Jin et al., 2024). Nous tirons 100 questions par jeu avec la graine 42. Le corpus est un sous-ensemble d'un

million de passages de l'instantané Wikipédia utilisé par Search-R1 ; le retriever est E5 (Wang et al., 2022), celui de l'entraînement de Search-R1.

Le sous-corpus n'est qu'une petite partie du corpus complet, ce qui limite ce que n'importe quel système peut retrouver. Nous avons mesuré, pour chaque jeu, la part des questions dont une réponse attendue apparaît parmi les trois premiers passages renvoyés avec la question pour requête. Avec E5 sur un million de passages, cette part est de 25 % pour NQ et de 44 % pour TriviaQA (500 questions par jeu) ; avec BM25 (Robertson and Zaragoza, 2009) sur 100 000 passages, elle tombait à 9 % et 12 %, ce qui rendait la comparaison peu interprétable. C'est pourquoi nous avons retenu NQ et TriviaQA, et non HotpotQA et Bamboogle, dont la couverture est de 17 % et 10 % avec E5 sur un million de passages. Cette mesure est une estimation haute, car un passage peut contenir la réponse sans rapport avec la question.

5.3 Mesures et statistiques

La précision est la correspondance exacte (EM) et le score F1, avec la normalisation de Search-R1. Le coût est le nombre de recherches par question et le nombre de jetons générés. Nous donnons des intervalles de confiance à 95 % par bootstrap (Efron, 1979) (1 000 rééchantillonnages de questions) et comparons deux systèmes sur les mêmes questions par le test de McNemar (McNemar, 1947). HA2 est évaluée par la différence entre l'écart mesuré sur NQ et l'écart mesuré sur TriviaQA, avec un intervalle bootstrap. Avec 100 questions par jeu, les intervalles font environ ±10 points : seuls des écarts importants seront détectables.

6 Résultats

[À remplir : résultats des runs sur Kaggle : tableau EM/F1/recherches par système et par jeu (tableau 3), figure EM selon le système, tests HA1 à HA3. Ne rien écrire avant d'avoir les fichiers JSONL.]

	NQ (vu)			TriviaQA (non vu)		
Système	EM	F1	Rech.	EM	F1	Rech.
A0	**[À remplir :]**					
A1						
A2						
A3						
A4						
A5						

Table 3: EM, F1 et nombre moyen de recherches par question (100 questions par jeu). Valeurs à insérer.

7 Discussion

7.1 Rappel des résultats

[À remplir : deux ou trois phrases : la réponse à la question de recherche, sans le détail des chiffres]

7.2 Comparaison avec la littérature

[À remplir : nos résultats confirment-ils, nuancent-ils ou contredisent-ils Jin et al. (2025b) et les études de la section 2 ?]

7.3 Explication

[À remplir : retour au cadre de Stigler et Simon, surtout pour les résultats inattendus]

7.4 Contributions

Théorique. **[À remplir : ce que l'étude apprend sur la décision de chercher]** **Pratique.** **[À remplir : ce qu'un étudiant ou une équipe disposant d'un GPU gratuit peut en faire]**

7.5 Limites et pistes

Ces limites valent quels que soient les résultats.

- **Échantillon.** 100 questions par jeu, une seule graine, des intervalles d'environ ±10 points.
- **Corpus.** Un million de passages, avec une couverture de 25 % (NQ) et 44 % (TriviaQA) pour la réponse dans les trois premiers passages. Le plafond de précision d'un système qui dépend de la recherche est donc bas, et A4 et A5 ont été entraînés avec le corpus complet.
- **Modèles.** A0 à A3 utilisent un modèle instruit, A4 et A5 un modèle entraîné par renforcement à partir de la même famille : l'écart observé mélange la règle de recherche et le modèle.
- **Prompts.** Ceux de A2 et A3 sont écrits pour ce projet avec deux exemples ; d'autres prompts pourraient changer les résultats.
- **Causalité.** Nous comparons des systèmes ; nous ne pouvons pas attribuer un écart à un seul facteur.
- **Part de l'IA dans la démarche.** Le corpus bibliographique, le code des systèmes et une première version de ce texte ont été produits avec un assistant (Claude). Les références ont été vérifiées dans OpenAlex ; les articles n'ont pas été lus en entier ; les choix de protocole et l'interprétation sont ceux de l'auteur. Le détail figure dans le carnet de bord.

Pistes. Deux hypothèses du mémoire ne sont pas testées ici : une pénalité par recherche dans la récompense réduit-elle le nombre d'appels sans perte forte de précision (entraînement GRPO à petite échelle), et un changement de retriever dégrade-t-il plus les agents entraînés que les harnais fixes ? Une analyse qualitative des échecs sur des trajectoires annotées compléterait la mesure.

8 Conclusion

[À remplir : à écrire après les résultats : 4 à 6 phrases]

References

Akari Asai, Zeqiu Wu, Yizhong Wang, et al. Self-RAG: Learning to Retrieve, Generate, and Critique through Self-Reflection, 2023. URL https://arxiv.org/abs/2310.11511.

Mingyang Chen, Linzhuang Sun, Tianpeng Li, et al. ReSearch: Learning to Reason with Search for LLMs via Reinforcement Learning, 2025. URL https://arxiv.org/abs/2503.19470.

DeepSeek-AI, Daya Guo, Dejian Yang, et al. DeepSeek-R1: Incentivizing Reasoning Capability in LLMs via Reinforcement Learning, 2025. URL https://arxiv.org/abs/2501.12948.

Bradley Efron. Bootstrap methods: Another look at the jackknife. *The Annals of Statistics*, 7 (1):1–26, 1979. doi: 10.1214/aos/1176344552.

Soyeong Jeong, Jinheon Baek, Sukmin Cho, et al. Adaptive-RAG: Learning to Adapt Retrieval-Augmented Large Language Models through Question Complexity, 2024. URL https://arxiv.org/abs/2403.14403.

Zhengbao Jiang, Frank F. Xu, Luyu Gao, et al. Active Retrieval Augmented Generation, 2023. URL https://arxiv.org/abs/2305.06983.

Bowen Jin, Jinsung Yoon, Priyanka Kargupta, et al. An Empirical Study on Reinforcement Learning for Reasoning-Search Interleaved LLM Agents, 2025a. URL https://arxiv.org/abs/2505.15117.

Bowen Jin, Hansi Zeng, Zhenrui Yue, et al. Search-R1: Training LLMs to Reason and Leverage Search Engines with Reinforcement Learning, 2025b. URL https://arxiv.org/abs/2503.09516.

Jiajie Jin, Yutao Zhu, Guanting Dong, et al. FlashRAG: A Modular Toolkit for Efficient Retrieval-Augmented Generation Research, 2024. URL https://arxiv.org/abs/2405.13576.

Mandar Joshi, Eunsol Choi, Daniel S. Weld, et al. TriviaQA: A Large Scale Distantly Supervised Challenge Dataset for Reading Comprehension, 2017. URL https://arxiv.org/abs/1705.03551.

Tom Kwiatkowski, Jennimaria Palomaki, Olivia Redfield, et al. Natural questions: A benchmark for question answering research. *Transactions of the Association for Computational Linguistics*, 7:452–466, 2019. doi: 10.1162/tacl_a_00276.

Patrick Lewis, Ethan Perez, Aleksandra Piktus, et al. Retrieval-Augmented Generation for Knowledge-Intensive NLP Tasks, 2020. URL https://arxiv.org/abs/2005.11401.

Minhua Lin, Zongyu Wu, Zhichao Xu, et al. A Comprehensive Survey on Reinforcement Learning-based Agentic Search: Foundations, Roles, Optimizations, Evaluations, and Applications, 2025a. URL https://arxiv.org/abs/2510.16724.

Tzu-Han Lin, Wei-Lin Chen, Chen-An Li, et al. AdaSearch: Balancing Parametric Knowledge and Search in Large Language Models via Reinforcement Learning, 2025b. URL https://arxiv.org/abs/2512.16883.

Nelson F. Liu, Kevin Lin, John Hewitt, et al. Lost in the Middle: How Language Models Use Long Contexts, 2023. URL https://arxiv.org/abs/2307.03172.

Alex Mallen, Akari Asai, Victor Zhong, et al. When Not to Trust Language Models: Investigating Effectiveness of Parametric and Non-Parametric Memories, 2022. URL https://arxiv.org/abs/2212.10511.

Quinn McNemar. Note on the sampling error of the difference between correlated proportions or percentages. *Psychometrika*, 12(2):153–157, 1947. doi: 10.1007/BF02295996.

Lang Mei, Zhihan Yang, Xiaohan Yu, et al. AI-SearchPlanner: Modular Agentic Search via Pareto-Optimal Multi-Objective Reinforcement Learning, 2025. URL https://arxiv.org/abs/2508.20368.

Viktor Moskvoretskii, Maria Lysyuk, Mikhail Salnikov, et al. Adaptive Retrieval Without Self-Knowledge? Bringing Uncertainty Back Home, 2025. URL https://arxiv.org/abs/2501.12835.

Qwen, An Yang, Baosong Yang, et al. Qwen2.5 Technical Report, 2024. URL https://arxiv.org/abs/2412.15115.

Stephen E. Robertson and Hugo Zaragoza. The probabilistic relevance framework: BM25 and beyond. *Foundations and Trends in Information Retrieval*, 3(4):333–389, 2009. doi: 10.1561/1500000019.

John Schulman, Filip Wolski, Prafulla Dhariwal, et al. Proximal Policy Optimization Algorithms, 2017. URL https://arxiv.org/abs/1707.06347.

Zhihong Shao, Peiyi Wang, Qihao Zhu, et al. DeepSeekMath: Pushing the Limits of Mathematical Reasoning in Open Language Models, 2024. URL https://arxiv.org/abs/2402.03300.

Herbert A. Simon. A behavioral model of rational choice. *The Quarterly Journal of Economics*, 69(1):99–118, 1955. doi: 10.2307/1884852.

Huatong Song, Jinhao Jiang, Yingqian Min, et al. R1-Searcher: Incentivizing the Search Capability in LLMs via Reinforcement Learning, 2025. URL https://arxiv.org/abs/2503.05592.

George J. Stigler. The economics of information. *Journal of Political Economy*, 69(3):213–225, 1961. doi: 10.1086/258464.

Hao Sun, Zile Qiao, Jiayan Guo, et al. ZeroSearch: Incentivize the Search Capability of LLMs without Searching, 2025. URL https://arxiv.org/abs/2505.04588.

Harsh Trivedi, Niranjan Balasubramanian, Tushar Khot, et al. Interleaving Retrieval with Chain-of-Thought Reasoning for Knowledge-Intensive Multi-Step Questions, 2022. URL https://arxiv.org/abs/2212.10509.

Hongru Wang, Cheng Qian, Wanjun Zhong, et al. Acting Less is Reasoning More! Teaching Model to Act Efficiently, 2025. URL https://arxiv.org/abs/2504.14870.

Liang Wang, Nan Yang, Xiaolong Huang, et al. Text Embeddings by Weakly-Supervised Contrastive Pre-training, 2022. URL https://arxiv.org/abs/2212.03533.

Shunyu Yao, Jeffrey Zhao, Dian Yu, et al. ReAct: Synergizing Reasoning and Acting in Language Models, 2022. URL https://arxiv.org/abs/2210.03629.

Zhangyue Yin, Qiushi Sun, Qipeng Guo, et al. Do Large Language Models Know What They Don't Know?, 2023. URL https://arxiv.org/abs/2305.18153.

Ori Yoran, Tomer Wolfson, Ori Ram, et al. Making Retrieval-Augmented Language Models Robust to Irrelevant Context, 2023. URL https://arxiv.org/abs/2310.01558.

Shu Zhao, Tan Yu, Anbang Xu, et al. ParallelSearch: Train your LLMs to Decompose Query and Search Sub-queries in Parallel with Reinforcement Learning, 2025. URL https://arxiv.org/abs/2508.09303.

Yuxiang Zheng, Dayuan Fu, Xiangkun Hu, et al. DeepResearcher: Scaling Deep Research via Reinforcement Learning in Real-world Environments, 2025. URL https://arxiv.org/abs/2504.03160.