Chercher ou répondre ?
Agents de recherche entraînés par renforcement et harnais fixes : une comparaison à corpus et questions identiques

Valentin Proux

Premier rendu, 9 novembre 2026

Résumé

Pour répondre à une question factuelle, un modèle de langage peut interroger un moteur de recherche selon une règle fixée par le programmeur, comme la génération augmentée par la recherche (RAG), ReAct ou IRCoT, ou selon une politique apprise par renforcement, comme Search-R1. Or les gains attribués à cet apprentissage sont mesurés par les auteurs des méthodes, contre des lignes de base qui ne partagent ni le corpus, ni le moteur, ni le budget de recherche. Cette étude compare six systèmes fondés sur Qwen2.5-3B dans des conditions identiques, sur 100 questions de Natural Questions (NQ), vu à l'entraînement des agents, et 100 de TriviaQA, non vu. Elle montre que l'avantage des agents entraînés est net, mais qu'il ne tient pas à une meilleure décision de chercher. En correspondance exacte (EM), les meilleurs agents ont atteint 23 % sur NQ et 53 % sur TriviaQA, contre 10 % et 40 % pour le meilleur harnais ; les six comparaisons ont été significatives, et l'avance n'a pas été plus forte sur le jeu vu. Les agents ont cherché à chaque question, 0,92 fois de plus que ReAct. Mais sur les 44 questions que le modèle résolvait seul, les harnais en ont perdu de 18 à 24 après avoir cherché, les agents 6 et 10. Lu avec la théorie du fourragement de l'information, l'avantage des agents tient à l'exploitation de l'information trouvée plutôt qu'à la décision d'arrêter de chercher.

Mots-clés : Search-R1 ; génération augmentée par la recherche ; surrecherche ; fourragement de l'information ; évaluation contrôlée ; questions-réponses.

Résumé

Language models answer factual questions better when they can query a search engine. The decision to search can follow a fixed rule (retrieval-augmented generation, ReAct, IRCoT) or a policy learned by reinforcement learning, as in Search-R1. Yet the reported gains of learned policies come from method authors, measured against baselines that do not share the corpus, retriever or search budget. We compare six systems built on Qwen2.5-3B under identical conditions, on 100 Natural Questions (seen in training) and 100 TriviaQA questions (unseen). Trained agents clearly win, but not because they decide better when to search. They reached 23% and 53% exact match, against 10% and 40% for the best fixed pipeline; all six pairwise differences were significant, and the advantage was no larger on the seen dataset. The agents searched on every question, 0.92 times more than ReAct. Yet on the 44 questions the model answered correctly without search, fixed pipelines lost 18 to 24 after searching, the agents only 6 and 10. Read through information foraging theory, the agents' advantage lies in exploiting what they retrieve, not in deciding when to stop searching.

Keywords: Search-R1; retrieval-augmented generation; over-searching; information foraging; controlled evaluation; question answering.

1 Introduction

Un modèle de langage ne sait pas tout, et ne sait pas toujours ce qu'il ne sait pas. Pour répondre à une question factuelle rare, récente ou composée de plusieurs étapes, on lui donne donc accès à un moteur de recherche (Lewis et al., 2020). Ce couplage déplace la difficulté : il faut décider *quand* chercher et *quoi* chercher. Trois grandeurs en dépendent, que cet article suit tout du long : la décision de recherche elle-même, la *précision* de la réponse et le *coût* engagé, compté en recherches par question.

Ce problème n'est pas qu'académique. Chaque recherche ajoute de la latence, des jetons à lire et du calcul ; chercher trop peu fait répondre de mémoire, au risque de se tromper (Mallen et al., 2023). Les agents actuels penchent nettement du côté de l'excès : Wu et al. (2025) estiment que Search-R1 aurait pu éviter 27,7 % de ses étapes de recherche, et Pezzuti et al. (2026) observent jusqu'à 186 appels pour une seule requête. Pour une équipe qui ne dispose que d'un GPU gratuit, comme pour un service qui répond à des millions de questions, la règle qui décide de chercher fixe à la fois la qualité et la facture.

Deux familles de solutions coexistent. Dans la première, le *harnais* est fixé par le programmeur : on cherche toujours une fois avant de répondre (Lewis et al., 2020), on fait alterner pensée, action et observation guidées par un prompt (Yao et al., 2022), ou l'on cherche après chaque phrase de raisonnement (Trivedi et al., 2023). Dans la seconde, le modèle *apprend* par renforcement, avec une récompense portant sur la réponse finale, quand et quoi chercher (Jin et al., 2025b ; Song et al., 2025 ; Chen et al., 2025). Les auteurs de Search-R1 rapportent ainsi, avec Qwen2.5-3B, un gain de 20 % sur diverses lignes de base RAG (Jin et al., 2025b). Mais ces gains sont mesurés par les auteurs de chaque méthode, contre des lignes de base qu'ils choisissent, souvent sur les jeux de questions vus à l'entraînement ; Zhao et al. (2026) font le même constat pour les méthodes d'entraînement, dont la croissance a dépassé celle des comparaisons contrôlées. Dans le corpus que nous avons réuni, nous n'avons pas repéré de comparaison d'un agent entraîné avec les harnais fixes usuels à corpus, retriever, budget et questions identiques. Ce constat vaut pour notre recherche documentaire, dont la méthode est donnée en annexe A : il ne prouve pas qu'une telle étude n'existe pas. On ne sait donc pas si l'avantage rapporté vient de l'apprentissage de la décision de chercher, ou des autres différences entre systèmes.

Cette étude compare, dans des conditions identiques, deux agents Search-R1 entraînés par renforcement (PPO et GRPO) et quatre systèmes à règle fixe, de la réponse sans recherche à IRCoT, tous fondés sur des modèles Qwen2.5 de 3 milliards de paramètres. Elle mesure la précision et le coût sur un jeu de questions vu à l'entraînement des agents (Natural Questions) et sur un jeu non vu (TriviaQA), et lit les résultats avec la théorie du fourragement de l'information (Pirolli and Card, 1999), qui fait de la décision de chercher un arbitrage entre gain espéré et coût. Elle répond à la question suivante : *à corpus et questions identiques, un agent de recherche entraîné par renforcement décide-t-il mieux quand et quoi chercher qu'un harnais fixe, et à quel coût ?* C'est la partie à petite échelle d'un projet de mémoire plus large, dont deux hypothèses sont testées ici et deux sont présentées comme prolongements.

L'étude apporte trois éléments. D'abord, une comparaison contrôlée qui isole la règle de recherche : seuls la règle et, pour les agents, les poids du modèle changent d'un système à l'autre. Ensuite, une mesure qui sépare la précision du coût, et qui teste si les agents entraînés cherchent encore quand le modèle connaît déjà la réponse : c'est ce que prédit un cadre où la récompense ignore le coût d'une recherche. Enfin, un protocole reproductible sans budget : code public, GPU gratuits, règles de décision fixées avant les runs et analyse de puissance qui dit, avant de les lancer, quels écarts l'expérience peut voir.

2 Revue de la littérature

2.1 Démarche

Cette revue est narrative : le champ est jeune, fait surtout de préprints de 2025 et 2026, et le but est de construire le raisonnement qui mène à notre question plutôt que d'estimer un effet moyen. La recherche documentaire a utilisé OpenAlex et Consensus par l'intermédiaire d'un agent d'IA, les 3 et 9 novembre 2026. L'équation retenue croise le renforcement, la recherche agentique, la tâche de questions-réponses et les modèles de langage, depuis 2023 ; elle a été corrigée deux fois après mesure de sa précision sur 20 résultats tirés au hasard, de 35 % à environ 75 %. Elle ne retrouve qu'un article témoin sur cinq, car trois témoins sont des harnais fixes, hors du bloc « renforcement » : ces articles, et ceux qu'une requête sémantique a ajoutés, viennent d'une première collecte thématique. Les 51 références citées ont été vérifiées dans OpenAlex. Le corpus retenu compte 65 articles, dont 38 sont cités ici. L'annexe A donne les équations, les volumes et les décisions. Les textes n'ont pas tous été lus en entier : ce que nous rapportons des études les plus récentes vient de leur résumé, sauf mention contraire.

2.2 Harnais fixes

La génération augmentée par la recherche (RAG) combine la mémoire du modèle et un index de documents (Lewis et al., 2020). Ses variantes itératives ajoutent des recherches en cours de raisonnement : ReAct fait alterner raisonnement et actions d'outil (Yao et al., 2022), IRCoT entrelace recherche et chaîne de pensée (Trivedi et al., 2023). D'autres travaux apprennent à décider *si* il faut chercher, par un classifieur de complexité de la question (Jeong et al., 2024), par l'incertitude de la génération (Jiang et al., 2023 ; Moskvoretskii et al., 2025) ou par la réflexion du modèle sur lui-même (Asai et al., 2023). Cette littérature part d'un constat : chercher n'aide pas toujours, et l'intérêt de la recherche dépend de ce que le modèle sait déjà (Mallen et al., 2023 ; Yin et al., 2023).

2.3 Agents de recherche entraînés par renforcement

L'apprentissage par renforcement promet de remplacer la règle écrite à la main par une politique optimisée sur le résultat. Search-R1 en est la forme la plus simple : le modèle insère des requêtes dans son raisonnement, et seule la justesse de la réponse finale est récompensée (Jin et al., 2025b). Ce principe s'est vite décliné : R1-Searcher et ReSearch varient la récompense et les données (Song et al., 2025 ; Chen et al., 2025), DeepResearcher place l'agent sur le web réel

(Zheng et al., 2025), ZeroSearch remplace le moteur par un moteur simulé (Sun et al., 2025). Tous reposent sur PPO (Schulman et al., 2017) ou GRPO (Shao et al., 2024), popularisés pour le raisonnement par DeepSeek-R1 (Guo et al., 2025), et une synthèse récente organise ce champ (Lin et al., 2025).

Ce que l'agent apprend reste pourtant mal connu. Les auteurs de Search-R1 montrent eux-mêmes que les récompenses intermédiaires sur la recherche changent peu de chose, mais que le choix du moteur pèse sur l'entraînement et sur la robustesse (Jin et al., 2025a) : la politique apprise dépend de l'environnement dans lequel elle a été apprise. C'est la raison pour laquelle nous distinguons un jeu vu d'un jeu non vu.

2.4 Coût des recherches

La recherche a longtemps été évaluée à son seul bénéfice ; elle est désormais vue comme un coût à maîtriser. Le constat de départ est que les agents entraînés cherchent trop : la surrecherche est maintenant définie et mesurée, et Search-R1 aurait pu éviter 27,7 % de ses étapes (Wu et al., 2025). Les réponses proposées vont toutes dans le même sens, réintroduire le coût dans l'apprentissage : réduire les actions inutiles (Wang et al., 2025) ou l'abus d'outils (Chen et al., 2026), rendre la recherche plus économe (Sha et al., 2025), paralléliser les sous-requêtes pour réduire les appels (Zhao et al., 2025), optimiser conjointement utilité et coût (Mei et al., 2025), fixer un budget de tours et de passages (Sun et al., 2026a), superviser la décision de chercher ou de répondre (Sun et al., 2026b), ou équilibrer connaissances du modèle et recherche (Lin et al., 2026).

Mais réintroduire le coût n'est pas trivial. SAAS constate qu'une pénalité naïve par recherche réduit les appels au prix de la précision, et propose une pénalité ciblée sur les recherches que le modèle aurait pu éviter (Tang et al., 2026). L'arbitrage entre précision et coût est donc au cœur du champ ; il reste rarement mesuré face aux harnais fixes, qui ont pourtant un coût connu d'avance. C'est l'objet de nos hypothèses HA3a et HA3b, et de l'hypothèse H3 du mémoire.

2.5 Retriever et bruit

Le retriever compte : BM25 (Robertson and Zaragoza, 2009) est lexical, E5 (Wang et al., 2022) est dense ; Search-R1 est entraîné avec E5. Ajouter des passages n'aide pas toujours : selon la question et le modèle, la recherche peut aussi dégrader la réponse (Maekawa et al., 2024). Des modèles se laissent distraire par des passages non pertinents (Yoran et al., 2023) ou ignorent les informations placées au milieu d'un long contexte (Liu et al., 2024). Ces effets limitent ce que l'on peut attendre d'une recherche réussie. Zhao et al. (2026) signalent en outre un défaut de couverture du corpus Wikipédia 2018, dont la correction apporte plus que l'écart entre algorithmes d'entraînement : ce résultat, tiré du résumé, rend d'autant plus nécessaire notre mesure de couverture (section 5).

2.6 Lacune

Les articles ci-dessus évaluent souvent leur méthode contre des lignes de base choisies par leurs auteurs. Trois travaux s'approchent de notre question. Zhao et al. (2026) comparent de

façon contrôlée des méthodes d'entraînement entre elles, et non des agents entraînés à des harnais fixes. Raikote (2026) oppose un contrôleur appris à des règles fixes, mais avec un modèle gelé. s3 entraîne un chercheur séparé contre le RAG naïf (Jiang et al., 2025). La question de savoir si le gain vient de l'*apprentissage de la décision de chercher* ou d'autres différences (modèle, prompt, retriever, jeux vus à l'entraînement) nous paraît donc encore peu isolée, sous réserve de la lecture complète de ces travaux. C'est ce que le protocole de la section 5 vise à réduire.

3 Cadre théorique

Nous lisons la décision de chercher avec la théorie du fourragement de l'information (*information foraging*) de Pirolli and Card (1999). Elle transpose à la recherche d'information le raisonnement de l'écologie : un organisme exploite une parcelle tant que ce qu'elle rapporte justifie l'effort, puis passe à autre chose. Pour décider, il s'appuie sur des indices imparfaits de la valeur de ce qu'il va trouver, la *senteur de l'information*. L'idée que chercher a un coût, et qu'il faut s'arrêter quand le gain d'une recherche de plus ne le couvre plus, remonte à l'économie de l'information de Stigler (1961) ; la recherche d'information l'a reprise sous forme de modèles économiques de la recherche (Azzopardi, 2011).

Ce cadre explique le mécanisme que nous étudions et il est déjà mobilisé dans le champ : InForage s'en réclame explicitement pour formaliser le raisonnement augmenté par la recherche (Qian and Liu, 2025). Des travaux récents emploient le même vocabulaire sans toujours citer la théorie : le gain marginal de chaque recherche décroît avec les tours (Zhang et al., 2026), et il est proposé de traiter la recherche comme une acquisition d'informations sous budget (Poudel et al., 2026).

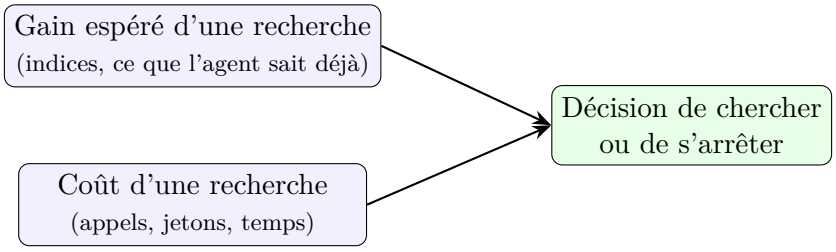


FIGURE 1 – Le cadre, d'après Pirolli and Card (1999) et Stigler (1961), simplifié. Lecture : l'agent cherche tant que le gain espéré d'une recherche de plus dépasse ce qu'elle lui coûte.

Transposé à nos systèmes, ce cadre oppose deux questions : qui estime le gain, et quel coût est pris en compte (tableau 1). Dans les harnais fixes, la règle est écrite d'avance ou confiée à un prompt. Dans A4 et A5, elle est apprise avec une récompense qui porte sur la réponse finale (Jin et al., 2025b) : l'agent a pu apprendre à estimer le gain, mais rien ne lui fait payer une recherche.

Il en découle trois attentes. Un agent qui estime le gain devrait mieux répartir ses recherches qu'une règle fixe. Cette estimation, apprise sur certains jeux de questions, devrait perdre en fiabilité ailleurs. Enfin, sans coût perçu, l'agent devrait continuer à chercher même quand le gain attendu est faible.

Limites du choix. La théorie décrit des humains : l'appliquer à un modèle de langage est

Système	Estimation du gain	Coût d'une recherche pris en compte
A0	Aucune : jamais de recherche	Sans objet
A1	Aucune : une recherche, toujours	Aucun : règle fixe
A2	Par le modèle, guidé par le prompt	Implicite : consigne de répondre dès que possible
A3	Aucune : une recherche par phrase	Aucun : règle fixe, dans la limite du budget
A4, A5	Apprise par renforcement	Aucun dans la récompense

TABLE 1 – Les systèmes lus avec le cadre. Tous partagent le même budget de quatre recherches.

une analogie, qui suit celle d'InForage. Elle suppose aussi un agent qui compare gain et coût, alors que nous n'observons que ses actions. Nous la mobilisons pour expliquer ces actions, sans affirmer que le modèle raisonne ainsi. Nous n'avons pas eu accès au texte de Pirolli and Card (1999) : notre présentation s'appuie sur ce qu'en rapportent Qian and Liu (2025). L'adéquation de ce cadre reste à valider avec la direction du mémoire.

4 Modèle conceptuel et hypothèses

4.1 Modèle

Le modèle (figure 2) traduit le cadre en cinq variables observables (tableau 2). La variable explicative est le *mode de décision de recherche* : harnais fixe ou agent entraîné. Il a deux variables expliquées : la *précision*, et le *nombre de recherches par question*, qui mesure le coût. Deux modérateurs changent la force de ces effets : la *familiarité du jeu de questions*, vu ou non vu à l'entraînement, et la *connaissance préalable* de la réponse. Le schéma montre aussi, en pointillé, les deux variables du projet de mémoire que la mini-expérience ne manipule pas : la *pénalité par recherche* dans la récompense (H3), justifiée par SAAS (Tang et al., 2026), et le *retriever* (H4), justifié par l'effet du moteur sur la robustesse de l'agent (Jin et al., 2025a). Elles sont gardées pour montrer où se place l'article dans le projet d'ensemble ; elles ne donnent lieu à aucun test ici.

Dans la théorie	Dans le modèle
Qui estime le gain, et comment	Mode de décision de recherche : variable explicative
Fiabilité des indices selon l'environnement	Familiarité du jeu de questions : modérateur
Gain réel d'une recherche	Connaissance préalable de la réponse : modérateur
Valeur obtenue	Précision : variable expliquée
Coût engagé	Nombre de recherches par question : variable expliquée

TABLE 2 – Du cadre théorique au modèle.

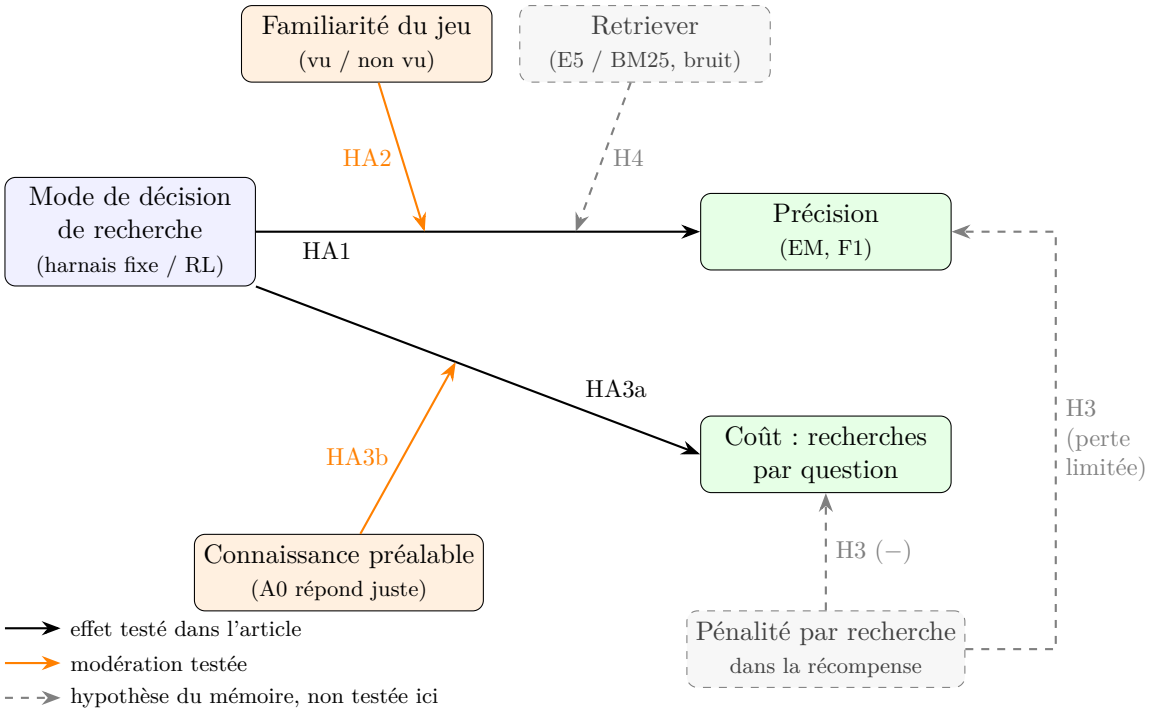


FIGURE 2 – Modèle conceptuel complet. Lecture : le mode de décision influence la précision (HA1) et le nombre de recherches (HA3a). Les flèches orange pointent sur une flèche : elles en changent la force. L'effet sur la précision dépend de la familiarité du jeu (HA2), l'effet sur le coût dépend de ce que le modèle sait déjà (HA3b). En pointillé, les deux hypothèses du mémoire que la mini-expérience ne peut pas tester : une pénalité par recherche réduit le coût pour une perte de précision limitée (H3), et le retriever modère l'avantage du RL (H4).

4.2 Hypothèses

Une flèche, une hypothèse. HA2 correspond à l'hypothèse H1 du mémoire, HA3a et HA3b à son hypothèse H2.

HA1 (effet sur la précision). À corpus, retriever et questions identiques, les agents entraînés par renforcement (A4, A5) obtiennent une précision supérieure à celle des harnais fixes (A1 à A3). *Justification.* Selon le cadre, un agent qui estime le gain place mieux ses recherches qu'une règle écrite d'avance. Les auteurs de Search-R1 rapportent un gain de 20 % avec Qwen2.5-3B face à des lignes de base RAG (Jin et al., 2025b), et R1-Searcher annonce lui aussi une nette avance sur des méthodes RAG (Song et al., 2025). Ces comparaisons sont celles des auteurs : HA1 est à tester, non à supposer.

HA2 (modération par la familiarité). L'avantage de HA1 est plus fort sur le jeu vu à l'entraînement (Natural Questions) que sur le jeu non vu (TriviaQA). *Justification.* Dans le cadre, des indices appris dans un environnement renseignent moins bien dans un autre. A4 et A5 ont été entraînés sur NQ et HotpotQA : un gain sur NQ peut refléter une adaptation au jeu plutôt qu'une meilleure décision de chercher. Dans un autre dispositif, un contrôleur appris sur HotpotQA adapte sa conduite à MuSiQue, mais la qualité de réponse y chute (Raikote, 2026).

HA3a (effet sur le coût). Les agents entraînés (A4, A5) font en moyenne plus de recherches par question que le harnais ReAct (A2), qui laisse aussi le modèle décider. *Justification.* Sans coût dans la récompense, le cadre prédit une surrecherche, alors que le prompt de A2 demande de répondre dès que possible. Wu et al. (2025) estiment que Search-R1 aurait pu éviter 27,7 % de ses étapes de recherche, et Tang et al. (2026) font de cette surrecherche un défaut central des agents. A2 est le point de comparaison retenu parce que A1 et A3 suivent une règle fixe.

HA3b (modération par la connaissance préalable). L'écart de HA3a persiste sur les questions auxquelles le modèle sait déjà répondre sans chercher (A0 juste). *Justification.* Sur ces questions, le gain réel d'une recherche est faible : seul un agent qui ne paie pas ses recherches a intérêt à continuer. Tang et al. (2026) décrivent des agents qui cherchent alors que leurs connaissances suffisent, et le lien entre recherche et connaissances du modèle est documenté par ailleurs (Mallen et al., 2023 ; Yin et al., 2023).

Testabilité et règles de décision. Chaque concept correspond à une colonne des fichiers de résultats, et chaque hypothèse à une règle fixée avant le run complet (tableau 3). Un résultat négatif sera rapporté comme tel.

Hyp.	Colonnes	Test et règle de décision
HA1	`system`, `em`	McNemar apparié sur les 200 questions, pour chaque paire (A4 ou A5 contre A1, A2 ou A3), avec correction de Holm sur les 6 paires. Soutenue si les 6 écarts sont positifs et significatifs à 5 %, partiellement si certains le sont seulement.
HA2	`system`, `em`, `dataset`	Écart moyen entre RL et harnais sur NQ, moins le même écart sur TriviaQA. Soutenue si la borne basse de l'intervalle bootstrap à 95 % est positive.
HA3a	`system`, `n_search`	Différence appariée du nombre de recherches entre RL et A2. Soutenue si la borne basse de l'intervalle bootstrap à 95 % est positive.
HA3b	`n_search`, `em` de A0	Même test, limité aux questions où A0 répond juste. Si elles sont moins de 20, le résultat est présenté comme exploratoire.

TABLE 3 – Hypothèses, colonnes utilisées et règles de décision. Une question sans réponse compte comme fausse.

5 Méthode

5.1 Systèmes

Six systèmes sont comparés (tableau 4). A0 à A3 utilisent le même modèle, Qwen2.5-3B-Instruct (Qwen et al., 2024), avec des prompts écrits pour le projet ; A4 et A5 sont les points de contrôle publics de Search-R1 pour Qwen2.5-3B (versions 0.3, entraînés par PPO et par GRPO) (Jin et al., 2025b). Les fichiers de configuration de ces points de contrôle indiquent qu'ils partent de Qwen2.5-3B, le modèle de base, et non de sa version Instruct. Les modèles de A0 à A3 et de A4/A5 diffèrent donc : un harnais par prompt demande un modèle qui suit des consignes, d'où

ce choix, qui reste une limite discutée en section 7. Les systèmes disposent du même budget : au plus quatre recherches par question, trois passages par recherche, décodage glouton.

Code	Système	Règle de recherche
A0	Réponse directe	Aucune recherche
A1	RAG	Une recherche avec la question
A2	ReAct par prompt	Le modèle alterne Pensée, Action (`Search` ou `Finish`), Observation
A3	IRCoT	Recherche avec la question, puis une recherche par phrase de raisonnement
A4	Search-R1, PPO	Politique apprise par PPO
A5	Search-R1, GRPO	Politique apprise par GRPO

TABLE 4 – Les six systèmes.

La figure 3 résume le protocole : seuls la règle de recherche et, pour A4 et A5, les poids du modèle changent d'un système à l'autre ; questions, corpus, retriever, budget et mesures sont communs.

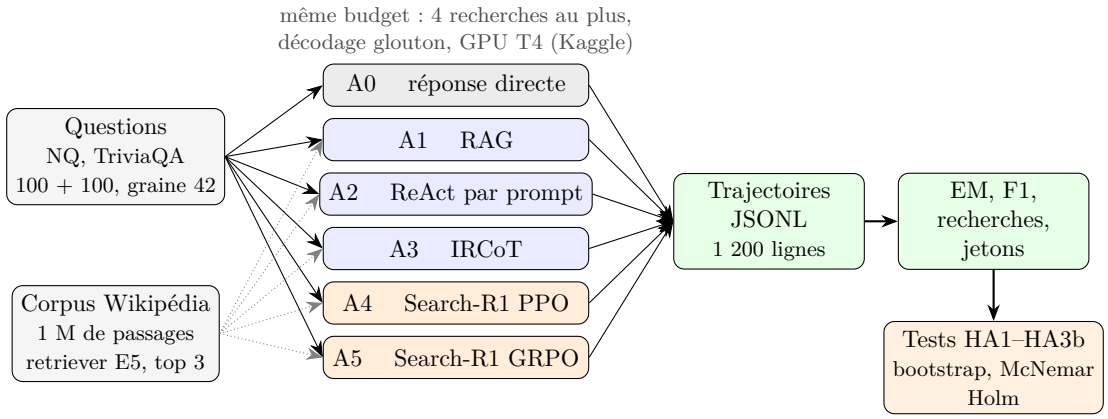


FIGURE 3 – Protocole. Lecture : les mêmes 200 questions passent dans les six systèmes ; ceux qui cherchent (pointillés) interrogent le même corpus avec le même retriever. Chaque passage d'une question dans un système donne une ligne JSONL, d'où sont tirées toutes les mesures et tous les tests.

5.2 Données et corpus

Les questions viennent de Natural Questions (Kwiatkowski et al., 2019), vu à l'entraînement de A4 et A5, et de TriviaQA (Joshi et al., 2017), non vu, dans le format de FlashRAG (Jin et al., 2025c). Nous tirons 100 questions par jeu avec la graine 42. Le corpus est un sous-ensemble d'un million de passages de l'instantané Wikipédia utilisé par Search-R1 ; le retriever est E5 (Wang et al., 2022), celui de l'entraînement de Search-R1.

Le sous-corpus n'est qu'une petite partie du corpus complet, ce qui limite ce que n'importe quel système peut retrouver. Nous avons mesuré, pour chaque jeu, la part des questions dont une réponse attendue apparaît parmi les trois premiers passages renvoyés avec la question pour requête. Avec E5 sur un million de passages, cette part est de 25 % pour NQ et de 44 % pour TriviaQA (500 questions par jeu) ; avec BM25 (Robertson and Zaragoza, 2009) sur 100 000 passages, elle tombait à 9 % et 12 %, ce qui rendait la comparaison peu interprétable. C'est

pourquoi nous avons retenu NQ et TriviaQA, et non HotpotQA et Bamboogle, dont la couverture est de 17 % et 10 % avec E5 sur un million de passages. Cette mesure est une estimation haute, car un passage peut contenir la réponse sans rapport avec la question.

5.3 Mesures et statistiques

La précision est la correspondance exacte (EM) et le score F1, avec la normalisation de Search-R1. Le coût est le nombre de recherches par question et le nombre de jetons générés. Nous donnons des intervalles de confiance à 95 % par bootstrap (Efron, 1979) (1 000 rééchantillonnages de questions) et comparons deux systèmes sur les mêmes questions par le test de McNemar (McNemar, 1947), avec une correction de Holm (Holm, 1979). Les règles de décision sont celles du tableau 3. Avec 100 questions par jeu, les intervalles font environ ±10 points.

Plan d'analyse fixé avant le run. Les quatre règles de décision (tableau 3) et le programme qui les applique ont été versionnés dans le dépôt public (commits `bd044e7` et `00bd108`, 9 novembre 2026 à 8 h 54) avant le lancement du run d'évaluation (commit `07c1fbb`, 9 h 17). Le programme a été testé sur des données fictives de même format, qui ne contiennent aucune question d'évaluation. L'historique git permet à chacun de vérifier que les tests n'ont pas été choisis après avoir vu les résultats.

5.4 Puissance de l'expérience

Avant tout run, nous avons estimé par simulation ce que l'expérience peut détecter (tableau 5). Le modèle de simulation suppose une EM de référence de 25 %, l'ordre de grandeur de la couverture de NQ, et des réponses corrélées entre systèmes par une difficulté commune à chaque question ; il est décrit dans `analysis/puissance.py`. Pour HA1, qui porte sur 200 questions avec six comparaisons, un vrai écart de 10 points n'a qu'environ 54 % de chances d'être déclaré significatif après correction de Holm, et un écart de 5 points 10 %. Avec 500 questions par jeu, comme prévu dans le mémoire, la puissance atteint 96 % pour un écart de 10 points. L'article ne peut donc conclure qu'à l'absence d'écarts *importants* ; un écart de quelques points passerait inaperçu. HA2, qui compare deux écarts mesurés chacun sur 100 questions, est la moins bien dotée.

	Écart réel 5 points		Écart réel 10 points		Écart réel 15 points	
Questions	5 %	Holm	5 %	Holm	5 %	Holm
100	13 %	3 %	42 %	19 %	81 %	56 %
200	28 %	10 %	79 %	54 %	99 %	95 %
500	65 %	35 %	99 %	96 %	100 %	100 %
1000	90 %	74 %	100 %	100 %	100 %	100 %

TABLE 5 – Puissance du test de McNemar apparié selon le nombre de questions et l'écart réel d'EM entre deux systèmes : part de 1 000 simulations où l'écart est déclaré significatif, au seuil de 5 % et au seuil le plus strict de la correction de Holm pour six comparaisons (5 %/6). EM de référence : 25 %. Ce tableau ne dépend d'aucune donnée observée.

6 Résultats

Le run d'évaluation a produit les 1 200 trajectoires attendues (100 questions, deux jeux, six systèmes), sans erreur ; les six systèmes ont traité exactement les mêmes questions. Il a duré 1 h 12 sur deux GPU T4 de Kaggle.

6.1 Vue d'ensemble

Le tableau 6 et la figure 4 donnent la précision des six systèmes. Sans recherche, le modèle répond juste à 15 % des questions de NQ et 29 % de celles de TriviaQA. Les harnais fixes n'améliorent ce score que sur TriviaQA, où le RAG simple atteint 40 % ; sur NQ, les trois harnais font *moins bien* que le modèle seul (10, 10 et 9 %). Les deux agents entraînés sont en tête sur les deux jeux : 23 et 22 % sur NQ, 47 et 53 % sur TriviaQA.

Dans notre échantillon, la recherche aide donc les agents entraînés partout, et les harnais seulement sur le jeu dont le corpus couvre le mieux les réponses (44 % contre 25 % pour NQ, section 5). Ce constat doit être lu avec deux précautions. Les intervalles de confiance des agents et du meilleur harnais se touchent sur chaque jeu pris seul : c'est le test apparié sur les 200 questions (section suivante) qui permet de conclure. Et la figure ne permet pas, à elle seule, d'attribuer l'écart à la règle de recherche, puisque les agents diffèrent aussi des harnais par les poids du modèle.

Deux comportements des harnais pèsent sur leur score. ReAct (A2) se termine sans réponse sur 18 questions sur 200, en épuisant son budget ou en produisant une action mal formée (par exemple une action « Decode » qui n'existe pas) ; IRCoT (A3) répond explicitement que les documents ne contiennent pas la réponse sur 30 questions sur 200, malgré la consigne de toujours répondre. Les agents entraînés ne s'abstiennent jamais.

	NQ (vu)			TriviaQA (non vu)		
Système	EM [IC 95 %]	F1	Rech.	EM [IC 95 %]	F1	Rech.
A0	0,15 [0,09 ; 0,22]	0,21	0,00	0,29 [0,21 ; 0,38]	0,36	0,00
A1	0,10 [0,05 ; 0,16]	0,16	1,00	0,40 [0,31 ; 0,50]	0,47	1,00
A2	0,10 [0,05 ; 0,16]	0,15	1,40	0,31 [0,22 ; 0,41]	0,39	1,42
A3	0,09 [0,04 ; 0,16]	0,13	3,09	0,36 [0,27 ; 0,46]	0,41	3,20
A4	0,23 [0,15 ; 0,31]	0,29	2,84	0,47 [0,38 ; 0,56]	0,57	2,92
A5	0,22 [0,15 ; 0,30]	0,30	1,79	0,53 [0,44 ; 0,63]	0,61	1,77

TABLE 6 – Correspondance exacte (EM) avec son intervalle de confiance bootstrap à 95 %, F1 et nombre moyen de recherches par question, 100 questions par jeu. Les agents entraînés sont sous le trait.

6.2 Tests des hypothèses

Le tableau 7 applique les règles de décision fixées avant le run (tableau 3).

HA1 (soutenue). Les six écarts entre agents entraînés et harnais sont positifs, de 10 à 17 points d'EM sur les 200 questions, et tous restent significatifs après correction de Holm ($p <$

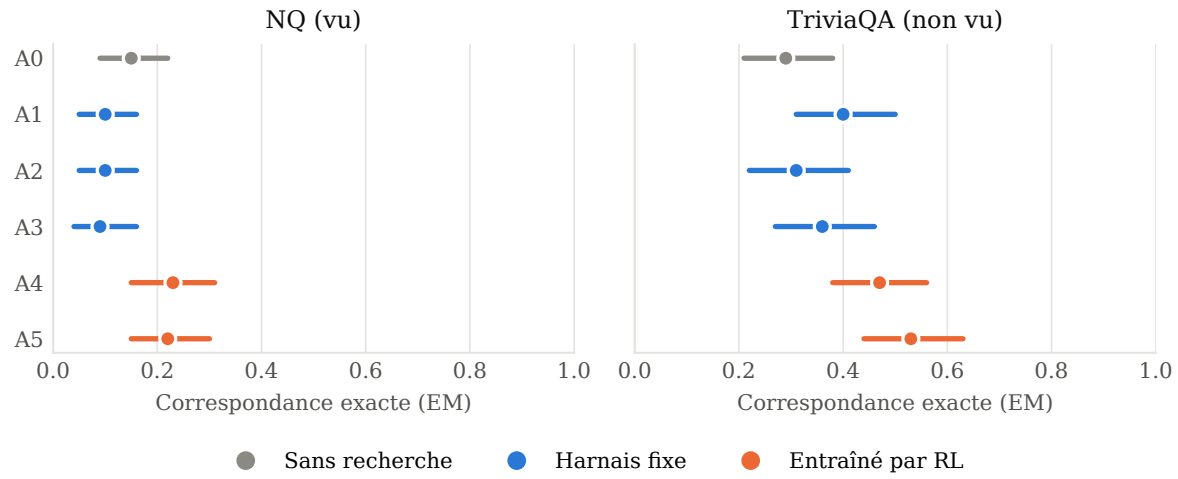


FIGURE 4 – Précision des six systèmes selon le jeu de questions. Données : run d'évaluation du 9 novembre 2026 sur Kaggle (version 4 du kernel). Une observation = une question traitée par un système ; effectif : 100 questions par jeu et par système, aucune écartée (les sorties sans réponse comptent comme fausses). Le point est l'EM moyen, le trait son intervalle bootstrap à 95 % (1 000 rééchantillonnages).

0,001). Ces écarts sont dans la zone où la simulation de la section 5 donnait une puissance d'au moins une chance sur deux : l'expérience pouvait les voir.

HA2 (non soutenue). L'avance des agents entraînés est de 12,8 points sur NQ, vu à l'entraînement, et de 14,3 points sur TriviaQA, non vu. La différence, −1,5 point, va à l'inverse de l'hypothèse, et son intervalle [−10,8 ; 7,3] contient zéro. L'avantage des agents ne se limite donc pas au jeu vu ; un écart modeste entre les deux jeux resterait toutefois indétectable avec 100 questions par jeu.

HA3a (soutenue). Les agents entraînés font en moyenne 0,92 recherche de plus par question que ReAct, avec un intervalle de [0,79 ; 1,05] sur 200 questions. Aucun des deux ne répond jamais sans chercher, alors que ReAct le fait sur 4 % des questions. La figure 5 nuance ce coût : A5 atteint une précision voisine de celle de A4, et meilleure sur TriviaQA, avec environ une recherche de moins par question que A4 et presque deux de moins que IRCoT.

HA3b (soutenue). Sur les 44 questions auxquelles A0 répond juste, l'écart avec ReAct reste de 0,74 recherche par question [0,48 ; 0,98]. Sur ces questions, ni les agents ni ReAct ne s'abstiennent de chercher.

Analyse exploratoire : ce que la recherche fait perdre. Cette analyse n'était pas prévue dans le plan d'analyse ; elle est rapportée comme exploratoire. Sur les 44 questions que le modèle résout sans chercher, les harnais se trompent après avoir cherché sur 18 (RAG), 23 (ReAct) et 24 (IRCoT) d'entre elles ; les agents entraînés sur 6 (A4) et 10 (A5). Les trajectoires montrent des harnais qui reprennent un passage voisin mais hors sujet. À la question de l'entrée du half-pipe à ski aux Jeux olympiques (2014), le RAG répond « 1998 », date tirée d'un passage sur le

Hyp.	Résultat du test	Verdict
HA1	Écarts d'EM RL − harnais, NQ et TriviaQA réunis (200 questions) : A4–A1 10,0 pt ($p_{\text{Holm}} < 0{,}001$) ; A4–A2 14,5 pt ($p_{\text{Holm}} < 0{,}001$) ; A4–A3 12,5 pt ($p_{\text{Holm}} < 0{,}001$) ; A5–A1 12,5 pt ($p_{\text{Holm}} < 0{,}001$) ; A5–A2 17,0 pt ($p_{\text{Holm}} < 0{,}001$) ; A5–A3 15,0 pt ($p_{\text{Holm}} < 0{,}001$). 6 paire(s) sur 6 positives et significatives.	soutenue
HA2	Écart RL − harnais : 12,8 pt sur NQ, 14,3 pt sur TriviaQA ; différence −1,5 pt [−10,8 ; 7,3].	non soutenue
HA3a	Recherches par question, RL − A2 : 0,92 [0,79 ; 1,05], 200 questions.	soutenue
HA3b	Même écart, questions où A0 répond juste : 0,74 [0,48 ; 0,98], 44 questions.	soutenue

TABLE 7 – Résultat des tests. Écarts d'EM en points de pourcentage, écarts de recherches en nombre de recherches par question ; entre crochets, intervalle bootstrap à 95 %.

snowboard ; à la question du lieu où sont absorbés la plupart des nutriments (« small intestine »), il répond « jejunum and ileum », repris d'un passage sur le duodénum. Le modèle seul répondait juste dans les deux cas. Le modèle Instruct semble faire davantage confiance aux passages qu'à ses propres connaissances, quand les agents entraînés gardent une bonne réponse malgré des passages qui ne la contiennent pas.

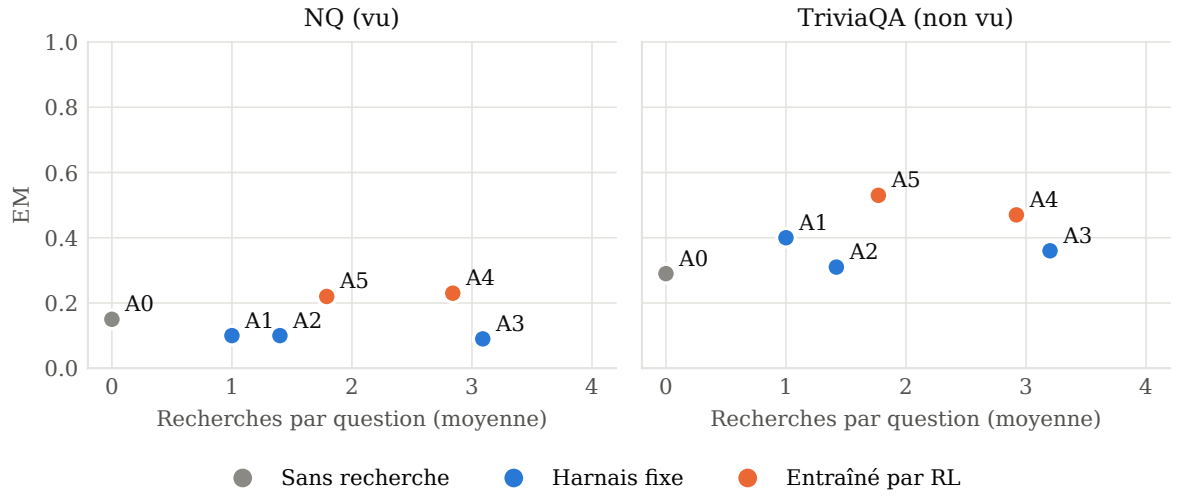


FIGURE 5 – Précision et coût. Chaque point est un système : en abscisse, le nombre moyen de recherches par question ; en ordonnée, l'EM. Mêmes données et mêmes effectifs que la figure 4. Un système placé plus haut et plus à gauche obtient plus avec moins de recherches.

7 Discussion

7.1 Rappel des résultats

À corpus, retriever, budget et questions identiques, les agents entraînés par renforcement répondent nettement mieux que les harnais fixes, sur le jeu vu comme sur le jeu non vu. Ils

ne doivent pas cet avantage à une recherche plus sobre : ils cherchent à chaque question, plus souvent que ReAct, y compris quand le modèle connaît déjà la réponse. Ce qui les distingue, c'est qu'une recherche les égare beaucoup moins.

7.2 Comparaison avec la littérature

Nos résultats confirment le sens du gain rapporté par les auteurs de Search-R1 (Jin et al., 2025b), cette fois face à des harnais qui partagent le corpus, le retriever et le budget de l'agent : le gain subsiste quand ces trois conditions sont communes, même si les poids du modèle, eux, diffèrent. Ils nuancent en revanche l'idée d'un avantage limité aux jeux d'entraînement. Un contrôleur appris sur HotpotQA perd en qualité de réponse sur MuSiQue (Raikote, 2026) ; ici, l'avance est aussi forte sur TriviaQA que sur NQ. Les deux jeux sont toutefois proches (questions factuelles à une étape) : notre « non vu » est un changement de distribution modeste. Sur le coût, nos agents confirment le constat de surrecherche (Wu et al., 2025 ; Tang et al., 2026) : ils ne se passent jamais de chercher. Enfin, les pertes des harnais rejoignent les travaux qui montrent qu'un modèle se laisse distraire par des passages non pertinents (Yoran et al., 2023) et que la recherche peut nuire sur ce que le modèle sait déjà (Mallen et al., 2023 ; Maekawa et al., 2024).

7.3 Explication

Le cadre du fourragement de l'information (section 3) distingue deux choses : décider s'il faut fourrager et quand s'arrêter, et tirer parti de ce que l'on trouve. Nos résultats séparent les deux. Sur la décision, le cadre rend compte de ce que l'on observe sans le distinguer des harnais : la récompense de Search-R1 ne fait payer aucune recherche, et les agents cherchent toujours, même quand le gain attendu est faible (HA3a, HA3b) ; mais ReAct, sur les questions que le modèle connaît, ne renonce pas davantage à chercher. La surrecherche n'est donc pas propre aux agents entraînés ; ils cherchent seulement plus. Leur avantage se situe ailleurs, du côté de l'exploitation : ce sont des fourrageurs qui ne choisissent pas mieux leurs parcelles, mais qui semblent mieux tirer parti de ce qu'ils y trouvent. Une lecture compatible avec nos données est que le renforcement, qui ne récompense que la bonne réponse finale, pénalise indirectement l'usage d'un passage trompeur ; le modèle Instruct, lui, reprend des passages voisins mais hors sujet alors même que son prompt l'autorise à s'en remettre à ses connaissances. Sur NQ, où le corpus ne contient la réponse que pour une question sur quatre, cette tendance coûte plus que la recherche ne rapporte. Nos données décrivent ce contraste ; elles n'en établissent pas la cause.

Explications concurrentes. Deux autres lectures sont possibles, et notre protocole ne permet pas de les écarter. La première tient au corpus : A4 et A5 ont été entraînés avec E5 sur Wikipédia 2018, la source de notre sous-corpus ; ils connaissent le format et le bruit de ces passages, ce que n'apprennent pas les harnais. La seconde tient au modèle : les agents partent du modèle de base, les harnais du modèle Instruct, dont l'ajustement aux consignes pourrait renforcer la déférence envers le contexte. Comparer A4 et A5 aux agents Search-R1 issus de la version Instruct, et faire varier le retriever (H4), permettra de départager ces lectures dans le mémoire.

7.4 Contributions

Théorique. L'étude sépare deux composantes que la littérature confond souvent sous « savoir chercher » : la décision de chercher, et l'usage de ce qui est trouvé. Dans nos conditions, les agents entraînés se distinguent par la seconde et non par la première, ce qui est compatible avec un cadre de fourragement où la récompense ignore le coût. La question « quand chercher ? » reste donc ouverte même pour les agents entraînés.

Pratique. Trois recommandations, chacune pour un acteur précis. L'équipe qui ajoute un moteur de recherche à un petit modèle Instruct devrait d'abord comparer, sur un échantillon de ses questions, le modèle seul et le modèle avec recherche : sur NQ, la recherche a fait baisser la précision de nos trois harnais. Celle qui dispose d'un agent Search-R1 public et d'un corpus encyclopédique proche de Wikipédia peut en attendre, dans des conditions comparables aux nôtres, un gain de précision pour environ une recherche de plus par question qu'un ReAct ; sur un autre corpus, ce gain reste à vérifier. Enfin, l'équipe qui entraîne un agent devrait ajouter un coût par recherche à sa récompense : sans lui, l'agent ne renonce jamais à chercher, même sur ce qu'il sait ; c'est l'hypothèse H3 du mémoire.

7.5 Limites et pistes

Ces limites valent quels que soient les résultats. Le tableau 8 les range selon le type de validité qu'elles menacent.

Causalité. Nous comparons des systèmes complets : aucun écart ne peut être attribué à un seul facteur. L'analyse des questions perdues après recherche, non prévue dans le plan, reste exploratoire.

Pistes. Deux hypothèses du mémoire ne sont pas testées ici : une pénalité par recherche dans la récompense réduit-elle le nombre d'appels sans perte forte de précision (entraînement GRPO à petite échelle), et un changement de retriever dégrade-t-il plus les agents entraînés que les harnais fixes ? Une analyse qualitative des échecs sur des trajectoires annotées compléterait la mesure : le mémoire prévoit d'en annoter 100 à la main et d'en faire classer 300 par un juge automatique, avec un accord mesuré par le kappa de Cohen.

Validité	Menace	Ce qui a été fait, ce qui reste
Interne	A0 à A3 utilisent Qwen2.5-3B-Instruct, A4 et A5 un modèle entraîné à partir de Qwen2.5-3B (base) : l'écart mélange règle de recherche et modèle.	Même famille, même taille, même budget. Les agents issus de la version Instruct permettront de séparer les deux dans le mémoire.
Interne	Les prompts de A2 et A3 ont été corrigés en mise au point.	Correction faite sur d'autres questions (graine 7), puis gel. A3 s'abstient explicitement sur 30 des 200 questions d'évaluation : il est probablement sous-estimé.
Construit	L'EM compte comme fausses des réponses justes formulées autrement.	F1 rapporté à côté de l'EM ; même normalisation que Search-R1 pour tous.
Construit	La connaissance préalable est mesurée par une seule réponse de A0, produite par le modèle Instruct.	Le mémoire prévoit huit échantillons par question (oracle de connaissance).
Statistique	100 questions par jeu, une graine : un vrai écart de 10 points n'a qu'environ 54 % de chances d'être détecté pour HA1.	Règles fixées d'avance, correction de Holm, intervalles rapportés. Une absence d'effet significatif ne prouve pas l'absence d'effet. Le mémoire passe à 500 questions par jeu.
Statistique	Décodage glouton : la répétabilité exacte de la génération entre deux machines n'est pas testée.	La recherche est rendue déterministe (ex aequo départagés) ; la génération reste à tester.
Externe	Corpus d'un million de passages : réponse dans les trois premiers passages pour 25 % (NQ) et 44 % (TriviaQA) des questions ; A4 et A5 ont été entraînés sur le corpus complet.	Couverture mesurée et rapportée. Le plafond de précision est bas pour tous les systèmes qui cherchent.
Externe	Deux jeux à une étape, en anglais, Wikipédia 2018, modèles de 3 milliards de paramètres.	Les jeux multi-étapes et d'autres retrievers sont prévus dans le mémoire (H4).

TABLE 8 – Menaces à la validité. Interne : l'écart vient-il bien de la règle de recherche ? Construit : mesure-t-on ce que l'on croit mesurer ? Statistique : l'échantillon permet-il de conclure ? Externe : le résultat vaut-il ailleurs ?

8 Conclusion

Nous avons comparé, à corpus, retriever, budget et questions identiques, deux agents de recherche entraînés par renforcement et quatre systèmes à règle fixe. Les agents entraînés répondent nettement mieux, sur le jeu vu comme sur le jeu non vu. Mais ils ne cherchent pas mieux au sens où on l'entend d'habitude : ils cherchent toujours, davantage que ReAct, y compris quand le modèle sait déjà répondre. Leur avantage tient à ce qu'une recherche les égare moins. Le cadre du fourragement de l'information rend compte des deux faits : sans coût dans la récompense, rien n'incite l'agent à s'arrêter ; une récompense sur la seule réponse finale peut, en revanche, l'avoir conduit à écarter l'information trompeuse, ce que nos données suggèrent sans l'établir. Ces conclusions valent pour un petit corpus, un petit modèle et deux jeux de questions proches. Le mémoire les mettra à l'épreuve sur sept jeux, en testant une pénalité par recherche (H3) et un changement de retriever (H4).

Déclaration d'usage de l'IA générative

Un assistant d'IA (Claude, Anthropic) a été utilisé à chaque étape : recherche documentaire par OpenAlex, écriture de tout le code (systèmes, statistiques, analyse, figures), premier jet de toutes les sections, mise en page LaTeX. L'auteur a fixé la question, les hypothèses et le protocole, validé chaque décision de méthode et chaque lancement, et relu le texte. Les références ont toutes été vérifiées dans OpenAlex ; les articles n'ont pas tous été lus en entier. Le carnet de bord joint détaille, étape par étape, ce que l'IA a fait, ce qui a été gardé, refait ou vérifié, et les erreurs de l'IA qui ont été rattrapées.

Disponibilité du code et des données

Le code, les consignes données aux modèles, les règles d'analyse et ce texte sont publics : `https://github.com/vqlentinn/memoire-rl-search`. Les questions (FlashRAG), le corpus (`maknee/wiki-18-subsets`) et les modèles sont publics sur Hugging Face. Les trajectoires produites ne sont pas versionnées dans le dépôt, mais se régénèrent avec `scripts/run_volet_a.py` sur un GPU gratuit ; l'article se régénère avec `scripts/rendu.sh`.

Références

Akari Asai, Zeqiu Wu, Yizhong Wang, et al. Self-RAG : Learning to Retrieve, Generate, and Critique through Self-Reflection, 2023. URL `https://arxiv.org/abs/2310.11511`.

Leif Azzopardi. The economics in interactive information retrieval. In *Proceedings of SIGIR*, 2011. doi : 10.1145/2009916.2009923.

Liuji Chen, Dianxing Tang, Xing Shi, et al. Learning When Not to Act : Mitigating Tool Abuse in Agentic Reinforcement Learning, 2026. URL `https://arxiv.org/abs/2606.02132`.

Mingyang Chen, Linzhuang Sun, Tianpeng Li, et al. ReSearch : Learning to Reason with Search for LLMs via Reinforcement Learning. In *Advances in Neural Information Processing Systems*, 2025. doi : 10.52202/085713-2858.

Bradley Efron. Bootstrap methods : Another look at the jackknife. *The Annals of Statistics*, 7 (1) :1–26, 1979. doi : 10.1214/aos/1176344552.

Daya Guo, Dejian Yang, Haowei Zhang, et al. DeepSeek-R1 incentivizes reasoning in LLMs through reinforcement learning. *Nature*, 2025. doi : 10.1038/s41586-025-09422-z.

Sture Holm. A simple sequentially rejective multiple test procedure. *Scandinavian Journal of Statistics*, 6(2) :65–70, 1979. doi : 10.2307/4615733.

Soyeong Jeong, Jinheon Baek, Sukmin Cho, Sung Ju Hwang, and Jong Park. Adaptive-RAG : Learning to Adapt Retrieval-Augmented Large Language Models through Question Complexity. In *Proceedings of NAACL-HLT*, 2024. doi : 10.18653/v1/2024.naacl-long.389.

Pengcheng Jiang, Xueqiang Xu, Jiacheng Lin, et al. s3 : You Don't Need That Much Data to Train a Search Agent via RL. In *Proceedings of EMNLP*, pages 21610–21628, 2025. doi : 10.18653/v1/2025.emnlp-main.1095.

Zhengbao Jiang, Frank F. Xu, Luyu Gao, et al. Active Retrieval Augmented Generation. In *Proceedings of EMNLP*, 2023. doi : 10.18653/v1/2023.emnlp-main.495.

Bowen Jin, Jinsung Yoon, Priyanka Kargupta, et al. An Empirical Study on Reinforcement Learning for Reasoning-Search Interleaved LLM Agents, 2025a. URL `https://arxiv.org/abs/2505.15117`.

Bowen Jin, Hansi Zeng, Zhenrui Yue, et al. Search-R1 : Training LLMs to Reason and Leverage Search Engines with Reinforcement Learning, 2025b. URL `https://arxiv.org/abs/2503.09516`.

Jiajie Jin, Yutao Zhu, Zhicheng Dou, et al. FlashRAG : A Modular Toolkit for Efficient Retrieval-Augmented Generation Research. In *Companion Proceedings of the ACM Web Conference (WWW)*, 2025c. doi : 10.1145/3701716.3715313.

Mandar Joshi, Eunsol Choi, Daniel S. Weld, and Luke Zettlemoyer. TriviaQA : A Large Scale Distantly Supervised Challenge Dataset for Reading Comprehension. In *Proceedings of ACL*, 2017. doi : 10.18653/v1/P17-1147.

Tom Kwiatkowski, Jennimaria Palomaki, Olivia Redfield, et al. Natural questions : A benchmark for question answering research. *Transactions of the Association for Computational Linguistics*, 7 :452–466, 2019. doi : 10.1162/tacl_a_00276.

Patrick Lewis, Ethan Perez, Aleksandra Piktus, et al. Retrieval-Augmented Generation for Knowledge-Intensive NLP Tasks, 2020. URL `https://arxiv.org/abs/2005.11401`.

Minhua Lin, Zongyu Wu, Zhichao Xu, et al. A Comprehensive Survey on Reinforcement Learning-based Agentic Search : Foundations, Roles, Optimizations, Evaluations, and Applications, 2025. URL `https://arxiv.org/abs/2510.16724`.

Tzu-Han Lin, Wei-Lin Chen, Chen-An Li, et al. AdaSearch : Balancing Parametric Knowledge and Search in Large Language Models via Reinforcement Learning. In *Proceedings of EMNLP*, 2026. doi : 10.18653/2026.emnlp-main.2696.

Nelson F. Liu, Kevin Lin, John Hewitt, et al. Lost in the Middle : How Language Models Use Long Contexts. *Transactions of the Association for Computational Linguistics*, 2024. doi : 10.1162/tacl_a_00638.

Seiji Maekawa, Hayate Iso, Sairam Gurajada, and Nikita Bhutani. Retrieval Helps or Hurts ? A Deeper Dive into the Efficacy of Retrieval Augmentation to Language Models. In *Proceedings of NAACL-HLT*, 2024. doi : 10.18653/v1/2024.naacl-long.308.

Alex Mallen, Akari Asai, Victor Zhong, et al. When Not to Trust Language Models : Investigating Effectiveness of Parametric and Non-Parametric Memories. In *Proceedings of ACL*, 2023. doi : 10.18653/v1/2023.acl-long.546.

Quinn McNemar. Note on the sampling error of the difference between correlated proportions or percentages. *Psychometrika*, 12(2) :153–157, 1947. doi : 10.1007/BF02295996.

Lang Mei, Zhihan Yang, Xiaohan Yu, et al. AI-SearchPlanner : Modular Agentic Search via Pareto-Optimal Multi-Objective Reinforcement Learning, 2025. URL `https://arxiv.org/abs/2508.20368`.

Viktor Moskvoretskii, Maria Marina, Mikhail Salnikov, et al. Adaptive Retrieval Without Self-Knowledge ? Bringing Uncertainty Back Home. In *Proceedings of ACL*, 2025. doi : 10.18653/v1/2025.acl-long.319.

Francesca Pezzuti, Ophir Frieder, Fabrizio Silvestri, Sean MacAvaney, and Nicola Tonellotto. How AI agents search. *PLoS ONE*, 21(10) :e0360157, 2026. doi : 10.1371/journal.pone.0360157.

Peter Pirolli and Stuart Card. Information foraging. *Psychological Review*, 106(4) :643–675, 1999. doi : 10.1037/0033-295X.106.4.643.

Biswas Poudel, Nilson Chapagain, Amit Kumar, and Xianshun Jiang. Reasoning-Search-Augmented LLMs : An Operational Taxonomy, Benchmark Analysis and Controlled Evidence Synthesis, 2026. URL `https://arxiv.org/abs/2610.29189`.

Hongjin Qian and Zheng Liu. Scent of Knowledge : Optimizing Search-Enhanced Reasoning with Information Foraging. In *Advances in Neural Information Processing Systems (NeurIPS)*, 2025. doi : 10.52202/085713-5204.

Qwen, An Yang, Baosong Yang, et al. Qwen2.5 Technical Report, 2024. URL `https://arxiv.org/abs/2412.15115`.

Pranav Raikote. Policy over Prompt : Reinforcement Learning for Agentic RAG. Mémoire déposé sur DiVA, urn :nbn :se :su :diva-256954, 2026.

Stephen E. Robertson and Hugo Zaragoza. The probabilistic relevance framework : BM25 and beyond. *Foundations and Trends in Information Retrieval*, 3(4) :333–389, 2009. doi : 10.1561/1500000019.

John Schulman, Filip Wolski, Prafulla Dhariwal, et al. Proximal Policy Optimization Algorithms, 2017. URL `https://arxiv.org/abs/1707.06347`.

Zeyang Sha, Shiwen Cui, and Weiqiang Wang. SEM : Reinforcement Learning for Search-Efficient Large Language Models, 2025. URL `https://arxiv.org/abs/2505.07903`.

Zhihong Shao, Peiyi Wang, Qihao Zhu, et al. DeepSeekMath : Pushing the Limits of Mathematical Reasoning in Open Language Models, 2024. URL `https://arxiv.org/abs/2402.03300`.

Huatong Song, Jinhao Jiang, Yingqian Min, et al. R1-Searcher : Incentivizing the Search Capability in LLMs via Reinforcement Learning, 2025. URL `https://arxiv.org/abs/2503.05592`.

George J. Stigler. The economics of information. *Journal of Political Economy*, 69(3) :213–225, 1961. doi : 10.1086/258464.

Hao Sun, Zile Qiao, Jiayan Guo, et al. ZeroSearch : Incentivize the Search Capability of LLMs without Searching, 2025. URL https://arxiv.org/abs/2505.04588.

Jianan Sun, Miao Zhang, Chen Chen, et al. AdaRAG : Budget-Aware Adaptive Retrieval-Augmented Generation via Hierarchical Reinforcement Learning. In *IEEE International Conference on Joint Cloud Computing (JCC)*, 2026a. doi : 10.1109/jcc72984.2026.00024.

Minhao Sun, Zhijing Wu, and Xian-Ling Mao. Search When Needed, Proceed When Reliable : Metacognitive Reliability Supervision for Efficient Agentic Search, 2026b. URL https://arxiv.org/abs/2610.41738.

Yunbo Tang, Chengyi Yang, Shiyu Liu, et al. SAAS : Self-Aware Reinforcement Learning for Over-Search Mitigation in Agentic Search, 2026. URL https://arxiv.org/abs/2605.29796.

Harsh Trivedi, Niranjan Balasubramanian, Tushar Khot, and Ashish Sabharwal. Interleaving Retrieval with Chain-of-Thought Reasoning for Knowledge-Intensive Multi-Step Questions. In *Proceedings of ACL*, 2023. doi : 10.18653/v1/2023.acl-long.557.

Hongru Wang, Cheng Qian, Wanjun Zhong, et al. Acting Less is Reasoning More ! Teaching Model to Act Efficiently, 2025. URL https://arxiv.org/abs/2504.14870.

Liang Wang, Nan Yang, Xiaolong Huang, et al. Text Embeddings by Weakly-Supervised Contrastive Pre-training, 2022. URL https://arxiv.org/abs/2212.03533.

Peilin Wu, Mian Zhang, Xinlu Zhang, Xinya Du, and Zhiyu Chen. Search Wisely : Mitigating Sub-optimal Agentic Searches By Reducing Uncertainty. In *Proceedings of EMNLP*, pages 19734–19745, 2025. doi : 10.18653/v1/2025.emnlp-main.998.

Shunyu Yao, Jeffrey Zhao, Dian Yu, et al. ReAct : Synergizing Reasoning and Acting in Language Models, 2022. URL https://arxiv.org/abs/2210.03629.

Zhangyue Yin, Qiushi Sun, Qipeng Guo, et al. Do Large Language Models Know What They Don't Know ? In *Findings of ACL*, 2023. doi : 10.18653/v1/2023.findings-acl.551.

Ori Yoran, Tomer Wolfson, Ori Ram, et al. Making Retrieval-Augmented Language Models Robust to Irrelevant Context, 2023. URL https://arxiv.org/abs/2310.01558.

Wenlin Zhang, Kuicai Dong, Junyi Li, et al. To Search or Not to Search : Aligning the Decision Boundary of Deep Search Agents via Causal Intervention. In *Proceedings of the ACM Web Conference (WWW)*, 2026. doi : 10.1145/3774904.3792235.

Shu Zhao, Tan Yu, Anbang Xu, et al. ParallelSearch : Train your LLMs to Decompose Query and Search Sub-queries in Parallel with Reinforcement Learning, 2025. URL https://arxiv.org/abs/2508.09303.

Yibo Zhao, Zichen Ding, Jiayi Wu, Zun Wang, and Xiang Li. Retrieval, Reward, and Training Protocols : What Matters in Training Search Agents ?, 2026. URL https://arxiv.org/abs/2605.27881.

Yuxiang Zheng, Dayuan Fu, Xiangkun Hu, et al. DeepResearcher : Scaling Deep Research via Reinforcement Learning in Real-world Environments. In *Proceedings of EMNLP*, 2025. doi : 10.18653/v1/2025.emnlp-main.22.

A Méthode de la recherche documentaire

La recherche a suivi la feuille de route de l'étape 5.2 de la trame : question en trois blocs, articles témoins, équation par blocs, mesure de la précision sur un tirage aléatoire de 20 résultats, boule de neige, vérification des références. Les requêtes ont été lancées par un agent d'IA (Claude) connecté à OpenAlex, les 3 et 9 novembre 2026. Les cinq articles témoins sont Search-R1, R1-Searcher, ReAct, IRCoT et Self-RAG.

N°	Requête	Nombre	Résultat et décision
1	Renforcement ET recherche agentique ET modèles de langage, depuis 2022	1 036	Précision 7/20 (bruit : réseaux 6G, médecine). Ajout d'un bloc « tâche ».
2	Bloc 1 ET questions-réponses (multi-sauts, à forte intensité de connaissances)	336	Précision inchangée (7/20) : bruit multimodal, télédétection. Termes trop larges retirés, exclusions ajoutées.
3	Équation retenue (OQL ci-dessous), depuis 2023	103	Précision environ 15/20.
4	Vérification des 91 références du corpus de départ	91	91 exactes, aucune rétractée.
5	Consensus, question en version fermée	10	Tous favorables au RL ; biais de publication probable. 4 candidats ajoutés.
6	Boule de neige : articles citant Search-R1	14	OpenAlex ne rattache que 14 citations à la notice arXiv : peu exploitable.
9	Équation 3 réécrite depuis le journal	116	L'équation exacte de la ligne 3 n'avait pas été conservée ; l'OQL est désormais noté.
10	Rappel sur les cinq témoins	116	1 sur 5 : les harnais fixes sont hors du bloc RL ; R1-Searcher n'emploie pas les mots de la tâche.
11	Tri des 116 titres	116	4 inclus, 58 doutes, 38 exclus proposés ; non relu à ce jour.
12	Requête sémantique : comparaison d'agents RL et de harnais à conditions identiques	50	Zhao et al. (2026) et Pezzuti et al. (2026), absents de l'équation, ajoutés.
14	Texte intégral : « information foraging » ET agents de recherche	58	Dans 4 PDF sur 5, le terme vient d'une seule référence (InForage) : cadre retenu.
15	Texte intégral : modèles économiques ou rationalité limitée ET agents	57	Aucune mention de Stigler ni de Simon dans 10 PDF : Simon retiré.

N°	Requête	Nombre	Résultat et décision
17	Vérification finale des références de l'article	46	43 exactes par titre, 3 exactes par DOI arXiv ; 6 passées à leur version publiée. Zéro référence introuvable.
18	Lecture des résumés des 58 doutes de l'équation 3	58	11 inclus, 44 exclus (E1, E3), 3 tranchés ensuite.
19	Vérification des 5 références ajoutées après la sélection finale	5	5 exactes par DOI.

Équation 3, en OQL :

```
works where title-abstract-keywords has (("reinforcement learning" or GRPO or RLVR) and ("search
↪ agent" or "agentic search" or "search-augmented" or "search engine" or "adaptive retrieval"
↪ or "retrieval-augmented reasoning") and ("question answering" or "multi-hop" or HotpotQA or
↪ "Natural Questions") and (LLM or "language model") and not (multimodal or "visual question"
↪ or "remote sensing" or network)) and published since 2023
```

Compte rendu de sélection. Revue narrative : la trame n'exige qu'une décision Inclus / Exclu, mais nous donnons les effectifs à chaque étape. La décision finale a été prise par l'assistant d'IA, à la demande de l'auteur, avec des règles écrites dans `scripts/selection_corpus.py` et rejouables.

Étape	Articles
Corpus de départ (collecte thématique, arXiv)	91
retenus par R1	32
repêchés par R2 (cités dans l'article)	9
hors revue : algorithmes, modèles, jeux de données, évaluation (références de méthode)	20
non retenus : priorité « contexte », ou « utile » hors thème du coût	30
Candidats OpenAlex et Consensus	32
inclus (R3)	5
exclus E1 : 26, E2 : 1	27
Résultats de l'équation 3	116
déjà présents dans les listes précédentes	16
inclus (R3)	17
exclus E1 : 62, E3 : 6, E4 : 15	83
Articles cités venus d'autres requêtes (sémantique, texte intégral)	12
Inclus avant fusion des doublons entre sources	75
doublons fusionnés (même article trouvé par plusieurs voies)	10
Corpus final de la revue	65
dont cités dans l'article	38

Règles d'inclusion : R1, articles « essentiels » du corpus de départ sur les agents entraînés, les harnais fixes, la décision de chercher, le retriever et le bruit, plus les articles « essentiels » et « utiles » sur le coût ; R2, tout article cité dans la revue ; R3, nouveaux candidats portant sur la décision de chercher, le coût, la comparaison à un harnais fixe, le retriever ou l'usage de l'information trouvée. La liste est dans `docs/litterature/corpus_final.csv`.

B Consignes données aux modèles

Les consignes sont en anglais, langue des questions. Celle de Search-R1 est reprise du dépôt officiel (licence Apache 2.0) ; les autres ont été écrites pour ce projet ; celles de A2 et A3 ont été corrigées une fois pendant la mise au point, avant toute question d'évaluation. Les accolades marquent ce que le programme remplace.

A1, RAG.

```
Answer the question. The documents below were retrieved for it: use them if they are useful,
↪  otherwise rely on your own knowledge. Give only the final answer inside <answer> and
↪  </answer>, without explanation. For example, <answer> Beijing </answer>.

{docs}
Question: {question}
```

A2, ReAct (consigne seule ; suivent deux exemples résolus, puis la question).

```
Solve the question by interleaving Thought, Action and Observation steps. Thought reasons
↪  about the current situation. Action is one of two types:
(1) Search[query]: search for the query; the top passages come back as the Observation.
(2) Finish[answer]: return the final answer and finish.
Write one Thought and one Action at a time, then stop and wait for the Observation. Give the
↪  final answer as soon as you have enough information. Never repeat a search query. If the
↪  passages do not help after a few searches, rely on your own knowledge and give your best
↪  answer with Finish[answer]. Start your reply with "Thought:".
```

A4 et A5, Search-R1.

```
Answer the given question. You must conduct reasoning inside <think> and </think> first every
↪  time you get new information. After reasoning, if you find you lack some knowledge, you
↪  can call a search engine by <search> query </search> and it will return the top searched
↪  results between <information> and </information>. You can search as many times as your
↪  want. If you find no further external knowledge needed, you can directly provide the answer
↪  inside <answer> and </answer>, without detailed illustrations. For example, <answer>
↪  Beijing </answer>. Question: {question}
```

Les consignes de A0 (réponse directe) et de A3 (IRCoT) sont dans le dossier `prompts/` du dépôt.

C Fiche données

Rubrique	Contenu
Source : questions	Existante. FlashRAG (Hugging Face, `RUC-NLPIR/FlashRAG_datasets`), configurations `nq` et `triviaqa`, partie `test` : 3 610 et 11 313 questions.
Source : corpus	Existante. `maknee/wiki-18-subsets`, sous-corpus d'un million de passages et son index E5. Jeu tiers sans fiche descriptive : l'alignement entre index et corpus a été vérifié (similarité minimale 0,9997 sur 50 passages).
Source : modèles	`Qwen/Qwen2.5-3B-Instruct` (A0 à A3) ; points de contrôle Search-R1 v0.3, PPO (A4) et GRPO (A5), entraînés sur NQ et HotpotQA.

Rubrique	Contenu
Source : trajectoires	Produites par ce projet sur Kaggle (GPU T4).
Une ligne	Une question traitée par un système : 100 questions × 2 jeux × 6 systèmes, soit 1 200 lignes.
Échantillon	100 questions par jeu tirées avec la graine 42. Mise au point sur un autre tirage (graine 7), sans aucune question d'évaluation.
Qui manque	Questions multi-étapes (HotpotQA, MuSiQue), écartées faute de couverture ; faits postérieurs à 2018 ; langues autres que l'anglais.
Modifications	Aucune question retirée. Seul ajout : « ? » en fin de question s'il manque, comme Search-R1.
Droits	Licences de FlashRAG, du sous-corpus, de Qwen2.5 et des points de contrôle Search-R1 : à vérifier avant diffusion des données.