Chercher ou répondre ?
Agents de recherche entraînés par renforcement et harnais fixes : une comparaison à corpus et questions identiques

Valentin Proux

Premier rendu, 9 novembre 2026

Version de démonstration : tous les résultats chiffrés sont fictifs

Données fictives. Les runs sur GPU n'ont pas encore été faits. Les chiffres des sections 6 à 8 et du résumé viennent de données fabriquées par `analysis/donnees_fictives.py` (paramètres choisis à la main, graine 2026), au format exact des vrais fichiers. Ils servent à tester la chaîne d'analyse et la mise en page ; ils ne disent rien des systèmes étudiés. Le texte qui les commente est un exemple de rédaction, à réécrire avec les vrais résultats.

Résumé

Pour répondre à une question factuelle, un modèle de langage peut interroger un moteur de recherche selon une règle fixée par le programmeur, comme la génération augmentée par la recherche (RAG), ReAct ou IRCoT, ou selon une politique apprise par renforcement, comme Search-R1. Or les gains attribués à cet apprentissage sont mesurés par les auteurs des méthodes, contre des lignes de base qui ne partagent ni le corpus, ni le moteur, ni le budget de recherche. Cette étude compare six systèmes fondés sur Qwen2.5-3B dans des conditions identiques, sur 100 questions de Natural Questions (NQ), vu à l'entraînement des agents, et 100 de TriviaQA, non vu. Elle montre[fictif] que l'apprentissage change davantage le coût que la précision. Sur NQ, le meilleur agent entraîné a atteint 25 % de correspondance exacte (EM), contre 20 % pour le meilleur harnais ; aucune des six comparaisons n'a été significative, et l'écart n'a pas été plus fort sur le jeu vu. Les agents entraînés ont en revanche lancé 0,63 recherche de plus par question que ReAct, et 1,23 de plus sur les questions que le modèle savait déjà résoudre sans chercher. Lu avec la théorie du fourragement de l'information, ce résultat suggère qu'une récompense qui ignore le coût d'une recherche produit des agents qui cherchent par défaut, et plaide pour intégrer ce coût à l'entraînement.

Mots-clés : Search-R1 ; génération augmentée par la recherche ; surrecherche ; fourragement de l'information ; évaluation contrôlée ; questions-réponses.

Résumé

Language models answer factual questions better when they can query a search engine. The decision to search can follow a fixed rule (retrieval-augmented generation, ReAct, IRCoT) or a policy learned by reinforcement learning, as in Search-R1. Yet the reported gains of learned policies come from method authors, measured against baselines that do not share the corpus, retriever or search budget. We compare six systems built on Qwen2.5-3B under identical conditions, on 100 Natural Questions (seen in training) and 100 TriviaQA questions

DONNÉES FICTIVES

(unseen). Learning changes cost more than accuracy[fictif]. On Natural Questions, the best trained agent reached 25% exact match against 20% for the best fixed pipeline; none of the six pairwise differences was significant, and the gap was not larger on the seen dataset. The trained agents issued 0.63 more searches per question than ReAct, and 1.23 more on questions the model already answered correctly without search. Read through information foraging theory, this suggests that rewards blind to search cost yield agents that search by default.

Keywords: Search-R1; retrieval-augmented generation; over-searching; information foraging; controlled evaluation; question answering.

1 Introduction

Un modèle de langage ne sait pas tout, et ne sait pas toujours ce qu'il ne sait pas. Pour répondre à une question factuelle rare, récente ou composée de plusieurs étapes, on lui donne donc accès à un moteur de recherche (Lewis et al., 2020). Ce couplage déplace la difficulté : il faut décider *quand* chercher et *quoi* chercher. Trois grandeurs en dépendent, que cet article suit tout du long : la décision de recherche elle-même, la *précision* de la réponse et le *coût* engagé, compté en recherches par question.

Ce problème n'est pas qu'académique. Chaque recherche ajoute de la latence, des jetons à lire et du calcul ; chercher trop peu fait répondre de mémoire, au risque de se tromper (Mallen et al., 2023). Les agents actuels penchent nettement du côté de l'excès : Wu et al. (2025) estiment que Search-R1 aurait pu éviter 27,7 % de ses étapes de recherche, et Pezzuti et al. (2026) observent jusqu'à 186 appels pour une seule requête. Pour une équipe qui ne dispose que d'un GPU gratuit, comme pour un service qui répond à des millions de questions, la règle qui décide de chercher fixe à la fois la qualité et la facture.

Deux familles de solutions coexistent. Dans la première, le *harnais* est fixé par le programmeur : on cherche toujours une fois avant de répondre (Lewis et al., 2020), on fait alterner pensée, action et observation guidées par un prompt (Yao et al., 2022), ou l'on cherche après chaque phrase de raisonnement (Trivedi et al., 2023). Dans la seconde, le modèle *apprend* par renforcement, avec une récompense portant sur la réponse finale, quand et quoi chercher (Jin et al., 2025b ; Song et al., 2025 ; Chen et al., 2025). Les auteurs de Search-R1 rapportent ainsi, avec Qwen2.5-3B, un gain de 20 % sur diverses lignes de base RAG (Jin et al., 2025b). Mais ces gains sont mesurés par les auteurs de chaque méthode, contre des lignes de base qu'ils choisissent, souvent sur les jeux de questions vus à l'entraînement ; Zhao et al. (2026) font le même constat pour les méthodes d'entraînement, dont la croissance a dépassé celle des comparaisons contrôlées. Dans le corpus que nous avons réuni, nous n'avons pas repéré de comparaison d'un agent entraîné avec les harnais fixes usuels à corpus, retriever, budget et questions identiques. Ce constat vaut pour notre recherche documentaire, dont la méthode est donnée en annexe A : il ne prouve pas qu'une telle étude n'existe pas. On ne sait donc pas si l'avantage rapporté vient de l'apprentissage de la décision de chercher, ou des autres différences entre systèmes.

Cette étude compare, dans des conditions identiques, deux agents Search-R1 entraînés par renforcement (PPO et GRPO) et quatre systèmes à règle fixe, de la réponse sans recherche à IRCoT, tous fondés sur des modèles Qwen2.5 de 3 milliards de paramètres. Elle mesure la

DONNÉES FICTIVES

précision et le coût sur un jeu de questions vu à l'entraînement des agents (Natural Questions) et sur un jeu non vu (TriviaQA), et lit les résultats avec la théorie du fourragement de l'information (Pirolli and Card, 1999), qui fait de la décision de chercher un arbitrage entre gain espéré et coût. Elle répond à la question suivante : *à corpus et questions identiques, un agent de recherche entraîné par renforcement décide-t-il mieux quand et quoi chercher qu'un harnais fixe, et à quel coût ?* C'est la partie à petite échelle d'un projet de mémoire plus large, dont deux hypothèses sont testées ici et deux sont présentées comme prolongements.

L'étude apporte trois éléments. D'abord, une comparaison contrôlée qui isole la règle de recherche : seuls la règle et, pour les agents, les poids du modèle changent d'un système à l'autre. Ensuite, une mesure qui sépare la précision du coût, et qui teste si les agents entraînés cherchent encore quand le modèle connaît déjà la réponse : c'est ce que prédit un cadre où la récompense ignore le coût d'une recherche. Enfin, un protocole reproductible sans budget : code public, GPU gratuits, règles de décision fixées avant les runs et analyse de puissance qui dit, avant de les lancer, quels écarts l'expérience peut voir.

2 Revue de la littérature

2.1 Démarche

Cette revue est narrative : le champ est jeune, fait surtout de préprints de 2025 et 2026, et le but est de construire le raisonnement qui mène à notre question plutôt que d'estimer un effet moyen. La recherche documentaire a utilisé OpenAlex et Consensus par l'intermédiaire d'un agent d'IA, les 3 et 9 novembre 2026. L'équation retenue croise le renforcement, la recherche agentique, la tâche de questions-réponses et les modèles de langage, depuis 2023 ; elle a été corrigée deux fois après mesure de sa précision sur 20 résultats tirés au hasard, de 35 % à environ 75 %. Elle ne retrouve qu'un article témoin sur cinq, car trois témoins sont des harnais fixes, hors du bloc « renforcement » : ces articles, et ceux qu'une requête sémantique a ajoutés, viennent d'une première collecte thématique. Les 46 références citées ont été vérifiées dans OpenAlex. L'annexe A donne les équations, les volumes et les décisions. Les textes n'ont pas tous été lus en entier : ce que nous rapportons des études les plus récentes vient de leur résumé, sauf mention contraire.

2.2 Harnais fixes

La génération augmentée par la recherche (RAG) combine la mémoire du modèle et un index de documents (Lewis et al., 2020). Ses variantes itératives ajoutent des recherches en cours de raisonnement : ReAct fait alterner raisonnement et actions d'outil (Yao et al., 2022), IRCoT entrelace recherche et chaîne de pensée (Trivedi et al., 2023). D'autres travaux apprennent à décider *si* il faut chercher, par un classifieur de complexité de la question (Jeong et al., 2024), par l'incertitude de la génération (Jiang et al., 2023 ; Moskvoretskii et al., 2025) ou par la réflexion du modèle sur lui-même (Asai et al., 2023). Cette littérature part d'un constat : chercher n'aide pas toujours, et l'intérêt de la recherche dépend de ce que le modèle sait déjà (Mallen et al., 2023 ; Yin et al., 2023).

DONNÉES FICTIVES

2.3 Agents de recherche entraînés par renforcement

L'apprentissage par renforcement promet de remplacer la règle écrite à la main par une politique optimisée sur le résultat. Search-R1 en est la forme la plus simple : le modèle insère des requêtes dans son raisonnement, et seule la justesse de la réponse finale est récompensée (Jin et al., 2025b). Ce principe s'est vite décliné : R1-Searcher et ReSearch varient la récompense et les données (Song et al., 2025 ; Chen et al., 2025), DeepResearcher place l'agent sur le web réel (Zheng et al., 2025), ZeroSearch remplace le moteur par un moteur simulé (Sun et al., 2025). Tous reposent sur PPO (Schulman et al., 2017) ou GRPO (Shao et al., 2024), popularisés pour le raisonnement par DeepSeek-R1 (Guo et al., 2025), et une synthèse récente organise ce champ (Lin et al., 2025).

Ce que l'agent apprend reste pourtant mal connu. Les auteurs de Search-R1 montrent eux-mêmes que les récompenses intermédiaires sur la recherche changent peu de chose, mais que le choix du moteur pèse sur l'entraînement et sur la robustesse (Jin et al., 2025a) : la politique apprise dépend de l'environnement dans lequel elle a été apprise. C'est la raison pour laquelle nous distinguons un jeu vu d'un jeu non vu.

2.4 Coût des recherches

La recherche a longtemps été évaluée à son seul bénéfice ; elle est désormais vue comme un coût à maîtriser. Le constat de départ est que les agents entraînés cherchent trop : la surrecherche est maintenant définie et mesurée, et Search-R1 aurait pu éviter 27,7 % de ses étapes (Wu et al., 2025). Les réponses proposées vont toutes dans le même sens, réintroduire le coût dans l'apprentissage : réduire les actions inutiles (Wang et al., 2025), paralléliser les sous-requêtes pour réduire les appels (Zhao et al., 2025), optimiser conjointement utilité et coût (Mei et al., 2025), ou équilibrer connaissances du modèle et recherche (Lin et al., 2026).

Mais réintroduire le coût n'est pas trivial. SAAS constate qu'une pénalité naïve par recherche réduit les appels au prix de la précision, et propose une pénalité ciblée sur les recherches que le modèle aurait pu éviter (Tang et al., 2026). L'arbitrage entre précision et coût est donc au cœur du champ ; il reste rarement mesuré face aux harnais fixes, qui ont pourtant un coût connu d'avance. C'est l'objet de nos hypothèses HA3a et HA3b, et de l'hypothèse H3 du mémoire.

2.5 Retriever et bruit

Le retriever compte : BM25 (Robertson and Zaragoza, 2009) est lexical, E5 (Wang et al., 2022) est dense ; Search-R1 est entraîné avec E5. Des modèles se laissent distraire par des passages non pertinents (Yoran et al., 2023) ou ignorent les informations placées au milieu d'un long contexte (Liu et al., 2024). Ces effets limitent ce que l'on peut attendre d'une recherche réussie. Zhao et al. (2026) signalent en outre un défaut de couverture du corpus Wikipédia 2018, dont la correction apporte plus que l'écart entre algorithmes d'entraînement : ce résultat, tiré du résumé, rend d'autant plus nécessaire notre mesure de couverture (section 5).

DONNÉES FICTIVES

2.6 Lacune

Les articles ci-dessus évaluent souvent leur méthode contre des lignes de base choisies par leurs auteurs. Trois travaux s'approchent de notre question. Zhao et al. (2026) comparent de façon contrôlée des méthodes d'entraînement entre elles, et non des agents entraînés à des harnais fixes. Raikote (2026) oppose un contrôleur appris à des règles fixes, mais avec un modèle gelé. s3 entraîne un chercheur séparé contre le RAG naïf (Jiang et al., 2025). La question de savoir si le gain vient de l'*apprentissage de la décision de chercher* ou d'autres différences (modèle, prompt, retriever, jeux vus à l'entraînement) nous paraît donc encore peu isolée, sous réserve de la lecture complète de ces travaux. C'est ce que le protocole de la section 5 vise à réduire.

3 Cadre théorique

Nous lisons la décision de chercher avec la théorie du fourragement de l'information (*information foraging*) de Pirolli and Card (1999). Elle transpose à la recherche d'information le raisonnement de l'écologie : un organisme exploite une parcelle tant que ce qu'elle rapporte justifie l'effort, puis passe à autre chose. Pour décider, il s'appuie sur des indices imparfaits de la valeur de ce qu'il va trouver, la *senteur de l'information*. L'idée que chercher a un coût, et qu'il faut s'arrêter quand le gain d'une recherche de plus ne le couvre plus, remonte à l'économie de l'information de Stigler (1961) ; la recherche d'information l'a reprise sous forme de modèles économiques de la recherche (Azzopardi, 2011).

Ce cadre explique le mécanisme que nous étudions et il est déjà mobilisé dans le champ : InForage s'en réclame explicitement pour formaliser le raisonnement augmenté par la recherche (Qian and Liu, 2025). Des travaux récents emploient le même vocabulaire sans toujours citer la théorie : le gain marginal de chaque recherche décroît avec les tours (Zhang et al., 2026), et il est proposé de traiter la recherche comme une acquisition d'informations sous budget (Poudel et al., 2026).

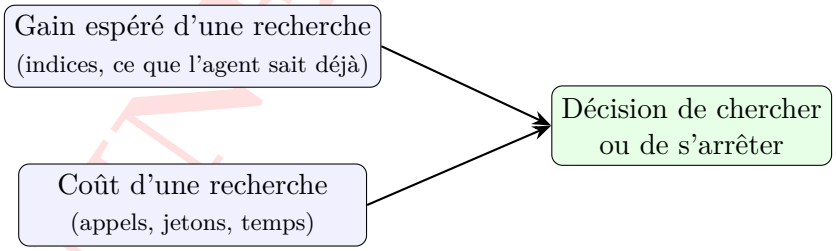


FIGURE 1 – Le cadre, d'après Pirolli and Card (1999) et Stigler (1961), simplifié. Lecture : l'agent cherche tant que le gain espéré d'une recherche de plus dépasse ce qu'elle lui coûte.

Transposé à nos systèmes, ce cadre oppose deux questions : qui estime le gain, et quel coût est pris en compte (tableau 1). Dans les harnais fixes, la règle est écrite d'avance ou confiée à un prompt. Dans A4 et A5, elle est apprise avec une récompense qui porte sur la réponse finale (Jin et al., 2025b) : l'agent a pu apprendre à estimer le gain, mais rien ne lui fait payer une recherche.

Il en découle trois attentes. Un agent qui estime le gain devrait mieux répartir ses recherches qu'une règle fixe. Cette estimation, apprise sur certains jeux de questions, devrait perdre en

DONNÉES FICTIVES

Système	Estimation du gain	Coût d'une recherche pris en compte
A0	Aucune : jamais de recherche	Sans objet
A1	Aucune : une recherche, toujours	Aucun : règle fixe
A2	Par le modèle, guidé par le prompt	Implicite : consigne de répondre dès que possible
A3	Aucune : une recherche par phrase	Aucun : règle fixe, dans la limite du budget
A4, A5	Apprise par renforcement	Aucun dans la récompense

TABLE 1 – Les systèmes lus avec le cadre. Tous partagent le même budget de quatre recherches.

fiabilité ailleurs. Enfin, sans coût perçu, l'agent devrait continuer à chercher même quand le gain attendu est faible.

Limites du choix. La théorie décrit des humains : l'appliquer à un modèle de langage est une analogie, qui suit celle d'InForage. Elle suppose aussi un agent qui compare gain et coût, alors que nous n'observons que ses actions. Nous la mobilisons pour expliquer ces actions, sans affirmer que le modèle raisonne ainsi. Nous n'avons pas eu accès au texte de Pirolli and Card (1999) : notre présentation s'appuie sur ce qu'en rapportent Qian and Liu (2025). L'adéquation de ce cadre reste à valider avec la direction du mémoire.

4 Modèle conceptuel et hypothèses

4.1 Modèle

Le modèle (figure 2) traduit le cadre en cinq variables observables (tableau 2). La variable explicative est le *mode de décision de recherche* : harnais fixe ou agent entraîné. Il a deux variables expliquées : la *précision*, et le *nombre de recherches par question*, qui mesure le coût. Deux modérateurs changent la force de ces effets : la *familiarité du jeu de questions*, vu ou non vu à l'entraînement, et la *connaissance préalable* de la réponse. Le schéma montre aussi, en pointillé, les deux variables du projet de mémoire que la mini-expérience ne manipule pas : la *pénalité par recherche* dans la récompense (H3), justifiée par SAAS (Tang et al., 2026), et le *retriever* (H4), justifié par l'effet du moteur sur la robustesse de l'agent (Jin et al., 2025a). Elles sont gardées pour montrer où se place l'article dans le projet d'ensemble ; elles ne donnent lieu à aucun test ici.

Dans la théorie	Dans le modèle
Qui estime le gain, et comment	Mode de décision de recherche : variable explicative
Fiabilité des indices selon l'environnement	Familiarité du jeu de questions : modérateur
Gain réel d'une recherche	Connaissance préalable de la réponse : modérateur
Valeur obtenue	Précision : variable expliquée
Coût engagé	Nombre de recherches par question : variable expliquée

TABLE 2 – Du cadre théorique au modèle.

DONNÉES FICTIVES

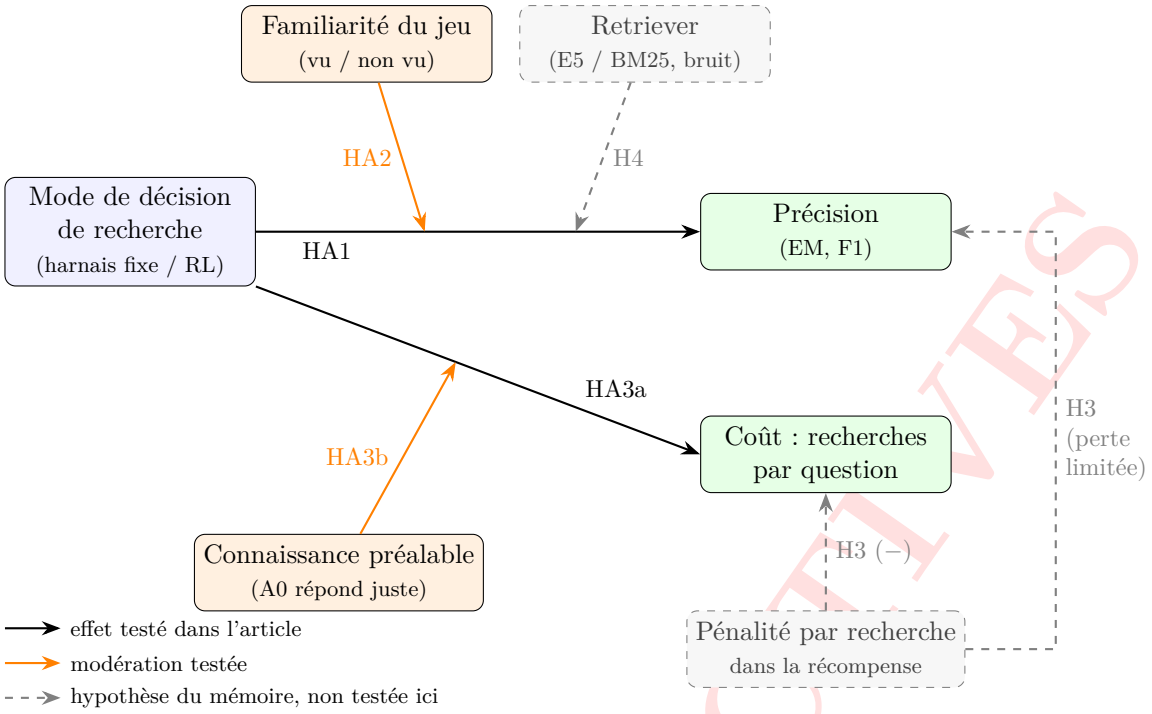


FIGURE 2 – Modèle conceptuel complet. Lecture : le mode de décision influence la précision (HA1) et le nombre de recherches (HA3a). Les flèches orange pointent sur une flèche : elles en changent la force. L'effet sur la précision dépend de la familiarité du jeu (HA2), l'effet sur le coût dépend de ce que le modèle sait déjà (HA3b). En pointillé, les deux hypothèses du mémoire que la mini-expérience ne peut pas tester : une pénalité par recherche réduit le coût pour une perte de précision limitée (H3), et le retriever modère l'avantage du RL (H4).

4.2 Hypothèses

Une flèche, une hypothèse. HA2 correspond à l'hypothèse H1 du mémoire, HA3a et HA3b à son hypothèse H2.

HA1 (effet sur la précision). À corpus, retriever et questions identiques, les agents entraînés par renforcement (A4, A5) obtiennent une précision supérieure à celle des harnais fixes (A1 à A3). *Justification.* Selon le cadre, un agent qui estime le gain place mieux ses recherches qu'une règle écrite d'avance. Les auteurs de Search-R1 rapportent un gain de 20 % avec Qwen2.5-3B face à des lignes de base RAG (Jin et al., 2025b), et R1-Searcher annonce lui aussi une nette avance sur des méthodes RAG (Song et al., 2025). Ces comparaisons sont celles des auteurs : HA1 est à tester, non à supposer.

HA2 (modération par la familiarité). L'avantage de HA1 est plus fort sur le jeu vu à l'entraînement (Natural Questions) que sur le jeu non vu (TriviaQA). *Justification.* Dans le cadre, des indices appris dans un environnement renseignent moins bien dans un autre. A4 et A5 ont été entraînés sur NQ et HotpotQA : un gain sur NQ peut refléter une adaptation au jeu plutôt qu'une meilleure décision de chercher. Dans un autre dispositif, un contrôleur appris sur HotpotQA adapte sa conduite à MuSiQue, mais la qualité de réponse y chute (Raikote, 2026).

DONNÉES FICTIVES

HA3a (effet sur le coût). Les agents entraînés (A4, A5) font en moyenne plus de recherches par question que le harnais ReAct (A2), qui laisse aussi le modèle décider. *Justification.* Sans coût dans la récompense, le cadre prédit une surrecherche, alors que le prompt de A2 demande de répondre dès que possible. Wu et al. (2025) estiment que Search-R1 aurait pu éviter 27,7 % de ses étapes de recherche, et Tang et al. (2026) font de cette surrecherche un défaut central des agents. A2 est le point de comparaison retenu parce que A1 et A3 suivent une règle fixe.

HA3b (modération par la connaissance préalable). L'écart de HA3a persiste sur les questions auxquelles le modèle sait déjà répondre sans chercher (A0 juste). *Justification.* Sur ces questions, le gain réel d'une recherche est faible : seul un agent qui ne paie pas ses recherches a intérêt à continuer. Tang et al. (2026) décrivent des agents qui cherchent alors que leurs connaissances suffisent, et le lien entre recherche et connaissances du modèle est documenté par ailleurs (Mallen et al., 2023 ; Yin et al., 2023).

Testabilité et règles de décision. Chaque concept correspond à une colonne des fichiers de résultats, et chaque hypothèse à une règle fixée avant le run complet (tableau 3). Un résultat négatif sera rapporté comme tel.

Hyp.	Colonnes	Test et règle de décision
HA1	`system`, `em`	McNemar apparié sur les 200 questions, pour chaque paire (A4 ou A5 contre A1, A2 ou A3), avec correction de Holm sur les 6 paires. Soutenue si les 6 écarts sont positifs et significatifs à 5 %, partiellement si certains le sont seulement.
HA2	`system`, `em`, `dataset`	Écart moyen entre RL et harnais sur NQ, moins le même écart sur TriviaQA. Soutenue si la borne basse de l'intervalle bootstrap à 95 % est positive.
HA3a	`system`, `n_search`	Différence appariée du nombre de recherches entre RL et A2. Soutenue si la borne basse de l'intervalle bootstrap à 95 % est positive.
HA3b	`n_search`, `em` de A0	Même test, limité aux questions où A0 répond juste. Si elles sont moins de 20, le résultat est présenté comme exploratoire.

TABLE 3 – Hypothèses, colonnes utilisées et règles de décision. Une question sans réponse compte comme fausse.

5 Méthode

5.1 Systèmes

Six systèmes sont comparés (tableau 4). A0 à A3 utilisent le même modèle, Qwen2.5-3B-Instruct (Qwen et al., 2024), avec des prompts écrits pour le projet ; A4 et A5 sont les points de contrôle publics de Search-R1 pour Qwen2.5-3B (versions 0.3, entraînés par PPO et par GRPO) (Jin et al., 2025b). Les fichiers de configuration de ces points de contrôle indiquent qu'ils partent de Qwen2.5-3B, le modèle de base, et non de sa version Instruct. Les modèles de A0 à A3 et de A4/A5 diffèrent donc : un harnais par prompt demande un modèle qui suit des consignes, d'où

DONNÉES FICTIVES

ce choix, qui reste une limite discutée en section 7. Les systèmes disposent du même budget : au plus quatre recherches par question, trois passages par recherche, décodage glouton.

Code	Système	Règle de recherche
A0	Réponse directe	Aucune recherche
A1	RAG	Une recherche avec la question
A2	ReAct par prompt	Le modèle alterne Pensée, Action (`Search` ou `Finish`), Observation
A3	IRCoT	Recherche avec la question, puis une recherche par phrase de raisonnement
A4	Search-R1, PPO	Politique apprise par PPO
A5	Search-R1, GRPO	Politique apprise par GRPO

TABLE 4 – Les six systèmes.

La figure 3 résume le protocole : seuls la règle de recherche et, pour A4 et A5, les poids du modèle changent d'un système à l'autre ; questions, corpus, retriever, budget et mesures sont communs.

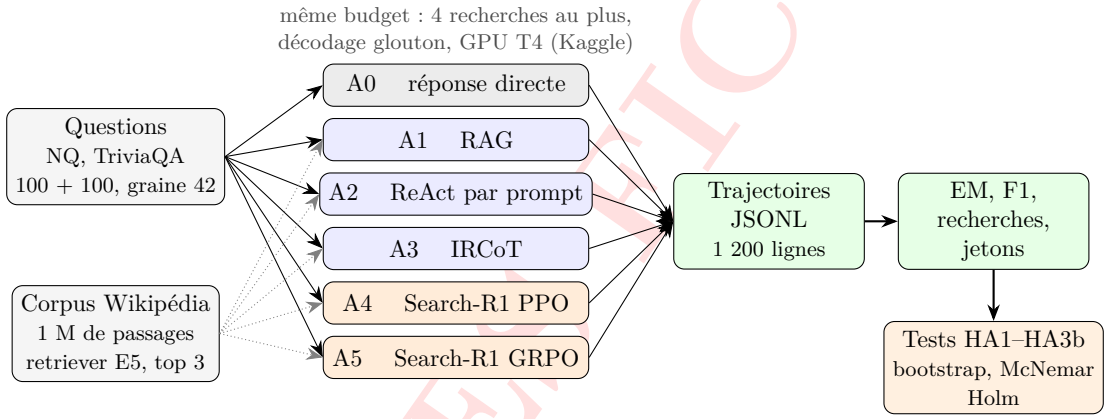


FIGURE 3 – Protocole. Lecture : les mêmes 200 questions passent dans les six systèmes ; ceux qui cherchent (pointillés) interrogent le même corpus avec le même retriever. Chaque passage d'une question dans un système donne une ligne JSONL, d'où sont tirées toutes les mesures et tous les tests.

5.2 Données et corpus

Les questions viennent de Natural Questions (Kwiatkowski et al., 2019), vu à l'entraînement de A4 et A5, et de TriviaQA (Joshi et al., 2017), non vu, dans le format de FlashRAG (Jin et al., 2025c). Nous tirons 100 questions par jeu avec la graine 42. Le corpus est un sous-ensemble d'un million de passages de l'instantané Wikipédia utilisé par Search-R1 ; le retriever est E5 (Wang et al., 2022), celui de l'entraînement de Search-R1.

Le sous-corpus n'est qu'une petite partie du corpus complet, ce qui limite ce que n'importe quel système peut retrouver. Nous avons mesuré, pour chaque jeu, la part des questions dont une réponse attendue apparaît parmi les trois premiers passages renvoyés avec la question pour requête. Avec E5 sur un million de passages, cette part est de 25 % pour NQ et de 44 % pour TriviaQA (500 questions par jeu) ; avec BM25 (Robertson and Zaragoza, 2009) sur 100 000 passages, elle tombait à 9 % et 12 %, ce qui rendait la comparaison peu interprétable. C'est

DONNÉES FICTIVES

pourquoi nous avons retenu NQ et TriviaQA, et non HotpotQA et Bamboogle, dont la couverture est de 17 % et 10 % avec E5 sur un million de passages. Cette mesure est une estimation haute, car un passage peut contenir la réponse sans rapport avec la question.

5.3 Mesures et statistiques

La précision est la correspondance exacte (EM) et le score F1, avec la normalisation de Search-R1. Le coût est le nombre de recherches par question et le nombre de jetons générés. Nous donnons des intervalles de confiance à 95 % par bootstrap (Efron, 1979) (1 000 rééchantillonnages de questions) et comparons deux systèmes sur les mêmes questions par le test de McNemar (McNemar, 1947), avec une correction de Holm (Holm, 1979). Les règles de décision sont celles du tableau 3. Avec 100 questions par jeu, les intervalles font environ ±10 points.

5.4 Puissance de l'expérience

Avant tout run, nous avons estimé par simulation ce que l'expérience peut détecter (tableau 5). Le modèle de simulation suppose une EM de référence de 25 %, l'ordre de grandeur de la couverture de NQ, et des réponses corrélées entre systèmes par une difficulté commune à chaque question ; il est décrit dans `analysis/puissance.py`. Pour HA1, qui porte sur 200 questions avec six comparaisons, un vrai écart de 10 points n'a qu'environ 54 % de chances d'être déclaré significatif après correction de Holm, et un écart de 5 points 10 %. Avec 500 questions par jeu, comme prévu dans le mémoire, la puissance atteint 96 % pour un écart de 10 points. L'article ne peut donc conclure qu'à l'absence d'écarts *importants* ; un écart de quelques points passerait inaperçu. HA2, qui compare deux écarts mesurés chacun sur 100 questions, est la moins bien dotée.

	Écart réel 5 points		Écart réel 10 points		Écart réel 15 points	
Questions	5 %	Holm	5 %	Holm	5 %	Holm
100	13 %	3 %	42 %	19 %	81 %	56 %
200	28 %	10 %	79 %	54 %	99 %	95 %
500	65 %	35 %	99 %	96 %	100 %	100 %
1000	90 %	74 %	100 %	100 %	100 %	100 %

TABLE 5 – Puissance du test de McNemar apparié selon le nombre de questions et l'écart réel d'EM entre deux systèmes : part de 1 000 simulations où l'écart est déclaré significatif, au seuil de 5 % et au seuil le plus strict de la correction de Holm pour six comparaisons (5 %/6). EM de référence : 25 %. Ce tableau ne dépend d'aucune donnée observée.

6 Résultats

Données fictives. Tableaux et figures produits par `analyse_mini.py` à partir des fichiers fictifs. Avec les vrais runs, la même commande les régénère ; le texte de cette section devra être réécrit.

DONNÉES FICTIVES

6.1 Vue d'ensemble

Le tableau 6 et la figure 4 donnent la précision des six systèmes. Sans recherche, le modèle répond juste à 8 % des questions de NQ et 39 % de celles de TriviaQA[fictif] : TriviaQA est plus facile pour le modèle seul, ce qui rejoint l'écart de couverture mesuré en section 5. Toute forme de recherche améliore la précision sur NQ. Les deux agents entraînés sont en tête sur NQ (25 et 24 %), mais leurs intervalles de confiance recouvrent ceux des trois harnais. Sur TriviaQA, le RAG le plus simple (A1) obtient le meilleur score (49 %)[fictif]. Dans notre échantillon, la recherche apporte donc surtout là où le modèle seul échoue, et l'ordre entre systèmes change d'un jeu à l'autre. Ce constat doit être lu en tenant compte de la taille de l'échantillon : avec 100 questions, deux systèmes séparés de moins d'une dizaine de points ne sont pas distinguables (section 5). La figure ne permet pas non plus, à elle seule, d'attribuer un écart à la règle de recherche, puisque A4 et A5 diffèrent aussi des harnais par les poids du modèle.

	NQ (vu)			TriviaQA (non vu)		
Système	EM [IC 95 %]	F1	Rech.	EM [IC 95 %]	F1	Rech.
A0	0,08 [0,03 ; 0,14]	0,25	0,00	0,39 [0,30 ; 0,49]	0,49	0,00
A1	0,18 [0,11 ; 0,26]	0,31	1,00	0,49 [0,39 ; 0,59]	0,57	1,00
A2	0,20 [0,12 ; 0,28]	0,33	1,57	0,41 [0,31 ; 0,50]	0,51	1,41
A3	0,20 [0,13 ; 0,28]	0,31	3,27	0,45 [0,35 ; 0,54]	0,55	3,33
A4	0,25 [0,17 ; 0,33]	0,37	2,29	0,43 [0,33 ; 0,53]	0,51	2,30
A5	0,24 [0,16 ; 0,32]	0,37	1,95	0,45 [0,36 ; 0,55]	0,54	1,94

TABLE 6 – Correspondance exacte (EM) avec son intervalle de confiance bootstrap à 95 %, F1 et nombre moyen de recherches par question, 100 questions par jeu. Les agents entraînés sont sous le trait. Valeurs fictives.

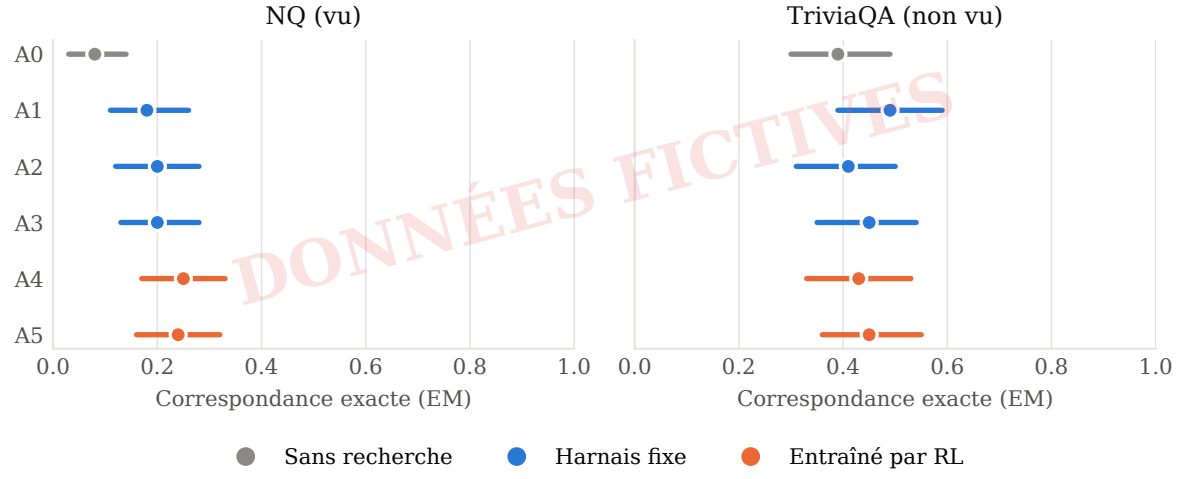


FIGURE 4 – Précision des six systèmes selon le jeu de questions. Données : fichiers fictifs générés le 9 novembre 2026. Une observation = une question traitée par un système ; effectif : 100 questions par jeu et par système, aucune écartée. Le point est l'EM moyen, le trait son intervalle bootstrap à 95 % (1 000 rééchantillonnages).

DONNÉES FICTIVES

6.2 Tests des hypothèses

Le tableau 7 applique les règles de décision fixées avant le run (tableau 3).

Hyp.	Résultat du test	Verdict
HA1	Écarts d'EM RL − harnais, NQ et TriviaQA réunis (200 questions) : A4–A1 0,5 pt (p_{Holm} 1,000) ; A4–A2 3,5 pt (p_{Holm} 1,000) ; A4–A3 1,5 pt (p_{Holm} 1,000) ; A5–A1 1,0 pt (p_{Holm} 1,000) ; A5–A2 4,0 pt (p_{Holm} 1,000) ; A5–A3 2,0 pt (p_{Holm} 1,000). 0 paire(s) sur 6 positives et significatives.	non soutenue
HA2	Écart RL − harnais : 5,2 pt sur NQ, −1,0 pt sur TriviaQA ; différence 6,2 pt [−3,8 ; 15,7].	non soutenue
HA3a	Recherches par question, RL − A2 : 0,63 [0,48 ; 0,79], 200 questions.	soutenue
HA3b	Même écart, questions où A0 répond juste : 1,23 [0,91 ; 1,55], 47 questions.	soutenue

TABLE 7 – Résultat des tests. Écarts d'EM en points de pourcentage, écarts de recherches en nombre de recherches par question ; entre crochets, intervalle bootstrap à 95 %. Valeurs fictives.

HA1 (non soutenue[fictif]). Les six écarts entre agents entraînés et harnais sont positifs mais faibles, et aucun ne résiste à la correction de Holm : 0 paire sur six est significative. Avec 200 questions, un écart de quelques points n'est pas détectable : l'absence d'effet significatif n'est pas la preuve d'une absence d'effet.

HA2 (non soutenue[fictif]). L'avance des agents entraînés est de 5,2 points sur NQ et de −1,0 point sur TriviaQA. La différence va dans le sens attendu, 6,2 points, mais son intervalle [−3,8 ; 15,7] contient zéro.

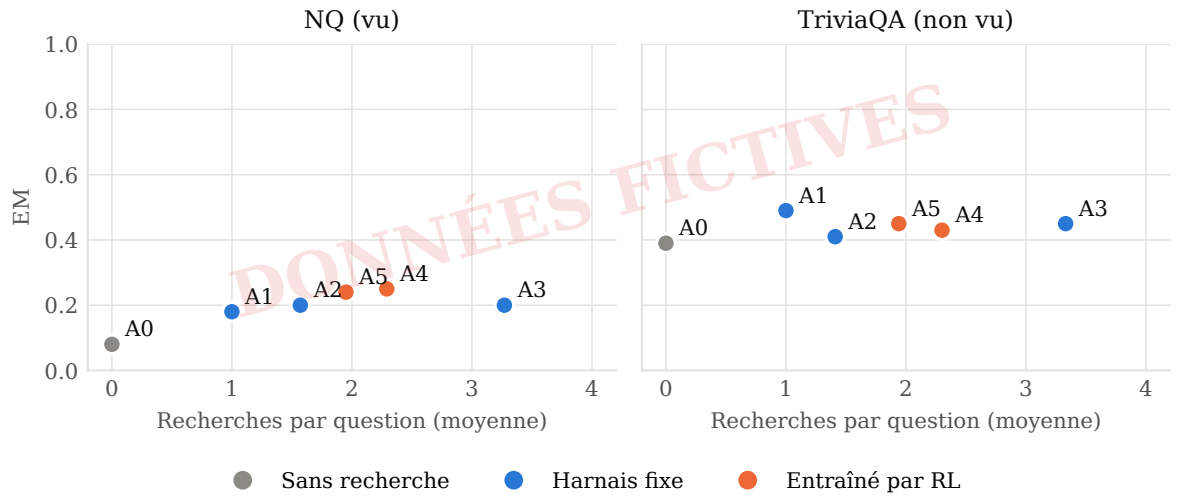
HA3a (soutenue[fictif]). Les agents entraînés font en moyenne 0,63 recherche de plus par question que ReAct (A2), avec un intervalle de [0,48 ; 0,79] sur 200 questions. La figure 5 place chaque système selon sa précision et son coût : à précision voisine, A4 et A5 sont plus coûteux que A1 et A2, moins que A3.

HA3b (soutenue[fictif]). Sur les 47 questions auxquelles A0 répond juste, l'écart avec A2 ne disparaît pas : il passe à 1,23 recherche par question [0,91 ; 1,55]. A2 répond souvent sans chercher quand le modèle connaît la réponse, alors que A4 et A5 cherchent autant qu'ailleurs. Ce contraste est le résultat le plus net de l'expérience ; il porte toutefois sur moins de la moitié des questions, et la connaissance préalable est mesurée par une seule réponse de A0 (section 7).

7 Discussion

Données fictives. Cette discussion commente des résultats fictifs. Elle montre la forme attendue (les cinq mouvements de la trame) ; son contenu sera réécrit après les runs.

DONNÉES FICTIVES



DONNÉES FICTIVES

FIGURE 5 – Précision et coût. Chaque point est un système : en abscisse, le nombre moyen de recherches par question ; en ordonnée, l'EM. Mêmes données et mêmes effectifs que la figure 4. Un système placé plus haut et plus à gauche obtient plus avec moins de recherches.

7.1 Rappel des résultats

À corpus, retriever et questions identiques, les agents entraînés par renforcement ne répondent pas significativement mieux que les harnais fixes, sur le jeu vu comme sur le jeu non vu. Ils se distinguent par leur coût : ils cherchent plus que ReAct, y compris quand le modèle connaît déjà la réponse[fictif].

7.2 Comparaison avec la littérature

Ce résultat nuance le gain rapporté par les auteurs de Search-R1 (Jin et al., 2025b). Il ne le contredit pas : notre corpus est réduit, nos lignes de base partagent le retriever et le budget de l'agent, et notre échantillon ne détecte que des écarts importants. Il rejoint en revanche les travaux sur la surrecherche : Wu et al. (2025) estiment qu'une part importante des recherches de Search-R1 était évitable, et Tang et al. (2026) décrivent des agents qui cherchent alors que leurs connaissances suffisent. L'écart plus fort sur NQ que sur TriviaQA va dans le sens de l'adaptation au jeu d'entraînement observée par Raikote (2026), sans que nos données permettent de le confirmer.

7.3 Explication

Le cadre du fourragement de l'information (section 3) éclaire ces résultats. Un agent cherche tant que le gain espéré d'une recherche dépasse son coût. La récompense de Search-R1 ne porte que sur la réponse finale : aucune recherche n'y coûte quoi que ce soit. Pour l'agent, le seuil d'arrêt est donc nul, et chercher est toujours rationnel, même quand le gain est faible ; c'est ce que montre HA3b. Le prompt de ReAct, à l'inverse, introduit un coût implicite (« *Give the final answer as soon as you have enough information* ») que le modèle Instruct respecte. Quant à la précision, le cadre attend un gain de l'estimation apprise ; mais si le corpus ne contient la réponse que pour une question sur quatre (NQ), une meilleure estimation du gain a peu de

prise : c'est la parcelle qui est pauvre, pas le fourrageur.

Explications concurrentes. Deux autres lectures sont possibles, et notre protocole ne permet pas de les écarter. La première tient au modèle : A4 et A5 partent du modèle de base, A2 du modèle Instruct ; un modèle Instruct pourrait être plus enclin à répondre tôt, indépendamment de toute règle de recherche. La seconde tient au réglage : les prompts de A2 et A3 ont été corrigés pendant la mise au point, ce qui avantage les harnais. Comparer A4 et A5 aux points de contrôle Search-R1 issus de la version Instruct, dans le mémoire, permettra de départager la première.

7.4 Contributions

Théorique. L'étude propose de lire la décision de chercher d'un agent comme un problème de fourragement, et montre ce que ce cadre prédit quand la récompense ignore le coût : une surrecherche qui ne dépend pas de ce que le modèle sait. Elle sépare deux effets souvent confondus, celui de l'apprentissage sur la précision et celui sur le coût. **Pratique.** Trois recommandations, chacune pour un acteur précis. L'équipe qui construit un assistant de questions-réponses sur un petit corpus devrait commencer par mesurer la couverture de ce corpus (la part des questions dont la réponse figure dans les premiers passages) : la mesure prend une vingtaine de minutes sur un processeur gratuit et borne ce que tout système peut atteindre. Elle devrait ensuite comparer un RAG simple et un ReAct par prompt avant d'envisager un entraînement, puisqu'à précision voisine ils coûtent moins de recherches. Enfin, l'équipe qui entraîne un agent devrait mesurer le nombre de recherches sur les questions que le modèle sait déjà résoudre, et ajouter un coût par recherche à la récompense si ce nombre reste élevé ; c'est l'hypothèse H3 du mémoire.

7.5 Limites et pistes

Ces limites valent quels que soient les résultats.

— **Échantillon et puissance.** 100 questions par jeu, une seule graine, des intervalles d'environ ±10 points. D'après la simulation du tableau 5, un vrai écart de 10 points n'aurait qu'environ 54 % de chances d'être détecté pour HA1 : une absence d'effet significatif ne prouve pas l'absence d'effet.

— **Corpus.** Un million de passages, avec une couverture de 25 % (NQ) et 44 % (TriviaQA) pour la réponse dans les trois premiers passages. Le plafond de précision d'un système qui dépend de la recherche est donc bas, et A4 et A5 ont été entraînés avec le corpus complet.

— **Modèles.** A0 à A3 utilisent Qwen2.5-3B-Instruct, A4 et A5 un modèle entraîné par renforcement à partir de Qwen2.5-3B (base) : l'écart observé mélange la règle de recherche et le modèle. Des points de contrôle partant de la version Instruct existent : ils permettraient de réduire cet écart dans le mémoire.

— **Prompts.** Ceux de A2 et A3 sont écrits pour ce projet avec deux exemples ; d'autres prompts pourraient changer les résultats.

— **Connaissance préalable.** Elle est mesurée par une seule réponse de A0, produite par le modèle Instruct, et non par le modèle de base dont partent A4 et A5.

— **Causalité.** Nous comparons des systèmes ; nous ne pouvons pas attribuer un écart à un seul facteur.

DONNÉES FICTIVES

— **Part de l'IA dans la démarche.** Le corpus bibliographique, le code des systèmes et une première version de ce texte ont été produits avec un assistant (Claude). Les références ont été vérifiées dans OpenAlex ; les articles n'ont pas été lus en entier ; les choix de protocole et l'interprétation sont ceux de l'auteur. Le détail figure dans le carnet de bord, et la méthode de recherche documentaire en annexe A.

Pistes. Deux hypothèses du mémoire ne sont pas testées ici : une pénalité par recherche dans la récompense réduit-elle le nombre d'appels sans perte forte de précision (entraînement GRPO à petite échelle), et un changement de retriever dégrade-t-il plus les agents entraînés que les harnais fixes ? Une analyse qualitative des échecs sur des trajectoires annotées compléterait la mesure : le mémoire prévoit d'en annoter 100 à la main et d'en faire classer 300 par un juge automatique, avec un accord mesuré par le kappa de Cohen.

8 Conclusion

Données fictives. Conclusion écrite sur les résultats fictifs, à réécrire.

Nous avons comparé, à corpus, retriever, budget et questions identiques, deux agents de recherche entraînés par renforcement et quatre systèmes à règle fixe. Sur 200 questions, l'apprentissage ne se traduit pas par un gain de précision détectable, mais par un coût plus élevé : les agents entraînés cherchent plus, même quand ils n'en ont pas besoin[fictif]. Le cadre du fourragement de l'information explique cet écart par l'absence de coût dans la récompense. Ces conclusions valent pour un petit corpus, un petit modèle et un petit échantillon. Le mémoire les mettra à l'épreuve sur sept jeux de questions, en testant une pénalité par recherche (H3) et un changement de retriever (H4).

Références

Akari Asai, Zeqiu Wu, Yizhong Wang, et al. Self-RAG : Learning to Retrieve, Generate, and Critique through Self-Reflection, 2023. URL `https://arxiv.org/abs/2310.11511`.

Leif Azzopardi. The economics in interactive information retrieval. In *Proceedings of SIGIR*, 2011. doi : 10.1145/2009916.2009923.

Mingyang Chen, Linzhuang Sun, Tianpeng Li, et al. ReSearch : Learning to Reason with Search for LLMs via Reinforcement Learning. In *Advances in Neural Information Processing Systems*, 2025. doi : 10.52202/085713-2858.

Bradley Efron. Bootstrap methods : Another look at the jackknife. *The Annals of Statistics*, 7 (1) :1–26, 1979. doi : 10.1214/aos/1176344552.

Daya Guo, Dejian Yang, Haowei Zhang, et al. DeepSeek-R1 incentivizes reasoning in LLMs through reinforcement learning. *Nature*, 2025. doi : 10.1038/s41586-025-09422-z.

Sture Holm. A simple sequentially rejective multiple test procedure. *Scandinavian Journal of Statistics*, 6(2) :65–70, 1979. doi : 10.2307/4615733.

DONNÉES FICTIVES

Soyeong Jeong, Jinheon Baek, Sukmin Cho, Sung Ju Hwang, and Jong Park. Adaptive-RAG : Learning to Adapt Retrieval-Augmented Large Language Models through Question Complexity. In *Proceedings of NAACL-HLT*, 2024. doi : 10.18653/v1/2024.naacl-long.389.

Pengcheng Jiang, Xueqiang Xu, Jiacheng Lin, et al. s3 : You Don't Need That Much Data to Train a Search Agent via RL. In *Proceedings of EMNLP*, pages 21610–21628, 2025. doi : 10.18653/v1/2025.emnlp-main.1095.

Zhengbao Jiang, Frank F. Xu, Luyu Gao, et al. Active Retrieval Augmented Generation. In *Proceedings of EMNLP*, 2023. doi : 10.18653/v1/2023.emnlp-main.495.

Bowen Jin, Jinsung Yoon, Priyanka Kargupta, et al. An Empirical Study on Reinforcement Learning for Reasoning-Search Interleaved LLM Agents, 2025a. URL `https://arxiv.org/abs/2505.15117`.

Bowen Jin, Hansi Zeng, Zhenrui Yue, et al. Search-R1 : Training LLMs to Reason and Leverage Search Engines with Reinforcement Learning, 2025b. URL `https://arxiv.org/abs/2503.09516`.

Jiajie Jin, Yutao Zhu, Zhicheng Dou, et al. FlashRAG : A Modular Toolkit for Efficient Retrieval-Augmented Generation Research. In *Companion Proceedings of the ACM Web Conference (WWW)*, 2025c. doi : 10.1145/3701716.3715313.

Mandar Joshi, Eunsol Choi, Daniel S. Weld, and Luke Zettlemoyer. TriviaQA : A Large Scale Distantly Supervised Challenge Dataset for Reading Comprehension. In *Proceedings of ACL*, 2017. doi : 10.18653/v1/P17-1147.

Tom Kwiatkowski, Jennimaria Palomaki, Olivia Redfield, et al. Natural questions : A benchmark for question answering research. *Transactions of the Association for Computational Linguistics*, 7 :452–466, 2019. doi : 10.1162/tacl_a_00276.

Patrick Lewis, Ethan Perez, Aleksandra Piktus, et al. Retrieval-Augmented Generation for Knowledge-Intensive NLP Tasks, 2020. URL `https://arxiv.org/abs/2005.11401`.

Minhua Lin, Zongyu Wu, Zhichao Xu, et al. A Comprehensive Survey on Reinforcement Learning-based Agentic Search : Foundations, Roles, Optimizations, Evaluations, and Applications, 2025. URL `https://arxiv.org/abs/2510.16724`.

Tzu-Han Lin, Wei-Lin Chen, Chen-An Li, et al. AdaSearch : Balancing Parametric Knowledge and Search in Large Language Models via Reinforcement Learning. In *Proceedings of EMNLP*, 2026. doi : 10.18653/2026.emnlp-main.2696.

Nelson F. Liu, Kevin Lin, John Hewitt, et al. Lost in the Middle : How Language Models Use Long Contexts. *Transactions of the Association for Computational Linguistics*, 2024. doi : 10.1162/tacl_a_00638.

Alex Mallen, Akari Asai, Victor Zhong, et al. When Not to Trust Language Models : Investigating Effectiveness of Parametric and Non-Parametric Memories. In *Proceedings of ACL*, 2023. doi : 10.18653/v1/2023.acl-long.546.

DO NOT DISTRIBUTE

Quinn McNemar. Note on the sampling error of the difference between correlated proportions or percentages. *Psychometrika*, 12(2) :153–157, 1947. doi : 10.1007/BF02295996.

Lang Mei, Zhihan Yang, Xiaohan Yu, et al. AI-SearchPlanner : Modular Agentic Search via Pareto-Optimal Multi-Objective Reinforcement Learning, 2025. URL `https://arxiv.org/abs/2508.20368`.

Viktor Moskvoretskii, Maria Marina, Mikhail Salnikov, et al. Adaptive Retrieval Without Self-Knowledge ? Bringing Uncertainty Back Home. In *Proceedings of ACL*, 2025. doi : 10.18653/v1/2025.acl-long.319.

Francesca Pezzuti, Ophir Frieder, Fabrizio Silvestri, Sean MacAvaney, and Nicola Tonellotto. How AI agents search. *PLoS ONE*, 21(10) :e0360157, 2026. doi : 10.1371/journal.pone.0360157.

Peter Pirolli and Stuart Card. Information foraging. *Psychological Review*, 106(4) :643–675, 1999. doi : 10.1037/0033-295X.106.4.643.

Biswas Poudel, Nilson Chapagain, Amit Kumar, and Xianshun Jiang. Reasoning-Search-Augmented LLMs : An Operational Taxonomy, Benchmark Analysis and Controlled Evidence Synthesis, 2026. URL `https://arxiv.org/abs/2610.29189`.

Hongjin Qian and Zheng Liu. Scent of Knowledge : Optimizing Search-Enhanced Reasoning with Information Foraging. In *Advances in Neural Information Processing Systems (NeurIPS)*, 2025. doi : 10.52202/085713-5204.

Qwen, An Yang, Baosong Yang, et al. Qwen2.5 Technical Report, 2024. URL `https://arxiv.org/abs/2412.15115`.

Pranav Raikote. Policy over Prompt : Reinforcement Learning for Agentic RAG. Mémoire déposé sur DiVA, urn :nbn :se :su :diva-256954, 2026.

Stephen E. Robertson and Hugo Zaragoza. The probabilistic relevance framework : BM25 and beyond. *Foundations and Trends in Information Retrieval*, 3(4) :333–389, 2009. doi : 10.1561/1500000019.

John Schulman, Filip Wolski, Prafulla Dhariwal, et al. Proximal Policy Optimization Algorithms, 2017. URL `https://arxiv.org/abs/1707.06347`.

Zhihong Shao, Peiyi Wang, Qihao Zhu, et al. DeepSeekMath : Pushing the Limits of Mathematical Reasoning in Open Language Models, 2024. URL `https://arxiv.org/abs/2402.03300`.

Huatong Song, Jinhao Jiang, Yingqian Min, et al. R1-Searcher : Incentivizing the Search Capability in LLMs via Reinforcement Learning, 2025. URL `https://arxiv.org/abs/2503.05592`.

George J. Stigler. The economics of information. *Journal of Political Economy*, 69(3) :213–225, 1961. doi : 10.1086/258464.

Hao Sun, Zile Qiao, Jiayan Guo, et al. ZeroSearch : Incentivize the Search Capability of LLMs without Searching, 2025. URL `https://arxiv.org/abs/2505.04588`.

DONNÉES FICTIVES

Yunbo Tang, Chengyi Yang, Shiyu Liu, et al. SAAS : Self-Aware Reinforcement Learning for Over-Search Mitigation in Agentic Search, 2026. URL https://arxiv.org/abs/2605.29796.

Harsh Trivedi, Niranjan Balasubramanian, Tushar Khot, and Ashish Sabharwal. Interleaving Retrieval with Chain-of-Thought Reasoning for Knowledge-Intensive Multi-Step Questions. In *Proceedings of ACL*, 2023. doi : 10.18653/v1/2023.acl-long.557.

Hongru Wang, Cheng Qian, Wanjun Zhong, et al. Acting Less is Reasoning More ! Teaching Model to Act Efficiently, 2025. URL https://arxiv.org/abs/2504.14870.

Liang Wang, Nan Yang, Xiaolong Huang, et al. Text Embeddings by Weakly-Supervised Contrastive Pre-training, 2022. URL https://arxiv.org/abs/2212.03533.

Peilin Wu, Mian Zhang, Xinlu Zhang, Xinya Du, and Zhiyu Chen. Search Wisely : Mitigating Sub-optimal Agentic Searches By Reducing Uncertainty. In *Proceedings of EMNLP*, pages 19734–19745, 2025. doi : 10.18653/v1/2025.emnlp-main.998.

Shunyu Yao, Jeffrey Zhao, Dian Yu, et al. ReAct : Synergizing Reasoning and Acting in Language Models, 2022. URL https://arxiv.org/abs/2210.03629.

Zhangyue Yin, Qiushi Sun, Qipeng Guo, et al. Do Large Language Models Know What They Don't Know ? In *Findings of ACL*, 2023. doi : 10.18653/v1/2023.findings-acl.551.

Ori Yoran, Tomer Wolfson, Ori Ram, et al. Making Retrieval-Augmented Language Models Robust to Irrelevant Context, 2023. URL https://arxiv.org/abs/2310.01558.

Wenlin Zhang, Kuicai Dong, Junyi Li, et al. To Search or Not to Search : Aligning the Decision Boundary of Deep Search Agents via Causal Intervention. In *Proceedings of the ACM Web Conference (WWW)*, 2026. doi : 10.1145/3774904.3792235.

Shu Zhao, Tan Yu, Anbang Xu, et al. ParallelSearch : Train your LLMs to Decompose Query and Search Sub-queries in Parallel with Reinforcement Learning, 2025. URL https://arxiv.org/abs/2508.09303.

Yibo Zhao, Zichen Ding, Jiayi Wu, Zun Wang, and Xiang Li. Retrieval, Reward, and Training Protocols : What Matters in Training Search Agents ?, 2026. URL https://arxiv.org/abs/2605.27881.

Yuxiang Zheng, Dayuan Fu, Xiangkun Hu, et al. DeepResearcher : Scaling Deep Research via Reinforcement Learning in Real-world Environments. In *Proceedings of EMNLP*, 2025. doi : 10.18653/v1/2025.emnlp-main.22.

DONNÉES FICTIVES

A Méthode de la recherche documentaire

La recherche a suivi la feuille de route de l'étape 5.2 de la trame : question en trois blocs, articles témoins, équation par blocs, mesure de la précision sur un tirage aléatoire de 20 résultats, boule de neige, vérification des références. Les requêtes ont été lancées par un agent d'IA (Claude)

connecté à OpenAlex, les 3 et 9 novembre 2026. Les cinq articles témoins sont Search-R1, R1-Searcher, ReAct, IRCoT et Self-RAG.

N°	Requête	Nombre	Résultat et décision
1	Renforcement ET recherche agentique ET modèles de langage, depuis 2022	1 036	Précision 7/20 (bruit : réseaux 6G, médecine). Ajout d'un bloc « tâche ».
2	Bloc 1 ET questions-réponses (multi-sauts, à forte intensité de connaissances)	336	Précision inchangée (7/20) : bruit multimodal, télédétection. Termes trop larges retirés, exclusions ajoutées.
3	Équation retenue (OQL ci-dessous), depuis 2023	103	Précision environ 15/20.
4	Vérification des 91 références du corpus de départ	91	91 exactes, aucune rétractée.
5	Consensus, question en version fermée	10	Tous favorables au RL ; biais de publication probable. 4 candidats ajoutés.
6	Boule de neige : articles citant Search-R1	14	OpenAlex ne rattache que 14 citations à la notice arXiv : peu exploitable.
9	Équation 3 réécrite depuis le journal	116	L'équation exacte de la ligne 3 n'avait pas été conservée ; l'OQL est désormais noté.
10	Rappel sur les cinq témoins	116	1 sur 5 : les harnais fixes sont hors du bloc RL ; R1-Searcher n'emploie pas les mots de la tâche.
11	Tri des 116 titres	116	4 inclus, 58 doutes, 38 exclus proposés ; non relu à ce jour.
12	Requête sémantique : comparaison d'agents RL et de harnais à conditions identiques	50	Zhao et al. (2026) et Pezzuti et al. (2026), absents de l'équation, ajoutés.
14	Texte intégral : « information foraging » ET agents de recherche	58	Dans 4 PDF sur 5, le terme vient d'une seule référence (InForage) : cadre retenu.
15	Texte intégral : modèles économiques ou rationalité limitée ET agents	57	Aucune mention de Stigler ni de Simon dans 10 PDF : Simon retiré.
17	Vérification finale des références de l'article	46	43 exactes par titre, 3 exactes par DOI arXiv ; 6 passées à leur version publiée. Zéro référence introuvable.

Équation 3, en OQL :

```
works where title-abstract-keywords has (("reinforcement learning" or GRPO or RLVR) and ("search
↪ agent" or "agentic search" or "search-augmented" or "search engine" or "adaptive retrieval"
↪ or "retrieval-augmented reasoning") and ("question answering" or "multi-hop" or HotpotQA or
↪ "Natural Questions") and (LLM or "language model") and not (multimodal or "visual question"
↪ or "remote sensing" or network)) and published since 2023
```

DONNÉES FICTIVES

Compte rendu de sélection. Revue narrative : la trame n'exige qu'une décision Inclus / Exclu. Le corpus de départ compte 91 articles en 9 thèmes ; la recherche OpenAlex et Consensus a ajouté 23 candidats et 9 exclus (motifs E1, hors sujet, et E2, pas une étude empirique). L'article en cite 46, dont 3 pour le cadre théorique. Le journal complet est joint au carnet de bord.

B Consignes données aux modèles

Les consignes sont en anglais, langue des questions. Celle de Search-R1 est reprise du dépôt officiel (licence Apache 2.0) ; les autres ont été écrites pour ce projet ; celles de A2 et A3 ont été corrigées une fois pendant la mise au point, avant toute question d'évaluation. Les accolades marquent ce que le programme remplace.

A1, RAG.

```
Answer the question. The documents below were retrieved for it: use them if they are useful,
↪  otherwise rely on your own knowledge. Give only the final answer inside <answer> and
↪  </answer>, without explanation. For example, <answer> Beijing </answer>.

{docs}
Question: {question}
```

A2, ReAct (consigne seule ; suivent deux exemples résolus, puis la question).

```
Solve the question by interleaving Thought, Action and Observation steps. Thought reasons
↪  about the current situation. Action is one of two types:
(1) Search[query]: search for the query; the top passages come back as the Observation.
(2) Finish[answer]: return the final answer and finish.
Write one Thought and one Action at a time, then stop and wait for the Observation. Give the
↪  final answer as soon as you have enough information. Never repeat a search query. If the
↪  passages do not help after a few searches, rely on your own knowledge and give your best
↪  answer with Finish[answer]. Start your reply with "Thought:".
```

A4 et A5, Search-R1.

```
Answer the given question. You must conduct reasoning inside <think> and </think> first every
↪  time you get new information. After reasoning, if you find you lack some knowledge, you
↪  can call a search engine by <search> query </search> and it will return the top searched
↪  results between <information> and </information>. You can search as many times as your
↪  want. If you find no further external knowledge needed, you can directly provide the answer
↪  inside <answer> and </answer>, without detailed illustrations. For example, <answer>
↪  Beijing </answer>. Question: {question}
```

Les consignes de A0 (réponse directe) et de A3 (IRCoT) sont dans le dossier `prompts/` du dépôt.

C Fiche données

DONNÉES FICTIVES

Rubrique	Contenu
Source : questions	Existante. FlashRAG (Hugging Face, `RUC-NLPIR/FlashRAG_datasets`), configurations `nq` et `triviaqa`, partie `test` : 3 610 et 11 313 questions.
Source : corpus	Existante. `maknee/wiki-18-subsets`, sous-corpus d'un million de passages et son index E5. Jeu tiers sans fiche descriptive : l'alignement entre index et corpus a été vérifié (similarité minimale 0,9997 sur 50 passages).
Source : modèles	`Qwen/Qwen2.5-3B-Instruct` (A0 à A3) ; points de contrôle Search-R1 v0.3, PPO (A4) et GRPO (A5), entraînés sur NQ et HotpotQA.
Source : trajectoires	Produites par ce projet sur Kaggle (GPU T4). Dans cette version : fichiers fictifs, produits par `analysis/donnees_fictives.py`.
Une ligne	Une question traitée par un système : 100 questions × 2 jeux × 6 systèmes, soit 1 200 lignes.
Échantillon	100 questions par jeu tirées avec la graine 42. Mise au point sur un autre tirage (graine 7), sans aucune question d'évaluation.
Qui manque	Questions multi-étapes (HotpotQA, MuSiQue), écartées faute de couverture ; faits postérieurs à 2018 ; langues autres que l'anglais.
Modifications	Aucune question retirée. Seul ajout : « ? » en fin de question s'il manque, comme Search-R1.
Droits	Licences de FlashRAG, du sous-corpus, de Qwen2.5 et des points de contrôle Search-R1 : à vérifier avant diffusion des données.

DONNÉES FICTIVES