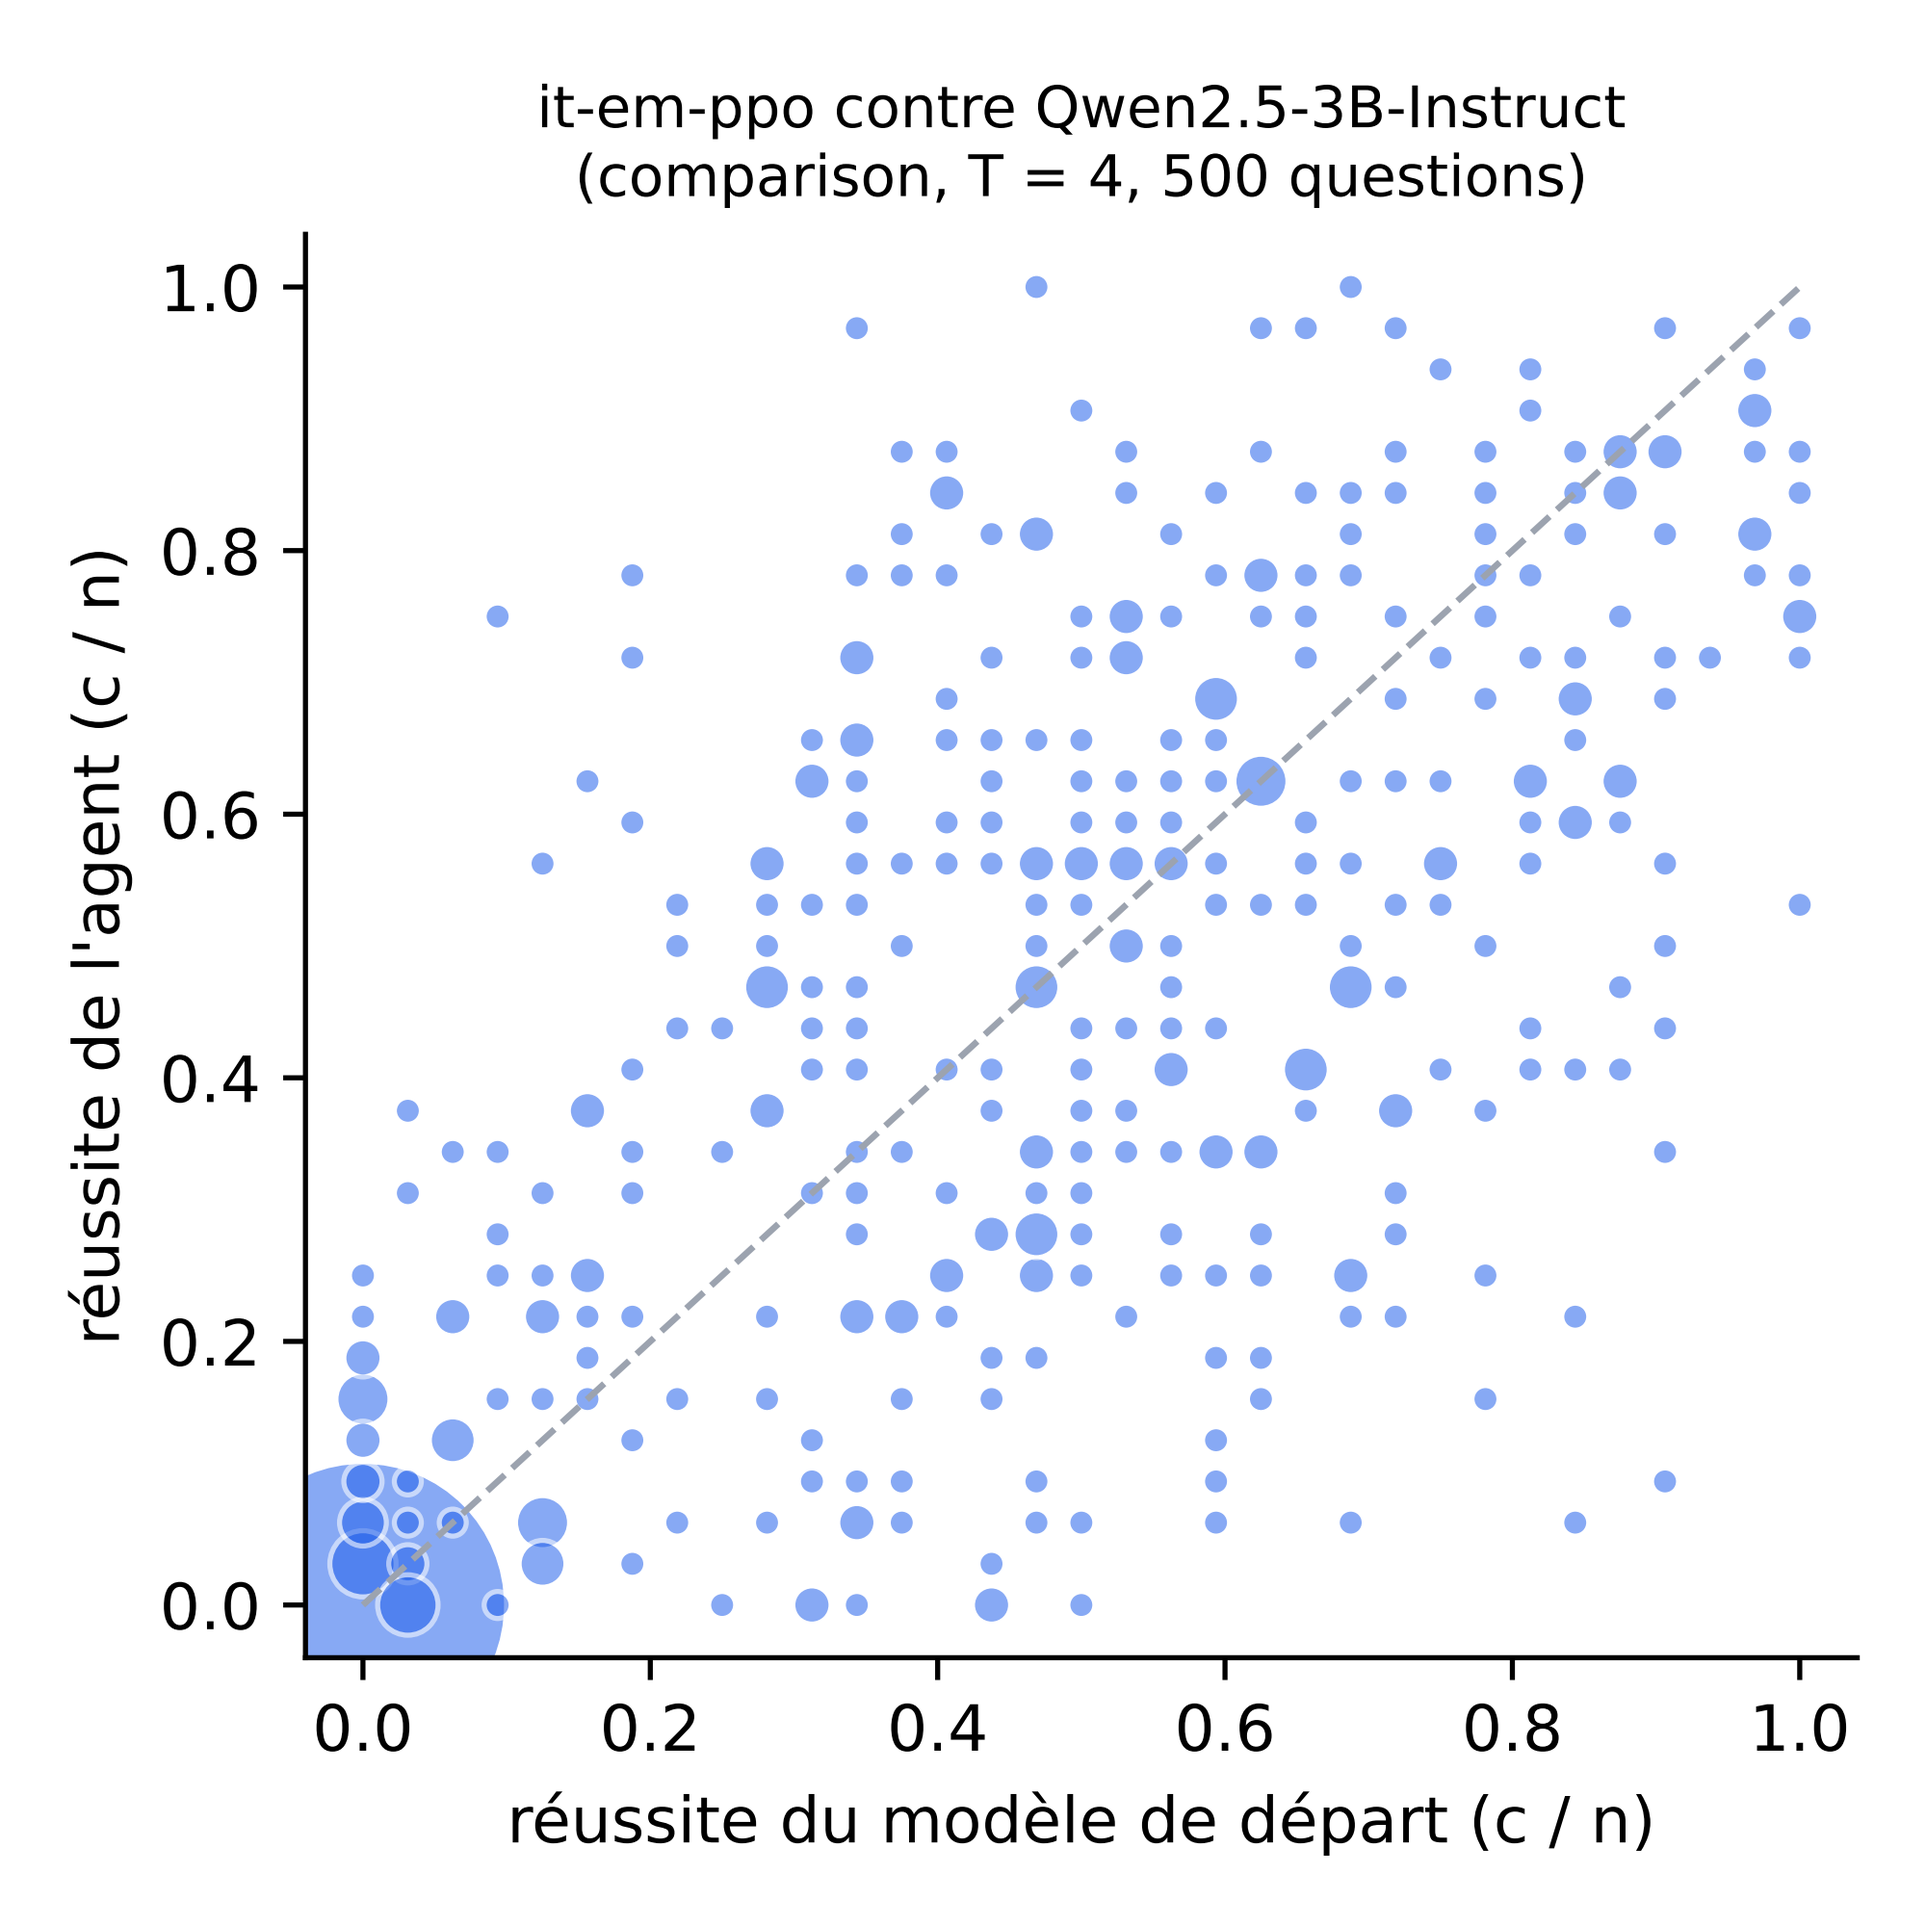
it-em-ppo contre Qwen2.5-3B-Instruct
(comparison, T = 4, 500 questions)
réussite de l'agent (c / n)
réussite du modèle de départ (c / n)
0.0
0.2
0.4
0.6
0.8
1.0