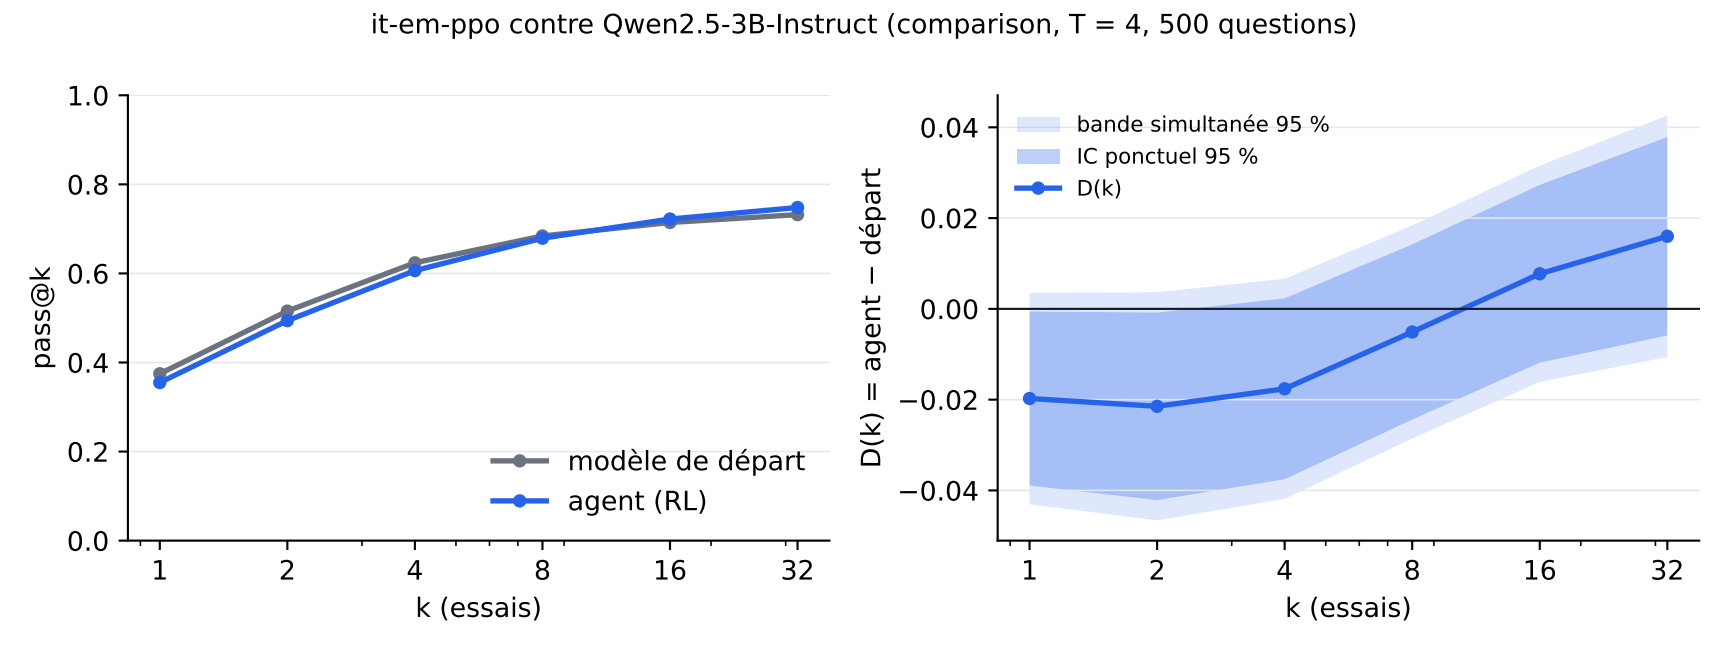
it-em-ppo contre Qwen2.5-3B-Instruct (comparison, T = 4, 500 questions)
pass@k
1.0
0.8
0.6
0.4
0.2
0.0
modèle de départ
agent (RL)
1
2
4
8
16
32
k (essais)
D(k) = agent − départ
0.04
0.02
0.00
−0.02
−0.04
bande simultanée 95 %
IC ponctuel 95 %
D(k)
1
2
4
8
16
32
k (essais)